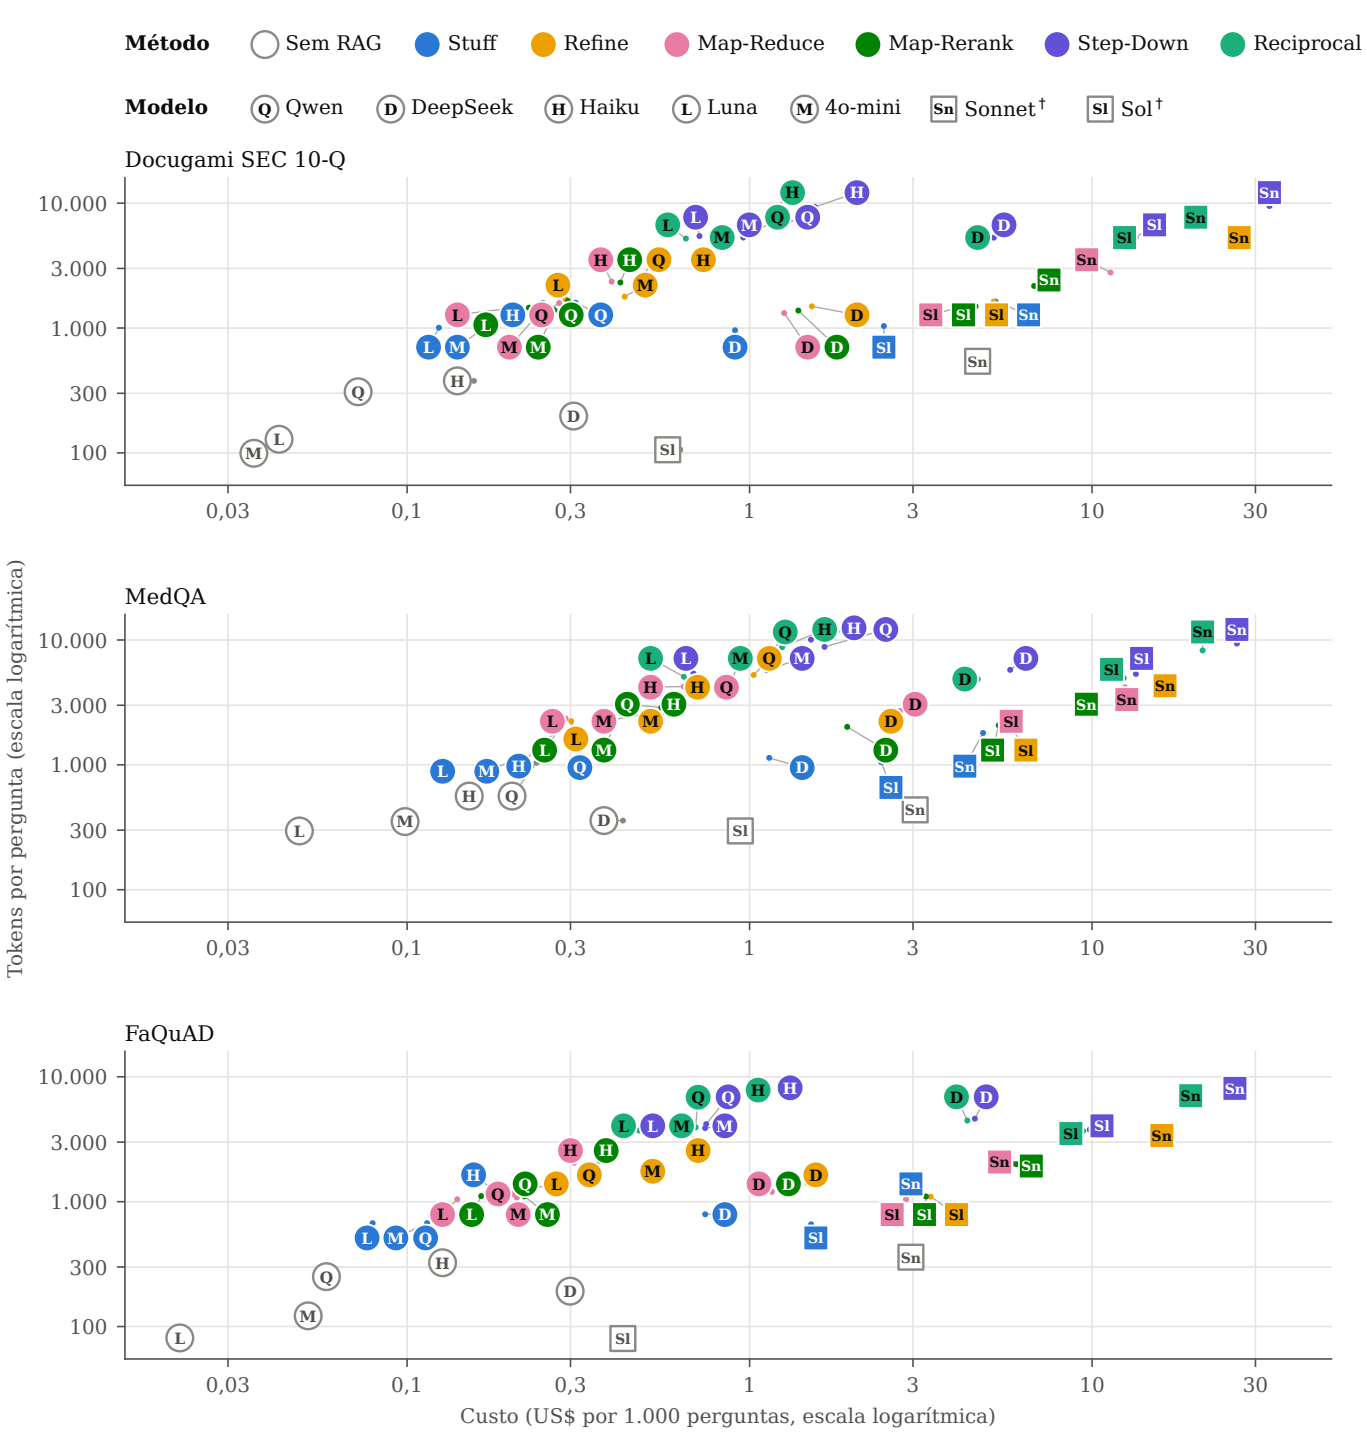

Método
Sem RAG
Stuff
Refine
Map-Reduce
Map-Rerank
Step-Down
Reciprocal
Modelo
Q Qwen
D DeepSeek
H Haiku
L Luna
M 4o-mini
Sn Sonnet†
Sl Sol†
Docugami SEC 10-Q
MedQA
FaQuAD
Tokens por pergunta (escala logarítmica)
10.000
3.000
1.000
300
100
0,03
0,1
0,3
1
3
10
30
Custo (US$ por 1.000 perguntas, escala logarítmica)