Graduação em Engenharia de Computação

Trabalho de Conclusão de Curso.

Data da Defesa 11/2026

Maximizando eficiência de RAG: uma análise comparativa de métodos RAG

AFONSO HENRIQUES MASSUNARI, RYAN ALVES MAZZEU, CARLOS HENRIQUE VALÉRIO DE MORAES (Orientador)

RESUMO A geração aumentada por recuperação ancora as respostas de modelos de linguagem em documentos, mas o método de injeção desses documentos costuma ser avaliado com poucos modelos, sem controle sem recuperação e por uma única métrica de similaridade. Este trabalho compara seis desses métodos (Stuff, Refine, Map-Reduce, Map-Rerank, Query Step-Down e Reciprocal) e um controle sem recuperação em três conjuntos de dados públicos com gabarito: relatórios financeiros (Docugami), questões de exame médico (MedQA) e documentos do ensino superior em português (FaQuAD). Sete modelos de quatro empresas, dois deles em uma amostra menor, responderam às perguntas em 12.150 execuções, com qualidade medida contra o gabarito. O efeito da recuperação dependeu do domínio: no FaQuAD, o Stuff elevou a cobertura das respostas de 35%–50% para 82%–92%; no MedQA, em que os modelos já acertam de 71% a 96% sem recuperação, nenhum método alterou significativamente a acurácia de nenhum deles. No financeiro e no FaQuAD, a ordem dos métodos se repetiu entre os modelos, mas mudou entre domínios: o Query Step-Down liderou no financeiro, e o Stuff, o método mais barato, no FaQuAD. O Reciprocal custou cinco vezes o Stuff e ficou entre os últimos. Com o método adequado, modelos econômicos não ficaram significativamente abaixo dos intermediários da mesma família, custando de 3 a 20 vezes menos. No financeiro, a similaridade de cosseno favoreceu o controle sem recuperação na maioria dos modelos, embora o Stuff trouxesse mais valores corretos em todos. A busca aproximada do banco vetorial não alterou os resultados.

PALAVRAS-CHAVE Banco vetorial, geração aumentada por recuperação, modelos de linguagem, RAGAS, similaridade de cosseno

I. INTRODUÇÃO

OS Modelos de Linguagem de Grande Porte (LLMs) ampliaram de forma expressiva o alcance de sistemas de processamento de linguagem natural, mas continuam sujeitos a alucinações e ao envelhecimento do conhecimento aprendido durante o treinamento. A Geração Aumentada por Recuperação (RAG) [1] consolidou-se como a principal alternativa não paramétrica para mitigar esse problema [2]: em vez de depender apenas do conhecimento interno do modelo, o sistema recupera trechos relevantes de uma base documental, indexada em um banco de dados vetorial [3], e os fornece ao LLM no momento da geração. Na prática, porém, um pipeline RAG envolve uma sequência de escolhas de engenharia — o método de injeção do contexto, o LLM, o banco vetorial, o modelo de embedding — cujo efeito combinado sobre a qualidade da resposta, o consumo de tokens e o tempo de execução raramente é medido de forma sistemática.

Şakar e Emekci [4] realizaram a análise mais abrangente desse espaço de decisão: uma busca em grade com 23.625 configurações, cruzando seis métodos de RAG (Stuff, Refine, Map-Reduce, Map-Rerank, Query Step-Down e Reciprocal RAG), três bancos vetoriais, três modelos de embedding, três LLMs e filtros de compressão contextual, sobre três domínios em inglês — relatórios financeiros (SEC 10-Q), documentação técnico-científica (artigo do Llama 2) e questões médicas (MedQA). O estudo conclui que não há arquitetura universalmente ótima: o Reciprocal RAG obteve a maior similaridade com as respostas de referência, enquanto o Stuff foi o mais rápido e o mais econômico em tokens.

Três aspectos daquele desenho limitam o alcance das conclusões. Primeiro, a qualidade foi medida apenas pela similaridade de cosseno entre a resposta gerada e a de referência, que mede proximidade semântica e não acerto: uma resposta fluente no vocabulário do domínio pode ficar

próxima da referência sem conter o valor pedido. Segundo, o desenho não inclui um controle sem recuperação, o que impede separar o que o RAG acrescenta do que o LLM já sabe — questão central em domínios como o médico, em que as perguntas vêm de provas públicas [5], [6]. Terceiro, a comparação entre os métodos (Tabela 1 do estudo) agrega os três LLMs e as demais configurações, o que não mostra se a ordem dos métodos se mantém de um modelo para outro. Além disso, todos os documentos estavam em inglês, idioma em que se concentra a literatura de avaliação de RAG [7].

Este trabalho compara os mesmos seis métodos e um controle sem RAG em três conjuntos de dados públicos com gabarito: dois dos três domínios do estudo de referência, o financeiro (Docugami SEC 10-Q) e o médico (MedQA-USMLE [8]), e um conjunto em português, o FaQuAD [9], com perguntas sobre documentos do ensino superior brasileiro. Sete LLMs de quatro empresas, dois deles de pesos abertos, com 9,7 bilhões e 1,6 trilhão de parâmetros, responderam às mesmas perguntas: cinco modelos de faixa de preço econômica em uma amostra maior, e dois intermediários em uma amostra menor, para verificar se as conclusões se mantêm em modelos mais capazes. A qualidade foi medida diretamente contra o gabarito de cada conjunto — acurácia no MedQA, cobertura de tokens no FaQuAD e presença dos valores numéricos da resposta de referência no Docugami —, e complementada pelas métricas do RAGAS [10], com o juiz automático validado contra um conjunto anotado [11].

O trabalho busca responder às seguintes questões de pesquisa:

QP1. Como os seis métodos de RAG se comparam em qualidade da resposta e em custo (tokens, tempo e US$) em cada domínio?

QP2. A ordem dos métodos se mantém entre LLMs de empresas, tamanhos e faixas de preço diferentes?

QP3. Quanto a recuperação acrescenta em relação ao próprio LLM sem RAG, e esse ganho depende do domínio e do modelo?

QP4. A busca aproximada do banco vetorial (HNSW, no ChromaDB) altera os resultados em relação à busca exata (FAISS)?

Uma questão metodológica atravessa as quatro: se a similaridade de cosseno, métrica do estudo de referência, mede o acerto das respostas. Ela foi calculada em todas as execuções, ao lado das métricas comparadas com o gabarito, e recalculada com o mesmo modelo de embedding do estudo de referência, para a comparação direta com os seus resultados.

O restante do artigo está organizado da seguinte forma. A Seção II apresenta a revisão bibliográfica. A Seção III descreve os conjuntos de dados, o pipeline, os LLMs, as métricas e a análise estatística. A Seção IV apresenta e discute os resultados, junto com as limitações do estudo. A Seção V conclui o trabalho.

II. REVISÃO BIBLIOGRÁFICA

A. GERAÇÃO AUMENTADA POR RECUPERAÇÃO

Na formulação de Lewis et al. [1], um sistema RAG combina um componente de recuperação, que seleciona trechos de uma coleção de documentos a partir da pergunta, e um componente gerador, que condiciona a resposta a esses trechos. Em implementações atuais, os documentos são divididos em fragmentos (chunks) [12], convertidos em vetores por um modelo de embedding e armazenados em um banco vetorial [3]; a pergunta é codificada pelo mesmo modelo, e os k fragmentos mais próximos são entregues ao LLM. A arquitetura reduz alucinações e permite atualizar o conhecimento sem retreinar o modelo [2], mas sua robustez depende de decisões tomadas empiricamente: Barnett et al. [13] catalogam sete pontos de falha recorrentes, entre eles a recuperação de trechos errados e a incapacidade do gerador de extrair a resposta de um contexto que a contém.

B. MÉTODOS DE INJEÇÃO DE CONTEXTO

Uma vez recuperados os fragmentos, há diferentes formas de entregá-los ao LLM [14]. No **Stuff**, todos os fragmentos são concatenados em um único prompt. No **Refine**, a resposta é construída a partir do primeiro fragmento e refinada sequencialmente a cada fragmento seguinte. No **Map-Reduce**, cada fragmento gera uma resposta parcial independente, e uma chamada final combina as parciais. No **Map-Rerank**, cada fragmento gera uma resposta acompanhada de uma nota de confiança, e mantém-se apenas a de maior confiança. Şakar e Emekci [4] acrescentam dois métodos que atuam sobre a pergunta: o **Query Step-Down** gera perguntas alternativas mais específicas, responde cada uma e combina as respostas; o **Reciprocal RAG** segue o mesmo primeiro passo, mas retém apenas a resposta mais confiável. Ambos dialogam com a reescrita de consultas [15] e com o RAG-Fusion [16], que ampliam a cobertura da recuperação ao custo de chamadas adicionais ao LLM e do risco de desvio em relação à intenção original da pergunta.

A escolha do método tem efeito direto sobre o número de chamadas ao LLM e, portanto, sobre tokens e latência. Há também um efeito sobre a qualidade: Liu et al. [17] mostram que LLMs aproveitam pior a informação posicionada no meio de contextos longos, o que penaliza estratégias que apenas acumulam fragmentos, e Nair et al. [18] mostram que representações condensadas de documentos longos preservam quase todo o desempenho com uma fração dos tokens.

C. BANCOS VETORIAIS E BUSCA APROXIMADA

Bancos vetoriais como o ChromaDB oferecem persistência em disco, armazenamento dos textos e filtros por metadados, e, por padrão, indexam os vetores com o HNSW [19], um grafo de proximidade em camadas que encontra vizinhos próximos em tempo sublinear, mas de forma aproximada: os k fragmentos devolvidos podem não ser os k mais próximos. Bibliotecas como o FAISS [20] oferecem tanto índices aproximados quanto a busca exata por força bruta (`IndexFlatL2`), cujo custo cresce linearmente com o nú-

mero de vetores. A diferença entre os dois bancos, portanto, não é apenas de infraestrutura: com o índice aproximado, a escolha do banco pode mudar os fragmentos entregues ao LLM, efeito que tende a crescer com o tamanho da base.

D. AVALIAÇÃO DE SISTEMAS RAG

A similaridade de cosseno entre os embeddings da resposta gerada e da resposta de referência é uma métrica barata e reprodutível, mas mede proximidade semântica global: penaliza respostas corretas redigidas de forma mais longa que a referência, favorece respostas no mesmo vocabulário mesmo quando o conteúdo está errado e não verifica se a resposta está ancorada nos documentos recuperados. Em conjuntos de compreensão de leitura, a métrica usual é a sobreposição de tokens com a resposta de referência (F1 e exact match) [21], e, em questões de múltipla escolha, a acurácia.

O framework RAGAS [10] propõe métricas específicas para RAG calculadas com um LLM como juiz: Faithfulness (fração das afirmações da resposta sustentadas pelo contexto recuperado), Answer Relevancy (quanto a resposta endereça a pergunta), Context Precision e Context Recall (qualidade e suficiência do contexto recuperado em relação à referência). O uso de LLMs como juízes, porém, tem vieses documentados, entre eles o de autopreferência: juízes tendem a avaliar melhor textos gerados por eles mesmos [22], [23]. O RAGBench [11] oferece respostas anotadas quanto à sustentação pelo contexto em sete subconjuntos de domínios variados, o que permite medir a concordância de um juiz automático com um gabarito.

E. O PAPEL DO LLM E DO DOMÍNIO

O ganho do RAG não é uniforme. Mallen et al. [5] mostram que a recuperação ajuda sobretudo em conhecimento pouco popular, que o modelo não memorizou, e pode até prejudicar em fatos populares, que o modelo já responde de memória. No domínio médico, o MIRAGE [6] avaliou o RAG com vários LLMs e corpora, entre eles os livros-texto que acompanham o MedQA, sempre contra o mesmo modelo sem recuperação, e encontrou ganhos que variam com o modelo e com o corpus. A variação do LLM também importa por razões de custo e de reprodutibilidade: o FrugalGPT [24] mostra que combinações de modelos mais baratos podem alcançar o desempenho de modelos caros a uma fração do custo; Chen, Zaharia e Zou [25] documentam mudanças de comportamento de um mesmo modelo comercial ao longo de poucos meses; e Palmer, Smith e Spirling [26] defendem que pesquisas com modelos proprietários justifiquem a escolha e incluam modelos abertos, cujos pesos permitem reproduzir os resultados.

F. RAG EM PORTUGUÊS

A avaliação de RAG em português ainda é incipiente. Medeiros e Oliveira [7] compararam modelos de embedding e LLMs abertos e proprietários em três bases em português (Pirá, SQuAD 2 e FairytaleQA PT-BR), com ROUGE-L, BERTScore e as métricas RAGAS de fidelidade e relevância da resposta. Os melhores resultados foram obtidos pelo Multilingual E5 large e pelo Gemma 2 9B. Aquele estudo varia o embedding e o LLM com um método de injeção fixo; o presente trabalho faz o recorte complementar, fixando o embedding e variando o método de injeção e o LLM.

TABELA 1. Conjuntos de dados. Frag.: fragmentos de 1.000 caracteres no índice. Perguntas: total no conjunto e, entre parênteses, a amostra da camada principal. No Docugami, a amostra foi sorteada entre as 133 perguntas com valor numérico na resposta de referência. O gabarito é uma resposta escrita com os valores pedidos (Docugami), a alternativa correta oficial (MedQA) ou um trecho do parágrafo (FaQuAD).

Conjunto	Domínio	Corpus	Frag.	Perguntas
Docugami	financeiro (EN)	20 relatórios 10-Q	4.463	195 (100)
MedQA	médico (EN)	18 livros-texto	121.553	1.273 (100)
FaQuAD	educacional (PT)	249 parágrafos	318	900 (100)

G. LACUNA

A literatura avançou na acurácia [15], [16], na confiabilidade [2], [13] e no entendimento das limitações de contexto [17], [18] de sistemas RAG. A comparação sistemática entre métodos de injeção de contexto, porém, foi feita com documentos em inglês, uma única métrica de similaridade e sem um controle sem recuperação [4], enquanto os estudos que variam o LLM e incluem esse controle fixam o método de injeção [6], [7]. Não há, até onde foi possível verificar, uma comparação dos métodos de injeção que cruze domínios, idiomas e LLMs com um controle sem RAG e métricas verificadas contra o gabarito. Este trabalho se insere nessa lacuna.

III. METODOLOGIA

O estudo é quantitativo e experimental. O desenho segue o de Şakar e Emekci [4], com os mesmos seis métodos de RAG, o mesmo tamanho de fragmento e dois dos seus três conjuntos de dados, e acrescenta um controle sem recuperação, sete LLMs, um conjunto de dados em português e métricas comparadas diretamente com o gabarito. O modelo de embedding, o tamanho dos fragmentos e o número de fragmentos recuperados foram mantidos fixos em todos os experimentos, para isolar o efeito do método e do LLM.

A. CONJUNTOS DE DADOS

A Tabela 1 resume os três conjuntos. O critério comum foi que as perguntas e as respostas de referência viessem de um conjunto público, construído e revisado por terceiros, e que o corpus de recuperação fosse o próprio material de onde as respostas saem.

Docugami SEC 10-Q. O conjunto, distribuído pelo LlamaIndex [27] e usado pelo estudo de referência, reúne 195 perguntas sobre os relatórios trimestrais (formulário 10-Q da SEC) de Apple, Amazon, Intel, Microsoft e NVIDIA, do terceiro trimestre de 2022 ao terceiro de 2023. As perguntas foram escritas por pessoas, e as respostas de referência foram geradas pelo GPT-4 e revisadas por pessoas. A maior

parte pede valores das demonstrações financeiras, muitas comparando empresas ou trimestres, e cada resposta de referência cita o relatório de onde sai, o que permite medir a recuperação. Os PDFs foram convertidos em texto com o `pdftotext` preservando o leiaute, para que cada linha das tabelas financeiras mantivesse o rótulo junto dos valores.

MedQA. São questões reais do USMLE, o exame de licenciamento médico dos Estados Unidos, da divisão de teste do MedQA [8], na versão de quatro alternativas, com a alternativa correta oficial. O corpus de recuperação são os 18 livros-texto de medicina que acompanham o conjunto, na versão distribuída pelo MedRAG [6], remontados livro a livro e refragmentados com o mesmo tamanho dos demais conjuntos. A pergunta enviada ao sistema é o caso clínico seguido das alternativas. O gabarito não indica de onde, nos livros, sai a resposta.

FaQuAD. O FaQuAD [9] é um conjunto de compreensão de leitura no formato do SQuAD [21], com 900 perguntas escritas por pessoas sobre 249 parágrafos originais em português, extraídos de 18 documentos oficiais de uma universidade federal e de 21 artigos da Wikipédia sobre o ensino superior brasileiro. Cada resposta de referência é um trecho do parágrafo, e algumas perguntas têm mais de uma resposta aceita. Os parágrafos formam a base de recuperação, e o parágrafo de cada pergunta é o trecho certo para medir a recuperação.

O terceiro conjunto do estudo de referência, sobre o artigo do Llama 2, foi descartado porque tanto as perguntas quanto as respostas de referência foram geradas pelo GPT-4. O FaQuAD foi preferido a outros conjuntos em português, como o Pirá, por ter documentos originalmente escritos em português, e não traduzidos.

Amostragem. O desenho tem duas camadas. Na camada principal, cinco LLMs de faixa de preço econômica respondem a 100 perguntas de cada conjunto, sorteadas com semente fixa. Na camada de generalização, os dois LLMs intermediários respondem às 25 primeiras perguntas da mesma permutação, um subconjunto das 100, de modo que os sete modelos compartilham essas 75 perguntas e a comparação entre eles é pareada. A camada principal sustenta as conclusões sobre os métodos; a de generalização verifica se elas se mantêm em modelos mais capazes. No Docugami, o sorteio considerou apenas as 133 das 195 perguntas cuja resposta de referência tem algum valor numérico, já que a métrica principal desse conjunto verifica esses valores (Seção III-D); as perguntas qualitativas, como as que pedem os processos judiciais divulgados por uma empresa, ficaram fora da amostra.

B. PIPELINE DE RAG

Os documentos foram divididos com o `RecursiveCharacterTextSplitter` em fragmentos de 1.000 caracteres com sobreposição de 100, os mesmos valores do estudo de referência, e codificados com o BGE-M3 [28], modelo de embedding multilíngue que atende aos dois idiomas, usando apenas os vetores densos. Os vetores foram indexados no ChromaDB com distância euclidiana e o índice padrão do banco, o HNSW [19], de busca aproximada. Em todos os métodos, a recuperação devolve os $k = 4$ fragmentos mais próximos da pergunta. A Figura 1 resume as duas etapas do pipeline: a indexação, feita uma vez por conjunto, e a consulta, feita a cada pergunta.

Os seis métodos foram implementados diretamente sobre as APIs, sem frameworks de orquestração, para que cada chamada ao LLM fosse contabilizada:

- **Stuff** (1 chamada): os k fragmentos são concatenados em um único prompt com a pergunta.
- **Refine** (k chamadas): gera uma resposta com o primeiro fragmento e a refina com cada fragmento seguinte, alterando-a apenas se o novo fragmento trouxer informação relevante.
- **Map-Reduce** ($k + 1$ chamadas): gera uma resposta parcial por fragmento e combina as parciais em uma resposta final.
- **Map-Rerank** (k chamadas): gera, para cada fragmento isoladamente, uma resposta e uma nota de confiança de 0 a 100, e mantém a resposta de maior confiança.
- **Query Step-Down** (6 chamadas): a partir da pergunta e de um contexto inicial, gera quatro perguntas alternativas mais específicas, responde cada uma com o Stuff, com recuperação própria, e combina as quatro respostas em uma chamada final, que recebe a pergunta original e as respostas.
- **Reciprocal RAG** (5 chamadas): gera as mesmas quatro perguntas alternativas, responde cada uma com nota de confiança e mantém a resposta mais confiável, sem etapa de combinação.

O **controle sem RAG** (1 chamada) envia ao LLM apenas a pergunta, sem nenhum fragmento, com a mesma instrução do conjunto. A Figura 2 mostra o fluxo de cada método e as suas chamadas ao LLM.

Prompts. Os prompts foram escritos em português e traduzidos literalmente para o inglês, idioma usado no Docugami e no MedQA: em um piloto com os prompts em português, parte dos modelos respondia em português às perguntas em inglês, o que penalizaria as métricas sem relação com o método. No Docugami e no FaQuAD, o modelo é instruído a responder usando apenas o contexto e a dizer que não sabe quando a resposta não estiver nele; no controle sem RAG, a dizer que não sabe quando não souber. No MedQA, como os livros-texto raramente trazem a resposta exata de um caso clínico, a instrução de recusa faria a acurácia medir recusas, e não conhecimento. Por isso, como no MIRAGE [6], o modelo usa os trechos como apoio, recorre ao próprio conhecimento quando eles não bastam e sempre escolhe uma alternativa, começando a resposta pela letra, seguida de uma justificativa curta.

C. MODELOS DE LINGUAGEM

A Tabela 2 lista os sete LLMs. As faixas são de preço, e não de tamanho: o DeepSeek V4 Pro, um dos maiores modelos

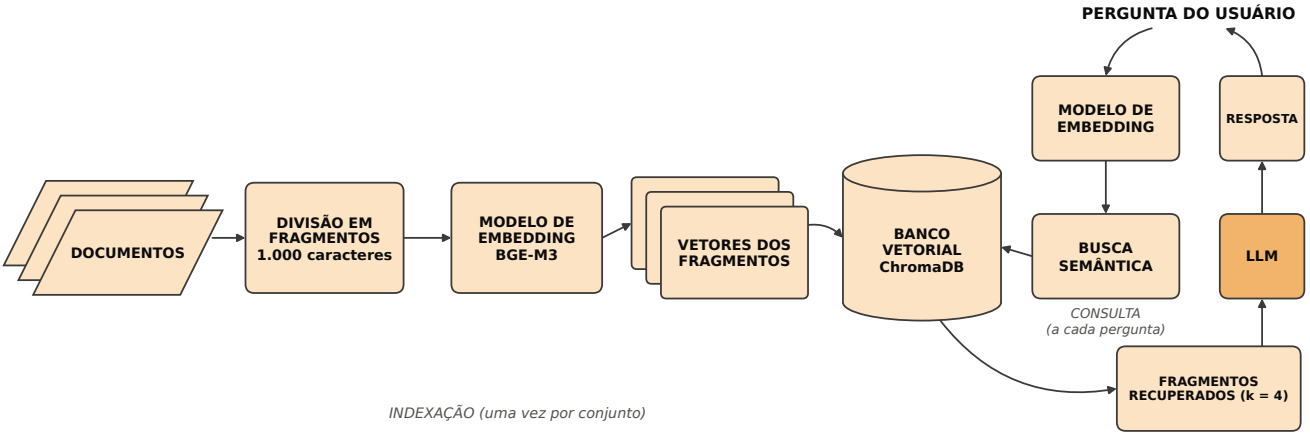


FIGURA 1. Pipeline de RAG usado nos experimentos. Na indexação, os documentos de cada conjunto são divididos em fragmentos, convertidos em vetores pelo BGE-M3 e guardados no ChromaDB; na consulta, a pergunta é convertida pelo mesmo modelo, a busca semântica devolve os quatro fragmentos mais próximos, e o método de injeção os entrega ao LLM (Figura 2). No controle sem RAG, a pergunta vai direto ao LLM. Adaptado de Şakar e Emekci [4] (licença CC BY 4.0).

TABELA 2. LLMs avaliados. Preço em US$ por milhão de tokens (entrada/saída), consultado em outubro e novembro de 2026. Temp. 0: o modelo aceita temperatura 0; os demais rodaram com a temperatura padrão da API e tiveram o Stuff executado três vezes nas 25 perguntas da camada de generalização. n. d.: não divulgado.

Modelo	Empresa	Pesos	Parâm.	US$/1M	Temp. 0
Camada principal (econômicos): 100 perguntas por dataset					
Qwen3.5-9B	Alibaba	abertos	9,7 bi	0,17/0,25	sim
DeepSeek V4 Pro	DeepSeek	abertos	1,6 tri	0,90/1,80	sim
Claude Haiku 5.5	Anthropic	fechados	n. d.	0,10/0,50	não
GPT-6 Luna	OpenAI	fechados	n. d.	0,10/0,50	não
gpt-4o-mini	OpenAI	fechados	n. d.	0,15/0,60	sim
Camada de generalização (intermediários): 25 perguntas por dataset					
Claude Sonnet 5	Anthropic	fechados	n. d.	2,00/10,00	não
GPT-6 Sol	OpenAI	fechados	n. d.	2,00/10,00	não

de pesos abertos, custa como um modelo econômico. A escolha buscou a diversidade necessária para generalizar os resultados, com uma justificativa para cada modelo:

- **gpt-4o-mini**: um dos três LLMs do estudo de referência, o que liga os resultados aos dele.
- **GPT-6 Luna** e **Claude Haiku 5.5**: os modelos econômicos atuais das duas principais empresas de modelos fechados.
- **Qwen3.5-9B**: modelo pequeno, de pesos abertos (Apache-2.0), que pode ser executado localmente; garante que parte dos resultados seja reprodutível independentemente de uma API comercial [25], [26].
- **DeepSeek V4 Pro**: modelo de pesos abertos (MIT) com 1,6 trilhão de parâmetros em arquitetura de mistura de especialistas, a preço de modelo econômico.
- **Claude Sonnet 5** e **GPT-6 Sol**: os intermediários das mesmas duas famílias fechadas, o que permite medir o efeito do porte dentro de cada família, e testar se um modelo econômico com o método adequado alcança o intermediário [24].

Para a camada de generalização, os intermediários foram preferidos aos modelos de topo das mesmas famílias (Claude Opus 4.8 e GPT-6 Astra), que custam de 2,5 a 5 vezes mais por token e, no caso do Astra, não permitem desligar o raciocínio. Pelo mesmo motivo, foram usados o Sonnet 5 e o GPT-6 Sol, e não as versões mais novas (Sonnet 5.5 e GPT-6.1 Sol), que também não permitem desligá-lo.

Em todos os modelos, o raciocínio estendido foi desligado, para comparar os métodos de RAG, e não o quanto cada modelo "pensa" antes de responder. A temperatura foi fixada em 0 nos modelos que aceitam o parâmetro; os modelos Claude e GPT-6 rejeitam a temperatura 0 e rodaram com a temperatura padrão. Como as respostas desses quatro modelos variam entre execuções, o Stuff foi executado três vezes com eles nas 25 perguntas de cada conjunto, para medir quanto da diferença entre métodos é só variação do próprio modelo. Os modelos da OpenAI foram acessados pela API da empresa, e os demais pelo OpenRouter [29], com o provedor de cada chamada registrado; o Qwen rodou em precisão bf16 e o DeepSeek em fp8, a precisão em que é distribuído. No total, foram 12.150 execuções: 10.500 na camada principal (5 LLMs $\times$ 3 conjuntos $\times$ 7 condições $\times$ 100 perguntas), 1.050 na de generalização e 600 repetições do Stuff.

D. MÉTRICAS

Métrica principal. Cada conjunto tem uma métrica comparada diretamente com o gabarito, sem juiz automático:

- **MedQA: acurácia.** A alternativa escolhida é identificada em qualquer ponto da resposta — no início, como o prompt pede, ou, se não estiver lá, na conclusão explícita ("the correct answer is C") ou na linha que destaca uma alternativa — e comparada com a alternativa correta oficial. Das 4.050 respostas, 32 não traziam a letra no início; a alternativa identificada nelas foi

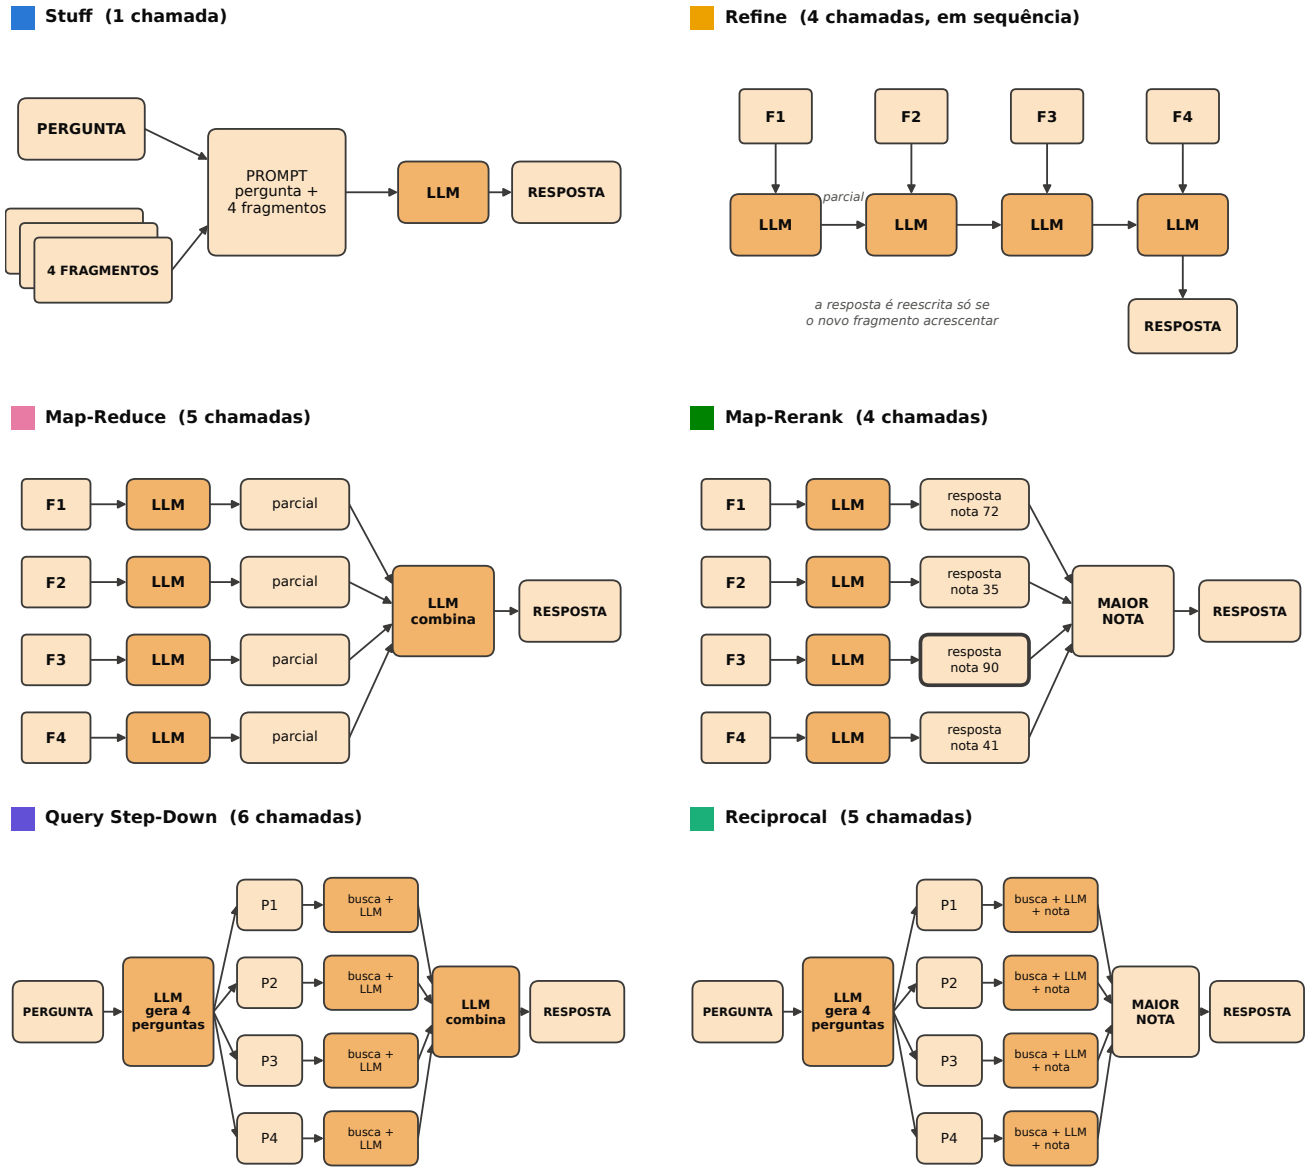


FIGURA 2. Os seis métodos de injeção de contexto, com os $k = 4$ fragmentos recuperados (F1 a F4) ou as quatro perguntas alternativas (P1 a P4). As caixas em laranja são chamadas ao LLM, e em todas elas o prompt traz também a pergunta original. Nos dois últimos métodos, cada pergunta alternativa faz a sua própria busca e é respondida como no Stuff. A cor ao lado de cada nome é a mesma da Figura 7. Adaptado de Şakar e Emekci [4] (licença CC BY 4.0).

conferida uma a uma, e só uma não indicava nenhuma.

- **FaQuAD: cobertura de tokens.** Fração dos tokens da resposta de referência que aparecem na resposta gerada, após a normalização do SQuAD (minúsculas, sem pontuação), vale a melhor entre as respostas aceitas. A cobertura corresponde à revocação das métricas oficiais do SQuAD [21], que também foram calculadas: o exact match, que vale 1 quando a resposta normalizada é idêntica a uma resposta aceita e 0 nos demais casos, e o F1, média harmônica entre a precisão (fração dos tokens da resposta gerada presentes na referência) e a revocação (fração dos tokens da referência presentes na resposta gerada). As duas, porém, penalizam respostas em frase completa diante de referências de poucas palavras: o exact match do Stuff não passou de 0,12 em nenhum modelo, embora as respostas contivessem o trecho certo na maior parte dos casos. Os artigos não foram removidos na normalização, porque em português "a" e "o" também são preposição e pronome.
- **Docugami: valores do gabarito.** Fração dos valores numéricos distintos da resposta de referência — montantes em dólares, percentuais e valores em milhões ou bilhões — que aparecem na resposta gerada, aceitando arredondamento e troca de escala (US$ 7.442 milhões

equivalem a US$ 7,44 bilhões), com tolerância de até 2%. Datas, anos e numeração de itens não contam como valor.

A métrica do Docugami foi definida depois de se observar que a similaridade de cosseno dava notas altas a respostas genéricas, sem nenhum número: uma recusa parcial como "I don't have verified figures", seguida de comentários gerais sobre a empresa, chegava a 0,86 de similaridade com uma referência cheia de valores. A **similaridade de cosseno**, métrica do estudo de referência, é o cosseno do ângulo entre o embedding da resposta gerada e o da resposta de referência: quanto mais próxima de 1, mais próximos estão os dois textos no espaço do embedding, o que reflete semelhança de tema e de vocabulário, e não a coincidência dos valores e fatos. Calculada com o BGE-M3, ela foi mantida em todas as execuções para comparação, e recalculada com o bge-small-en-v1.5, o embedding usado por aquele estudo, nos dois conjuntos em inglês.

Recusas. Uma resposta foi classificada como recusa quando o modelo declarou não ter a informação, total ou parcialmente ("I don't know", "Não sei", "the context does not provide…", "I don't have verified figures"), por expressões regulares tiradas das próprias respostas. A taxa de recusa é a fração das respostas classificadas como recusa.

Informação no contexto. Para separar as falhas da recuperação das falhas do modelo, cada resposta dos métodos de RAG no Docugami e no FaQuAD foi classificada pelo contexto que o LLM de fato recebeu: os quatro fragmentos da pergunta original no Stuff, no Refine, no Map-Reduce e no Map-Rerank, e a união dos fragmentos das perguntas alternativas no Query Step-Down e no Reciprocal. O mesmo juiz do RAGAS (`gpt-4o-mini`, temperatura 0) recebeu a pergunta, a resposta de referência e esse contexto e indicou se o contexto continha toda a informação que responde à pergunta, apenas parte dela ou nenhuma. Cruzando esse veredito com a recusa, uma recusa foi considerada **justificada** quando o contexto não tinha a informação, ou só parte dela, e a falha é da recuperação, e **injustificada** quando o contexto tinha toda a informação e o modelo declarou não saber. Nos casos em que o contexto não tinha nada da informação, a **rejeição negativa**, termo do RGB [30], é a fração em que o modelo recusou, como o prompt pede; no restante, o modelo **respondeu sem a informação**, com dados do contexto que não respondem à pergunta, com o próprio conhecimento ou inventando, e a métrica principal mostra quanto dessas respostas acertou. No FaQuAD, cujas respostas aceitas são trechos do próprio parágrafo, o juiz foi conferido contra a busca literal da resposta no contexto, nas 3.300 respostas: a concordância foi de 97% (κ de Cohen de 0,73). Nas recusas, o juiz nunca indicou informação completa quando a resposta não estava no contexto (0 de 55 casos) e a reconheceu em 51 dos 65 casos em que estava; nas 14 divergências, ora a palavra da resposta aparecia no contexto em outra frase, sem responder à pergunta, ora o juiz não reconheceu a informação presente. O número de recusas injustificadas é, portanto, um limite inferior. O controle sem RAG, que não recebe contexto, ficou de fora, e também o MedQA: o prompt manda sempre escolher uma alternativa, não houve recusas de fato (nas 15 respostas marcadas pelo detector, a expressão de recusa aparecia na justificativa de uma resposta), e o gabarito não indica onde, nos livros, está a resposta.

Custo. Para cada resposta, foram registrados os tokens — as unidades em que o tokenizador de cada modelo divide o texto, e pelas quais as APIs cobram — de entrada (o prompt, com a instrução, a pergunta e os fragmentos) e de saída (o texto gerado), informados pela API, o custo em dólares, calculado com os preços de tabela da Tabela 2, e o tempo total, da recuperação até o fim da geração. Nos métodos com várias chamadas, os tokens, o custo e o tempo de uma resposta somam todas as chamadas. O custo é nominal: não considera descontos de cache de prompt, que dependem do provedor e da ordem das chamadas. O uso de CPU e memória da máquina local não foi analisado, porque, com os LLMs acessados por API, essas medidas não refletem o custo de inferência dos métodos.

Recuperação. A qualidade da busca foi medida sem chamadas ao LLM, contra o trecho certo marcado no gabarito: o relatório citado na resposta de referência, no Docugami, e o parágrafo de origem da pergunta, no FaQuAD. Um fragmento recuperado conta como relevante quando pertence a esse relatório ou parágrafo. O Hit@4 é a fração das perguntas em que ao menos um fragmento relevante aparece entre os quatro primeiros recuperados, o mesmo k usado pelos métodos. O Recall@4 é a fração dos documentos certos de cada pergunta que aparecem entre esses quatro fragmentos, em média sobre as perguntas; ele difere do Hit@4 no Docugami, em que 60 perguntas citam de dois a quatro relatórios, e coincide com ele no FaQuAD, em que cada pergunta tem um único parágrafo de origem. O MRR@10 (mean reciprocal rank) é a média, sobre as perguntas, do inverso da posição do primeiro fragmento relevante entre os dez primeiros: vale 1 quando ele vem em primeiro lugar, $1/2$ quando vem em segundo e 0 quando não aparece, e indica em que posição o trecho certo costuma aparecer. As três métricas foram calculadas em todas as perguntas com o trecho marcado: 193 das 195 do Docugami, já que duas não citam o relatório de origem, e as 900 do FaQuAD. O MedQA não marca o trecho certo.

RAGAS. Foram calculadas quatro métricas do RAGAS [10] (biblioteca `ragas` 0.4.3), com o `gpt-4o-mini` como juiz e o `text-embedding-3-small` da OpenAI como embedding. A Faithfulness mede se a resposta está sustentada pelos fragmentos: o juiz divide a resposta gerada em afirmações e verifica, para cada uma, se ela pode ser inferida dos fragmentos entregues ao LLM; a nota, de 0 a 1, é a fração sustentada, e valores baixos indicam conteúdo que não vem do contexto, como alucinações. Ela foi calculada nos quatro métodos que entregam ao LLM um conjunto único de fragmentos (Stuff, Refine, Map-Reduce e Map-Rerank); no Query Step-Down e no Reciprocal, cada pergunta alternativa recupera os seus próprios fragmentos, e

não há um contexto único contra o qual verificar a resposta. A Answer Relevancy mede se a resposta trata da pergunta feita: o juiz gera, a partir da resposta, três perguntas que ela responderia, e a nota é a média da similaridade de cosseno entre o embedding de cada uma e o da pergunta original; respostas que o juiz classifica como evasivas, como as recusas, recebem zero. Ela não verifica se a resposta está correta e foi calculada em todos os métodos e no controle sem RAG. Context Precision e Context Recall avaliam os fragmentos recuperados com a pergunta original, que são os mesmos nesses quatro métodos e em todos os LLMs; por isso foram calculadas uma única vez por pergunta, em vez de repetidas a cada linha, o que só mediria a variação do juiz. A Context Precision mede se os fragmentos úteis vêm no topo da lista: o juiz decide, para cada um dos quatro fragmentos, se ele ajuda a chegar à resposta de referência, e a nota é a média da precisão nas posições dos fragmentos úteis, de modo que um fragmento útil em primeiro lugar pesa mais que um em quarto. A Context Recall mede se os fragmentos bastam para responder: o juiz divide a resposta de referência em afirmações e verifica quais delas podem ser sustentadas pelos fragmentos recuperados, e a nota é a fração sustentada. As duas vão de 0 a 1 e dependem da resposta de referência, e não da resposta gerada. No MedQA, a referência dessas métricas é o texto da alternativa correta, e elas são a única avaliação da recuperação.

Validação do juiz. A Faithfulness do juiz foi comparada com os rótulos de sustentação pelo contexto do RAGBench [11] em uma amostra estratificada de 206 respostas de sete subconjuntos, com cerca de metade de respostas sustentadas e metade com alucinação em cada um. A concordância foi medida pela área sob a curva ROC (AUROC) [31], a probabilidade de que, sorteadas uma resposta sustentada e uma com alucinação, a sustentada receba a maior nota: 0,5 equivale ao acaso, e 1, à separação perfeita. A AUROC foi de 0,701, contra 0,567 da Faithfulness calculada pelos próprios autores do RAGBench sobre as mesmas respostas, e variou de 0,54 a 0,90 entre os subconjuntos. O juiz é, portanto, moderadamente confiável, e as métricas RAGAS entram como complementares: as conclusões principais vêm das métricas comparadas com o gabarito. Como o `gpt-4o-mini` também é um dos modelos avaliados, as suas notas RAGAS não foram usadas para comparar LLMs, por risco de autopreferência [23].

E. BANCOS VETORIAIS

Como o índice HNSW do ChromaDB é aproximado, a comparação com o FAISS (`IndexFlatL2`, busca exata) mede tanto a infraestrutura quanto o efeito da aproximação sobre os resultados. Os dois bancos indexaram os mesmos vetores BGE-M3 dos três conjuntos, que formam três escalas de base (318, 4.463 e 121.553 vetores), em processos separados e sem nada mais em execução, e responderam às consultas das perguntas da amostra. Foram medidos o tempo de indexação, o tempo médio por consulta, a memória alocada na indexação (o aumento da memória residente do processo) e a concordância do top-4 entre os bancos, isto é, a fração das consultas em que os dois devolvem os mesmos quatro fragmentos; no Docugami e no FaQuAD, também o Hit@4 de cada banco. Por fim, nas perguntas em que o top-4 do FAISS diferiu do recebido nos experimentos, o Stuff do `gpt-4o-mini` foi executado de novo com os fragmentos do FAISS, para medir o efeito da troca de banco na métrica principal.

F. ANÁLISE ESTATÍSTICA

Em cada combinação de conjunto e LLM, as perguntas foram tratadas como blocos pareados, já que todos os métodos respondem às mesmas perguntas. A diferença entre os seis métodos foi testada com o teste de Friedman [32], que ordena os métodos dentro de cada pergunta e verifica se os postos médios diferem mais do que o acaso explicaria, e, em seguida, com testes de Wilcoxon pareados [33] par a par, que comparam duas condições pelos postos das diferenças entre elas em cada pergunta, sem supor distribuição normal. Os valores-p foram corrigidos pelo método de Holm [34], que os ajusta em sequência para manter em no máximo 5% a probabilidade de ao menos um falso positivo entre as comparações de uma mesma família (p_{Holm} nas tabelas), conforme a recomendação de Demšar [35]. O efeito do RAG foi testado da mesma forma, comparando cada método com o controle sem RAG, com a correção de Holm sobre as seis comparações. O posto médio de um método é a média da sua posição entre os seis (1 = melhor) nos LLMs, e a concordância dessa ordem entre os LLMs foi medida pelo coeficiente W de Kendall [36], de 0 (nenhuma concordância) a 1 (mesma ordem em todos), com correção para empates — métodos com o mesmo valor em um LLM dividem a posição, e esse empate não conta como discordância — e o teste pela aproximação qui-quadrado, que equivale ao teste de Friedman com os LLMs como blocos. Comparações pareadas de acurácia entre duas condições usaram o teste exato de McNemar [37], que considera só as perguntas em que uma condição acerta e a outra erra. A associação entre duas métricas foi medida pela correlação de Spearman [38] (ρ), a correlação entre os postos das duas, de -1 a 1, em que 0 indica ausência de relação monotônica. O valor-p é a probabilidade de observar uma diferença ao menos tão grande quanto a medida se as condições fossem equivalentes, e o nível de significância adotado foi 0,05. Na camada de generalização, com 25 perguntas por conjunto, só diferenças grandes podem ser detectadas.

G. AMBIENTE E REPRODUTIBILIDADE

Os experimentos foram executados entre outubro e novembro de 2026, em Python 3.12, em um notebook com processador Intel Core i5-12450H (12 threads), cerca de 20 GB de RAM e sem GPU dedicada. Os embeddings dos dois corpora maiores foram calculados em GPU no Google Colab e conferidos contra os fragmentos locais por um hash dos textos. As principais bibliotecas foram `chromadb` 1.5.9, `faiss` 1.14.3, `FlagEmbedding` 1.4.0, `openai` 2.41.1,

TABELA 3. Recuperação ($k = 4$). Hit@4, Recall@4 e MRR@10 contra a origem da resposta marcada no gabarito (o relatório, no Docugami; o parágrafo, no FaQuAD), em todas as perguntas que a marcam (193 das 195 no Docugami); o MedQA não a marca. Context Precision (CP) e Context Recall (CR) do RAGAS, uma vez por pergunta da amostra de 100.

Dataset	Hit@4	Recall@4	MRR@10	CP	CR
Docugami	0,82	0,75	0,63	0,56	0,41
MedQA	–	–	–	0,44	0,52
FaQuAD	0,91	0,91	0,81	0,87	0,94

`ragas` 0.4.3 e `scipy` 1.17.1. Cada execução foi registrada em um arquivo JSONL, com a pergunta, os fragmentos recuperados, a resposta, os tokens, os tempos, a versão do modelo informada pela API e o provedor. O custo nominal da geração foi de US$ 19,99. O código, os registros e os scripts que geram todas as tabelas e figuras deste artigo estão no repositório do trabalho.

IV. RESULTADOS E DISCUSSÃO

A. RECUPERAÇÃO

A Tabela 3 mostra a qualidade da recuperação, que é a mesma para todos os LLMs. No FaQuAD, o parágrafo certo estava entre os quatro fragmentos recuperados em 91% das perguntas, e o Context Recall do RAGAS indica que os fragmentos cobriam 94% das afirmações da resposta de referência. No Docugami, o relatório certo apareceu no top-4 em 82% das perguntas, mas os fragmentos cobriram menos da metade da resposta de referência (Context Recall de 0,41): encontrar o relatório não basta quando a resposta exige valores de tabelas diferentes, de trimestres ou empresas diferentes. No MedQA, os livros-texto cobriram cerca de metade da resposta de referência (0,52), o que é esperado para casos clínicos que exigem raciocínio sobre o conteúdo dos livros, e não a sua transcrição.

A Context Precision do juiz se correlacionou com o Hit@4 do gabarito nos dois conjuntos, mas de forma fraca: Spearman $\rho = 0{,}34$ no FaQuAD ($p < 0{,}001$) e $\rho = 0{,}22$ no Docugami ($p = 0{,}03$). Essas duas métricas do RAGAS servem, assim, como indicação geral da recuperação no MedQA, onde não há gabarito de recuperação, mas não como medida precisa.

B. EFEITO DO RAG

A Figura 3 e a primeira linha da Tabela 4 comparam o controle sem RAG com os métodos de RAG. O efeito da recuperação dependeu, sobretudo, do domínio (QP3). As Tabelas 5 e 6 trazem, nas mesmas perguntas, os tokens consumidos e o custo em dólares de cada combinação de método e LLM, discutidos na Seção IV-F.

FaQuAD. Sem recuperação, os cinco modelos econômicos cobriram de 35% a 50% dos tokens da resposta de referência e recusaram de 15% a 43% das perguntas; com o Stuff, a cobertura subiu para 85%–92%, e todos os seis métodos melhoraram todos os cinco modelos ($p_{\text{Holm}} < 0{,}05$). Os intermediários seguiram o padrão: o Stuff elevou a cobertura do Sonnet de 0,50 para 0,91 e a do Sol de 0,48 para 0,82, nas 25 perguntas. As perguntas tratam de normas e fatos de uma universidade específica, que o modelo não tem como saber de memória; é o cenário para o qual o RAG foi concebido.

MedQA. Sem recuperação, os modelos econômicos acertaram de 71% a 88% das questões, e os intermediários, 96%. O Stuff alterou a acurácia em no máximo quatro pontos percentuais, sem significância em nenhum dos sete modelos. Nenhum método alterou significativamente a acurácia de nenhum modelo após a correção de Holm; os maiores ganhos foram o do Qwen com o Query Step-Down (de 72% para 83%; $p_{\text{Holm}} = 0{,}10$) e o do Haiku com o Map-Rerank (de 84% para 92%; $p_{\text{Holm}} = 0{,}07$). No gpt-4o-mini, o Reciprocal reduziu a acurácia em 10 pontos, também sem significância após a correção. No Sol, todos os seis métodos mantiveram exatamente a acurácia do controle; no Sonnet, cinco dos seis. O resultado é coerente com Mallen et al. [5]: o conteúdo do USMLE é amplamente coberto pelos livros-texto e, provavelmente, pelos dados de treinamento dos modelos, e a recuperação acrescenta pouco ao que eles já sabem. Quanto mais forte o modelo sem recuperação, menor o espaço para o RAG.

Docugami. Sem recuperação, os cinco modelos econômicos trouxeram de 0% a 7% dos valores pedidos e recusaram de 26% (Luna) a 89% (Haiku) das perguntas. Com o RAG, o melhor método de cada modelo chegou a 13%–24% dos valores, um ganho significativo em quatro dos cinco modelos, todos menos o DeepSeek. O nível absoluto, porém, ficou baixo em todos os modelos: o Stuff recusou de 42% a 71% das perguntas, e mesmo a melhor combinação dos econômicos, Haiku com Query Step-Down, recuperou menos de 25% dos valores. O gargalo está na recuperação (Seção IV-A): com quatro fragmentos de 1.000 caracteres, raramente estão no contexto todos os valores de uma pergunta que compara empresas ou trimestres.

C. COMPARAÇÃO ENTRE OS MÉTODOS

O teste de Friedman indicou diferença entre os seis métodos em 12 das 15 combinações de conjunto e LLM da camada principal (Tabela 4); as exceções foram o Qwen, o DeepSeek e o Luna no MedQA. Nos intermediários, com 25 perguntas, o teste indicou diferença no Docugami nos dois modelos e no FaQuAD só no Sonnet; no MedQA, não houve diferença no Sonnet, e o Sol teve o mesmo resultado com todos os métodos. A ordem dos métodos, porém, mudou de um domínio para outro (QP1), e, no Docugami e no FaQuAD, se repetiu entre os LLMs (QP2; Tabela 7).

FaQuAD. O Stuff, o método mais simples e mais barato, teve a maior cobertura, ou empatou com a maior na segunda casa decimal, em quatro dos cinco modelos; no gpt-4o-mini, o Refine ficou à frente. O Reciprocal foi o pior método em quatro dos cinco modelos (no Haiku, o Map-Rerank ficou abaixo dele) e ficou significativamente abaixo do Stuff em todos os cinco após a correção de Holm, com perdas de 11 a 28 pontos; o Map-Rerank foi o penúltimo. Os dois

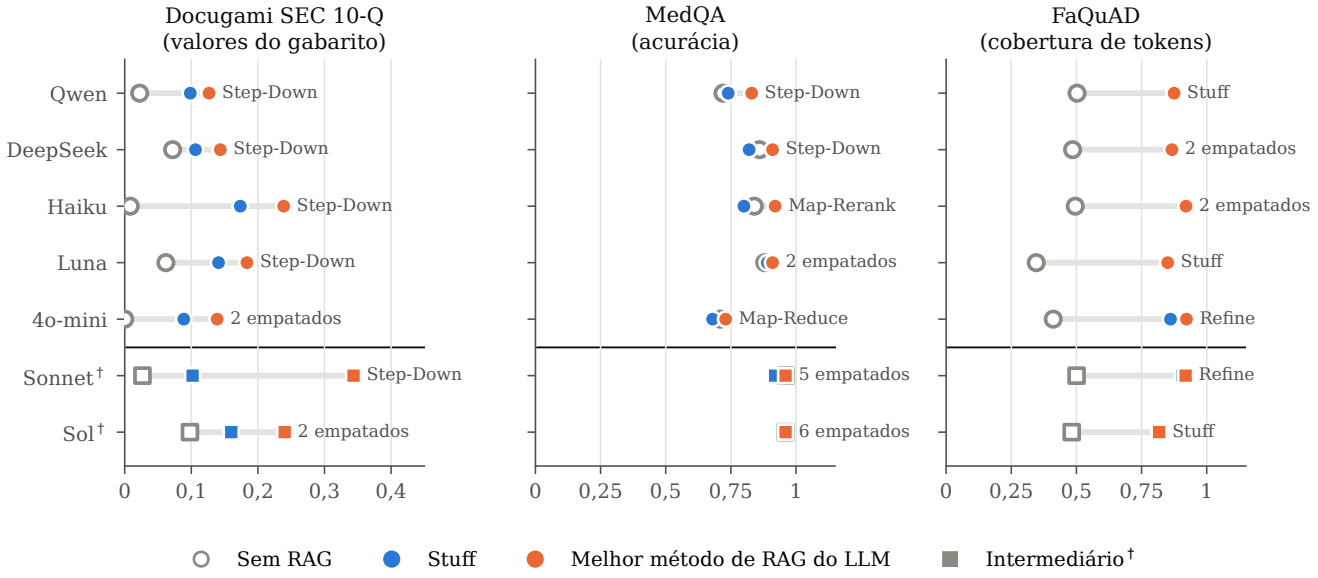


FIGURA 3. Métrica principal de cada conjunto: controle sem RAG, Stuff e o melhor método de RAG de cada LLM, indicado à direita (quando há empate no melhor valor na segunda casa decimal, o rótulo indica quantos métodos empataram). Econômicos (círculos): camada principal (100 perguntas). †Intermediários (quadrados, abaixo da linha): as 25 perguntas da camada de generalização.

TABELA 4. Métrica principal de cada dataset por método e LLM. Econômicos: camada principal (100 perguntas por dataset). † Intermediários: nas 25 perguntas da camada de generalização. Em negrito, o melhor valor de cada coluna (mais de um quando empatam na segunda casa decimal). * diferença em relação ao controle sem RAG com $p_{\text{Holm}} < 0{,}05$ (Wilcoxon pareado). Na última linha, o valor-p do teste de Friedman entre os seis métodos de RAG (–: o mesmo resultado com todos os métodos em todas as perguntas, sem teste possível).

	Docugami SEC 10-Q (valores do gabarito)							MedQA (acurácia)							FaQuAD (cobertura de tokens)						
Método	Qwen	Deep Seek	Haiku	Luna	4o-mini	Sonnet†	Sol†	Qwen	Deep Seek	Haiku	Luna	4o-mini	Sonnet†	Sol†	Qwen	Deep Seek	Haiku	Luna	4o-mini	Sonnet†	Sol†
Sem RAG	0,02	0,07	0,01	0,06	0,00	0,03	0,10	0,72	0,86	0,84	0,88	0,71	**0,96**	**0,96**	0,50	0,49	0,50	0,35	0,41	0,50	0,48
Stuff	0,10	0,11	0,17*	0,14	0,09*	0,10	0,16	0,74	0,82	0,80	0,89	0,68	0,92	**0,96**	**0,87***	**0,87***	**0,92***	**0,85***	0,86*	0,91*	**0,82***
Refine	0,08	0,07	0,15*	0,13	**0,14***	0,24*	**0,24**	0,79	0,88	0,82	0,89	0,68	**0,96**	**0,96**	0,84*	0,86*	0,89*	0,78*	**0,92***	**0,92***	0,73*
Map-Reduce	0,06	0,08	0,13*	0,16*	0,08*	0,17	0,12	0,80	0,84	0,90	0,88	**0,73**	**0,96**	**0,96**	0,85*	0,86*	0,84*	0,80*	0,85*	0,79*	0,72*
Map-Rerank	0,04	0,05	0,04	0,05	0,03	0,00	0,07	0,75	0,88	**0,92**	**0,91**	0,69	**0,96**	**0,96**	0,79*	0,80*	0,71*	0,77*	0,82*	0,56	0,68*
Step-Down	**0,13***	**0,14**	**0,24***	**0,18***	**0,14***	**0,34***	**0,24**	**0,83**	**0,91**	0,89	**0,91**	0,65	**0,96**	**0,96**	0,82*	**0,87***	**0,92***	0,79*	0,79*	0,90*	0,74*
Reciprocal	0,07	0,05	0,12*	0,14	0,09*	0,15	0,09	0,76	0,83	0,88	0,90	0,61	**0,96**	**0,96**	0,65*	0,75*	0,77*	0,70*	0,59*	0,56	0,75*
Friedman p	<0,001	<0,001	<0,001	<0,001	<0,001	<0,001	0,005	0,165	0,053	0,002	0,844	0,034	0,416	–	<0,001	<0,001	<0,001	<0,001	<0,001	<0,001	0,122

TABELA 5. Tokens consumidos por pergunta, por método e LLM, nas mesmas perguntas da Tabela 4 (econômicos: 100 perguntas por dataset). † Intermediários: nas 25 perguntas da camada de generalização. Cada valor é a média, por pergunta, da soma dos tokens de entrada e de saída de todas as chamadas ao LLM feitas pelo método. Os tokens são contados pelo tokenizador de cada modelo, de modo que a comparação entre LLMs reflete também a diferença entre tokenizadores.

	Docugami SEC 10-Q							MedQA							FaQuAD						
Método	Qwen	Deep Seek	Haiku	Luna	4o-mini	Sonnet†	Sol†	Qwen	Deep Seek	Haiku	Luna	4o-mini	Sonnet†	Sol†	Qwen	Deep Seek	Haiku	Luna	4o-mini	Sonnet†	Sol†
Sem RAG	309	197	377	126	101	542	106	1.040	358	614	295	351	596	296	251	192	334	81	122	359	80
Stuff	1.595	960	1.591	1.006	990	1.630	1.037	1.589	1.137	1.892	1.084	1.134	1.800	1.055	719	792	1.299	673	673	1.255	658
Refine	2.434	1.492	3.444	1.699	1.783	5.114	1.628	5.245	2.476	4.343	2.236	2.620	4.457	2.183	1.748	1.408	3.137	1.266	1.753	3.392	1.098
Map-Reduce	1.585	1.317	2.352	1.467	1.369	2.784	1.530	4.420	2.702	4.239	2.352	2.621	4.187	2.324	1.150	1.200	2.048	1.045	1.077	2.008	1.047
Map-Rerank	1.647	1.380	2.315	1.455	1.391	2.171	1.492	2.873	2.014	3.805	2.112	2.123	3.425	2.074	1.198	1.285	2.134	1.110	1.102	1.997	1.100
Step-Down	6.548	5.294	9.332	5.451	5.304	9.486	5.304	8.806	5.764	10.063	5.395	5.761	9.357	5.346	4.182	4.622	8.164	3.816	3.888	8.078	3.774
Reciprocal	6.102	5.024	7.867	5.206	5.096	7.698	4.983	6.018	4.862	8.741	5.077	4.983	8.246	4.951	3.939	4.461	7.128	3.717	3.729	7.059	3.682

métodos que selecionam uma única resposta por nota de confiança — de um fragmento isolado, no Map-Rerank, ou de uma pergunta reformulada, no Reciprocal — descartam o que as demais respostas trazem, e, no Reciprocal, a resposta escolhida responde a uma reformulação da pergunta, e não à pergunta original. Quando a resposta está inteira em um

TABELA 6. Custo em US$ por 1.000 perguntas, por método e LLM, nas mesmas perguntas da Tabela 4 (econômicos: 100 perguntas por dataset). † Intermediários: nas 25 perguntas da camada de generalização. Cada valor soma todas as chamadas ao LLM feitas pelo método: tokens de entrada e de saída vezes o preço de tabela de cada um (Tabela 2). Custo nominal, sem descontos de cache de prompt.

	Docugami SEC 10-Q							MedQA							FaQuAD						
Método	Qwen	DeepSeek	Haiku	Luna	4o-mini	Sonnet†	Sol†	Qwen	DeepSeek	Haiku	Luna	4o-mini	Sonnet†	Sol†	Qwen	DeepSeek	Haiku	Luna	4o-mini	Sonnet†	Sol†
Sem RAG	0,07	0,31	0,16	0,04	0,04	4,77	0,63	0,24	0,43	0,15	0,05	0,10	2,77	0,92	0,06	0,30	0,14	0,02	0,05	3,00	0,43
Stuff	0,31	0,91	0,25	0,12	0,17	5,23	2,47	0,31	1,14	0,27	0,13	0,21	4,81	2,42	0,13	0,74	0,17	0,08	0,11	3,14	1,51
Refine	0,46	1,52	0,75	0,29	0,43	26,90	5,16	1,03	2,54	0,74	0,30	0,58	15,82	5,70	0,34	1,47	0,69	0,23	0,52	15,99	3,38
Map-Reduce	0,28	1,26	0,40	0,21	0,25	11,32	4,38	0,85	2,76	0,64	0,29	0,52	12,48	5,65	0,20	1,16	0,31	0,14	0,21	5,93	2,86
Map-Rerank	0,29	1,39	0,42	0,23	0,27	6,77	4,57	0,55	1,93	0,67	0,28	0,40	9,62	5,34	0,22	1,30	0,36	0,16	0,22	6,02	3,27
Step-Down	1,16	5,17	1,55	0,71	0,96	32,96	13,39	1,66	5,77	1,51	0,69	1,12	26,48	13,43	0,75	4,55	1,31	0,50	0,74	26,13	9,84
Reciprocal	1,07	4,82	1,12	0,65	0,88	20,08	12,05	1,10	4,64	1,24	0,64	0,89	21,03	12,38	0,70	4,32	1,01	0,48	0,67	19,41	9,42

TABELA 7. Posto médio de cada método entre os cinco LLMs da camada principal (1 = melhor) e concordância da ordem dos seis métodos entre os LLMs (W de Kendall, com correção de empates: 1 = mesma ordem em todos; 0 = nenhuma concordância; entre parênteses, o valor-p).

Método	Docugami	MedQA	FaQuAD
Stuff	2,8	5,2	1,4
Refine	3,2	3,7	3,0
Map-Reduce	3,8	3,0	2,8
Map-Rerank	6,0	2,4	5,0
Step-Down	1,2	2,3	3,0
Reciprocal	4,0	4,4	5,8
W, 5 LLMs (100 perg.)	0,71 (0,003)	0,39 (0,084)	0,74 (0,002)
W, 7 LLMs (25 perg.)	0,64 (<0,001)	0,34 (0,034)	0,61 (<0,001)

parágrafo que a busca já encontra, como no FaQuAD, esse desvio de intenção custa qualidade e não traz ganho de recuperação.

Docugami. O Query Step-Down teve a maior proporção de valores em quatro dos cinco modelos e, no gpt-4o-mini, empatou com o Refine na segunda casa decimal (posto médio 1,2); também reduziu as recusas, de 42%–71% com o Stuff para 4%–31%. A sua vantagem sobre o Stuff, de 2,8 a 6,5 pontos, não sobreviveu à correção de Holm em nenhum modelo, e deve ser lida como uma tendência consistente, e não como um resultado individualmente significativo. O mecanismo é plausível: o Query Step-Down faz quatro recuperações adicionais, cada uma com uma pergunta mais específica, e amplia o conjunto de fragmentos que chega ao LLM justamente no domínio em que a recuperação é o gargalo [15]. O resultado mais firme é negativo: o Map-Rerank foi o pior método nos cinco modelos (posto médio 6,0; no DeepSeek, empatado com o Reciprocal na segunda casa decimal), significativamente abaixo do Query Step-Down em todos eles. Ao responder com um fragmento por vez, ele não consegue combinar valores espalhados por fragmentos diferentes.

MedQA. Não houve ordem consistente entre os modelos ($W = 0{,}39$; $p = 0{,}08$). Na média dos postos, o Query Step-Down e o Map-Rerank ficaram à frente e o Stuff em último, mas as diferenças entre métodos foram, em geral, de poucos pontos percentuais, e só no Haiku algum par sobreviveu à correção de Holm (Map-Rerank e Query Step-Down acima do Stuff).

D. RECUSAS E RESPOSTAS SEM A INFORMAÇÃO

A Figura 4 mostra quantas vezes cada LLM, com cada método, declarou não ter a informação, e separa essas recusas pelo que o contexto entregue ao modelo continha (Seção III-D).

Docugami. Das 1.302 recusas dos sete modelos, 935 (72%) ocorreram sem a informação no contexto e 204 (16%) com apenas parte dela; só 163 (13%) foram injustificadas. A maior parte das recusas é, portanto, falha da recuperação, e não do modelo, que seguiu a instrução de não responder além do contexto. Isso confirma que a recuperação é o gargalo nesse domínio (Seção IV-A) e explica a vantagem do Query Step-Down: ele teve o menor total de recusas (90, contra 323 do Stuff), e a redução veio sobretudo das justificadas (58 sem a informação, contra 250 do Stuff), porque as perguntas alternativas trouxeram ao contexto fragmentos que a busca com a pergunta original não encontrava. Os métodos com mais recusas injustificadas foram o Map-Rerank (48) e o Reciprocal (35), que escolhem uma única resposta por nota de confiança.

FaQuAD. Com a busca encontrando o parágrafo certo em 91% das perguntas, o quadro se inverte: as recusas foram poucas (120 nos sete modelos e seis métodos), mas 51 delas (43%) foram injustificadas. O Map-Rerank concentrou 22 dessas 51, mais do que as suas próprias recusas justificadas (14). Uma explicação provável está no mecanismo: ao responder com um fragmento por vez, ele produz uma recusa para cada fragmento que não contém a resposta, e basta que uma delas receba a maior nota de confiança para que o método recuse, mesmo com a resposta em outro fragmento. No Reciprocal, que usa a mesma seleção, 8 das 11 recusas foram injustificadas; no Stuff, que entrega todos os fragmentos de uma vez, 6 de 28. Entre os modelos, o gpt-4o-mini (13), o Haiku (10), o Qwen (10) e o DeepSeek (11) tiveram mais recusas injustificadas que o Luna (1) e o Sol (nenhuma).

A recusa é só uma das condutas possíveis quando a informação não chega. A Figura 5 mostra, para cada método e LLM, quantas vezes o contexto não tinha nada da informação e o que o modelo fez nesses casos, e a Tabela 8

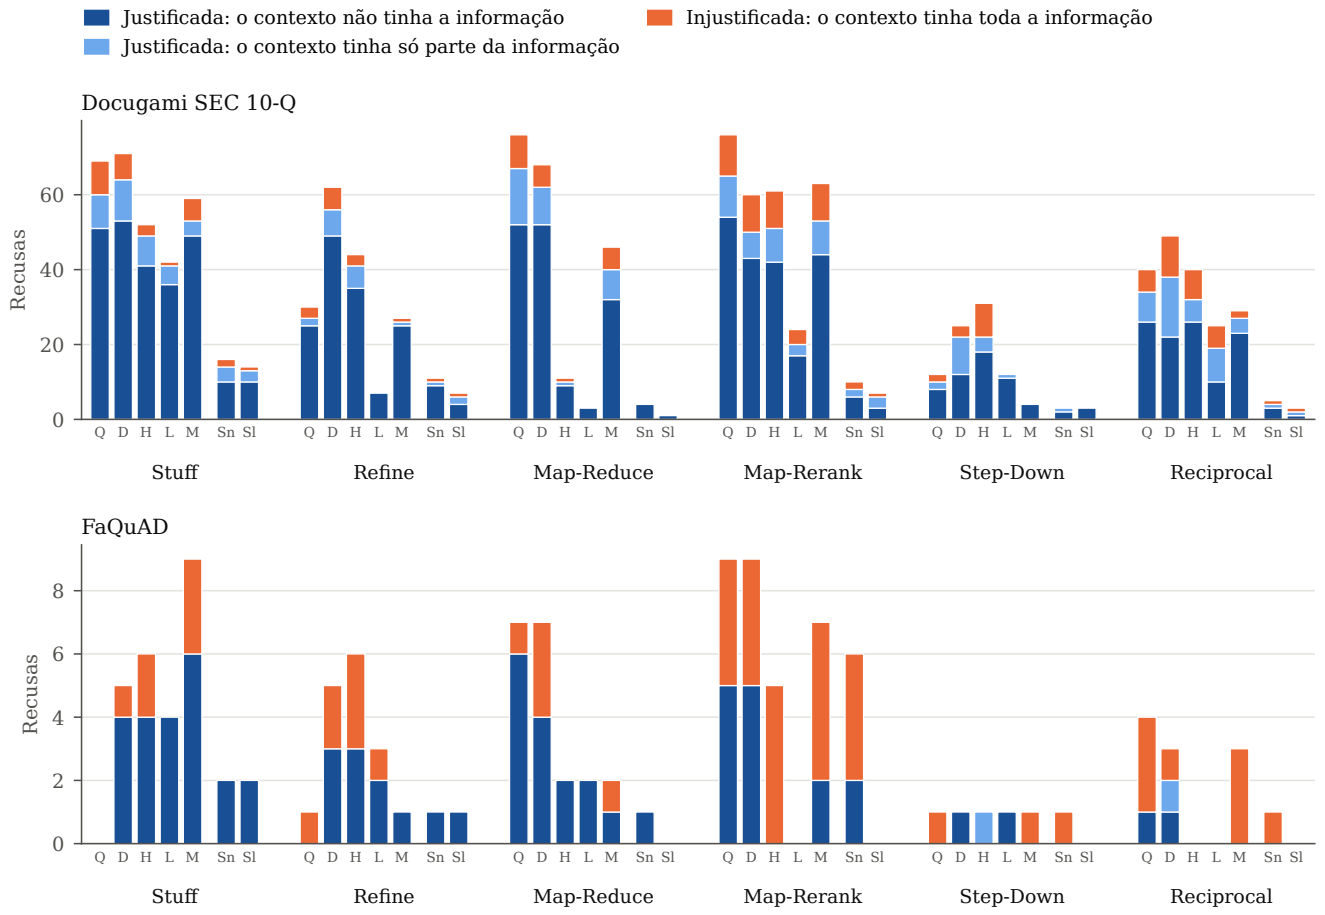


FIGURA 4. Recusas por método e LLM (repetição 1), separadas pelo conteúdo do contexto que o LLM recebeu, segundo o juiz: em azul, as justificadas, em que a informação não chegou ao modelo (escuro) ou chegou só em parte (claro); em laranja, as injustificadas, em que o contexto tinha toda a informação. Q: Qwen; D: DeepSeek; H: Haiku; L: Luna; M: gpt-4o-mini (econômicos, 100 perguntas); Sn: Sonnet; Sl: Sol (intermediários, afastados à direita em cada método, 25 perguntas). As escalas verticais dos dois painéis são diferentes. O MedQA não aparece: nele, as 15 respostas marcadas pelo detector traziam uma resposta à questão, e a expressão de recusa estava na justificativa.

resume, por método, o que chegou ao LLM e o que ele fez com e sem a informação.

Sem a informação, os modelos responderam quase metade das vezes. No Docugami, o contexto não tinha nada da informação em 1.719 das 3.300 respostas dos métodos de RAG, e os modelos recusaram em 935 delas: uma rejeição negativa de 54%. Nas outras 784, responderam assim mesmo; essas respostas trouxeram, em média, 2% dos valores pedidos, e 93% delas não acertaram nenhum. Nos exemplos inspecionados, parte responde com valores do contexto que são de outro trimestre ou de outra empresa, apresentados como se fossem os pedidos, e parte é uma recusa com outra redação (“the context does not directly state…”), que o detector não captura. A rejeição negativa variou muito entre os modelos: 76% no DeepSeek, 66% no Qwen, 56% no Sonnet, 55% no Haiku e 54% no gpt-4o-mini, contra 35% no Sol e 26% no Luna. O Luna, o econômico que menos recusou no Docugami, não recusa pouco por receber mais vezes a informação, já que, nos quatro métodos que usam a pergunta original, os fragmentos são os mesmos para todos os LLMs, mas por responder sem ela em 74% dos casos. No FaQuAD, a informação faltou em apenas 6% das respostas, e os modelos responderam em 135 desses 202 casos, com cobertura média de 0,39; em 40% deles, porém, a resposta aceita estava literalmente no contexto, o que indica, também, casos em que o juiz não reconheceu a informação.

O que muda de um método para outro. No Docugami, o Query Step-Down e o Reciprocal levaram a informação completa ao modelo em 32% das respostas cada um, contra 20% dos quatro métodos que usam a pergunta original, o que confirma que a vantagem do Query Step-Down vem da recuperação. Ele foi, porém, o método que menos recusou sem a informação (rejeição negativa de 23%, contra 81% do Stuff): provavelmente porque, ao combinar as respostas das perguntas alternativas, ele responde com o que elas encontraram, mesmo quando isso não responde à pergunta original. O Map-Rerank mostrou o problema oposto: com

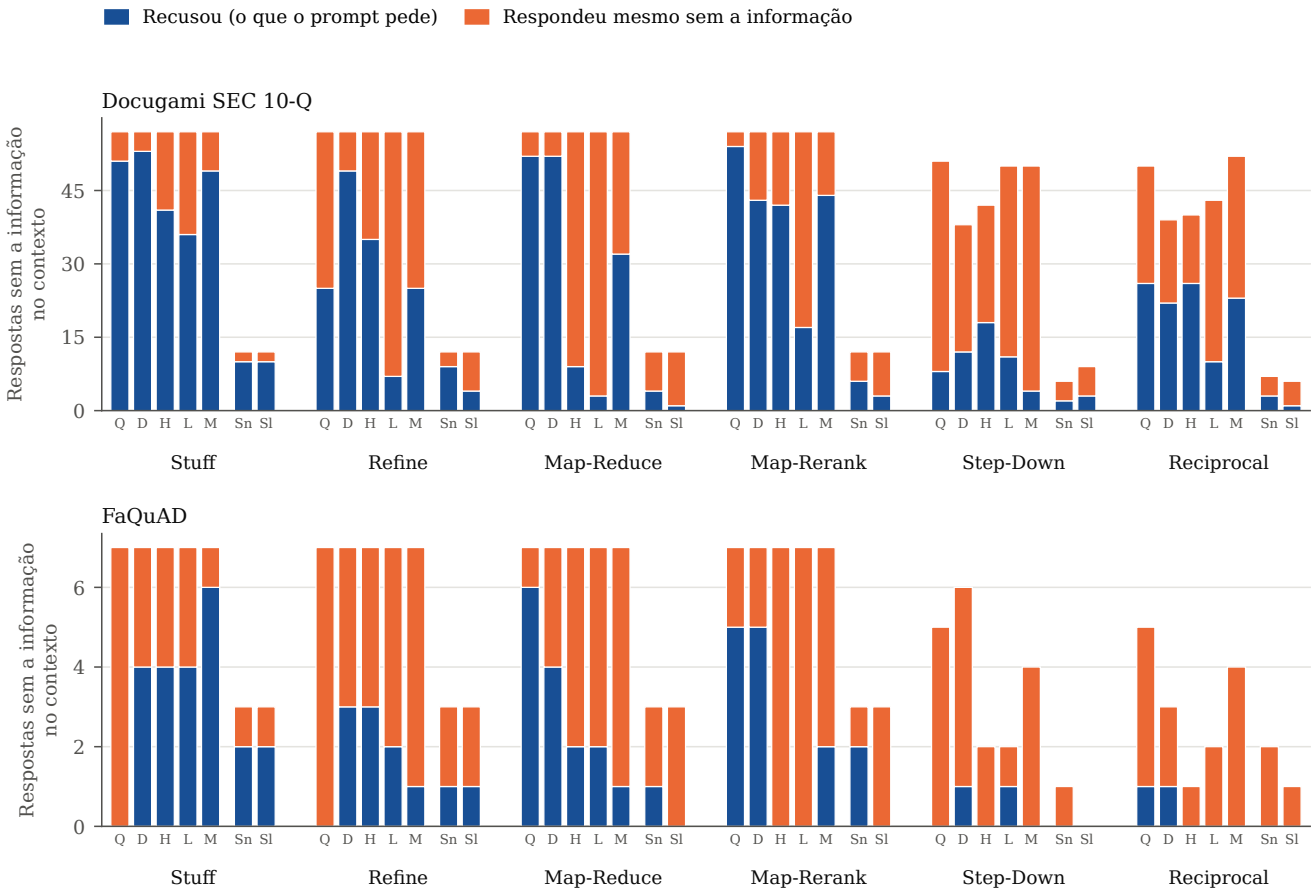


FIGURA 5. Respostas em que o contexto não tinha nada da informação, segundo o juiz, por método e LLM (repetição 1): em azul, o modelo recusou, como o prompt pede; em laranja, respondeu assim mesmo. A altura da barra é o número de perguntas em que a informação não chegou ao modelo; no Stuff, no Refine, no Map-Reduce e no Map-Rerank, que usam os mesmos quatro fragmentos, ela é igual em todos os LLMs de uma mesma camada. Siglas dos LLMs como na Figura 4. As escalas verticais dos dois painéis são diferentes.

TABELA 8. O que chegou ao LLM e o que ele fez, por método, nos cinco econômicos (camada principal, 500 respostas por método e conjunto), segundo o juiz. Inf. completa e Inf. ausente: porcentagem das respostas em que o contexto tinha toda a informação ou nada dela (o restante teve parte). Rej. negativa: dos casos sem a informação, a porcentagem em que o modelo recusou, como no RGB [30]; o restante respondeu sem a informação. Recusa injust.: dos casos com toda a informação, a porcentagem em que o modelo recusou. Métrica c/ inf.: métrica principal quando o contexto tinha toda a informação; Métrica s/ inf.: quando não tinha nada dela e o modelo respondeu assim mesmo.

	Docugami SEC 10-Q (valores do gabarito)						FaQuAD (cobertura de tokens)					
Método	Inf. completa	Inf. ausente	Rej. negativa	Recusa injust.	Métrica c/ inf.	Métrica s/ inf.	Inf. completa	Inf. ausente	Rej. negativa	Recusa injust.	Métrica c/ inf.	Métrica s/ inf.
Stuff	20	57	81	26	0,42	0,01	92	7	51	1	0,93	0,36
Refine	20	57	49	13	0,39	0,01	92	7	26	2	0,90	0,44
Map-Reduce	20	57	52	22	0,34	0,02	92	7	43	1	0,89	0,36
Map-Rerank	20	57	70	45	0,08	0,01	92	7	34	4	0,82	0,36
Step-Down	32	46	23	9	0,38	0,03	94	4	11	0	0,86	0,53
Reciprocal	32	45	48	20	0,23	0,02	94	3	13	1	0,72	0,18

toda a informação no contexto, recusou 45% das vezes e trouxe apenas 8% dos valores, contra 42% do Stuff, o que é coerente com responder a cada fragmento isoladamente, sem juntar os valores espalhados. No FaQuAD, o Reciprocal teve, com o Query Step-Down, a melhor recuperação (informação completa em 94% das respostas) e, ainda assim, a menor cobertura com a informação no contexto (0,72, contra 0,93 do Stuff): a sua perda vem da geração, que responde a uma reformulação da pergunta, e não da busca.

Essa decomposição distingue três problemas com soluções diferentes. Quando a informação não chega ao modelo, como em mais da metade das respostas do Docugami, o que resolve é melhorar a recuperação, com mais fragmentos ou perguntas mais específicas; trocar o LLM não resolve.

Quando a informação chega e o modelo recusa ou erra, como no Map-Rerank e no Reciprocal, o problema está no método, que seleciona uma única resposta. E, quando a informação não chega, os modelos trocam um erro por outro: os que menos recusam sem justificativa, como o Sol e o Luna (6% e 7% de recusa com a informação completa no Docugami, contra 29% do DeepSeek e do Qwen), são também os que mais respondem sem a informação. Uma taxa de recusa baixa, isoladamente, não indica um modelo melhor: ela precisa ser lida junto com o que chegou ao contexto, sob o risco de premiar respostas sem sustentação.

E. GENERALIZAÇÃO E EFEITO DO PORTE

A Figura 6 mostra os sete modelos nas 25 perguntas comuns. A concordância entre eles repetiu a da camada principal: alta no Docugami ($W = 0{,}64$; $p < 0{,}001$) e no FaQuAD ($W = 0{,}61$; $p < 0{,}001$), e menor no MedQA ($W = 0{,}34$; $p = 0{,}03$), próxima da camada principal ($W = 0{,}39$; $p = 0{,}08$), embora aqui significativa. No MedQA, o Sol acertou 96% com os seis métodos e não os ordena; com a correção de empates, ele não conta como discordância. Os intermediários seguiram, em geral, o padrão dos econômicos. No FaQuAD, o Sonnet teve 0,91 com o Stuff e 0,56 com o Map-Rerank e com o Reciprocal; no Docugami, o Query Step-Down e o Refine ficaram à frente nos dois intermediários, e o Map-Rerank, em último, com nenhum valor correto no Sonnet. No MedQA, os dois intermediários acertaram de 92% a 96% com qualquer método: no teto da escala, a escolha do método é irrelevante. A resposta à QP2 é, portanto, que a ordem dos métodos depende mais do domínio do que do LLM.

A Tabela 9 testa, em cada família, se o modelo econômico com o seu melhor método alcança o intermediário com o Stuff, a configuração mais simples [24]. Em nenhum caso o intermediário com o Stuff foi significativamente superior, e em cinco dos seis o econômico teve média igual ou maior. No Docugami, o Haiku com o Query Step-Down trouxe 26% dos valores, contra 10% do Sonnet com o Stuff ($p = 0{,}018$), a um custo 3,2 vezes menor; o Luna teve vantagem semelhante sobre o Sol (29% contra 16%), sem significância ($p = 0{,}12$). A diferença de custo vem do preço do token, e não do consumo: o Haiku com o Query Step-Down gastou 5,9 vezes mais tokens por pergunta que o Sonnet com o Stuff, mas cada token custa 20 vezes menos. No MedQA e no FaQuAD, as duas configurações empataram, a um custo de 7 a 20 vezes menor para o modelo econômico. Com 25 perguntas, o teste só detectaria diferenças grandes, mas a tendência é clara: escolher o método adequado ao domínio valeu tanto quanto trocar por um modelo mais caro.

F. CUSTO

A Tabela 10 resume o custo dos métodos. As diferenças são grandes e estáveis entre LLMs e conjuntos. Em relação ao Stuff (1.142 tokens por resposta, em média, e 2,9 s, em mediana), o Map-Reduce e o Map-Rerank custaram 1,8 vez, o Refine 2,7 vezes, e o Reciprocal e o Query Step-Down, que geram e respondem quatro perguntas alternativas, 5,3 e 5,7 vezes. O Query Step-Down também foi o mais lento, com 16,0 s em mediana, mais de cinco vezes o Stuff. O controle sem RAG custou 0,4 vez o Stuff. A Tabela 5 detalha o consumo por LLM e conjunto: nas 21 combinações, incluindo os intermediários, o Query Step-Down foi o método que mais consumiu tokens, seguido do Reciprocal, com 3.682 a 10.063 tokens por pergunta, contra 658 a 1.892 do Stuff. Em dólares (Tabela 6), o preço do token pesou mais que o método: em cada conjunto, o Haiku e o Luna com o Query Step-Down, o seu método mais caro, custaram menos que o Sonnet e o Sol com o Stuff, o seu método de RAG mais barato. Por 1.000 perguntas, os econômicos custaram de US$ 0,02 a US$ 5,77, e os intermediários, de US$ 0,43 a US$ 32,96.

Cruzando custo e qualidade, o Reciprocal é dominado: custa cerca de cinco vezes o Stuff e não o superou significativamente em nenhum domínio, ficando significativamente abaixo dele no FaQuAD. O Query Step-Down é o único método cujo custo adicional trouxe um ganho consistente, e apenas no domínio em que a recuperação é o gargalo. Entre os LLMs, o custo nominal total da geração variou de US$ 0,64 (Luna) a US$ 7,67 (Sonnet), e o Sonnet, com apenas 25 perguntas por conjunto, custou mais que qualquer modelo da camada principal com 100.

A Figura 7 reúne o custo e o desempenho de todos os métodos e LLMs. Entre os pontos de um mesmo modelo, a distância horizontal mostra quanto cada método custa a mais, e a vertical, quanto ele muda a métrica. No Docugami, o Query Step-Down, o método mais caro em todos os modelos, também teve a maior métrica em cinco dos sete e, nos outros dois, o gpt-4o-mini e o Sol, empatou com o Refine na segunda casa decimal. No FaQuAD, ocorreu o oposto: o Stuff, o método de RAG mais barato em todos os modelos, teve a maior cobertura, ou empatou com a maior, em cinco dos sete. No MedQA, os pontos de cada modelo se espalham mais na horizontal que na vertical: do ponto mais barato ao mais caro, o custo variou de 7 a 15 vezes, e a acurácia, no máximo 12 pontos percentuais. Com o mesmo método, os intermediários custaram mais que todos os econômicos nos três conjuntos; como eles foram avaliados em 25 perguntas, a comparação entre os dois grupos nas mesmas perguntas é a da Tabela 9.

A Figura 8 mostra os mesmos métodos e modelos com os tokens consumidos no lugar da métrica. Dentro de cada modelo, os pontos ficam quase sobre uma diagonal, já que o custo cresce na proporção dos tokens; a distância vertical entre modelos de mesmo custo é a diferença de preço do token. Com o mesmo consumo de tokens, o Sonnet e o Sol custam 20 vezes o Haiku e o Luna, o que explica por que, nos intermediários, até o Stuff custou mais que o Query Step-Down dos econômicos da mesma família.

G. VARIAÇÃO DO MODELO

Nos quatro modelos sem temperatura 0, o desvio-padrão da métrica principal entre as três execuções do Stuff, por

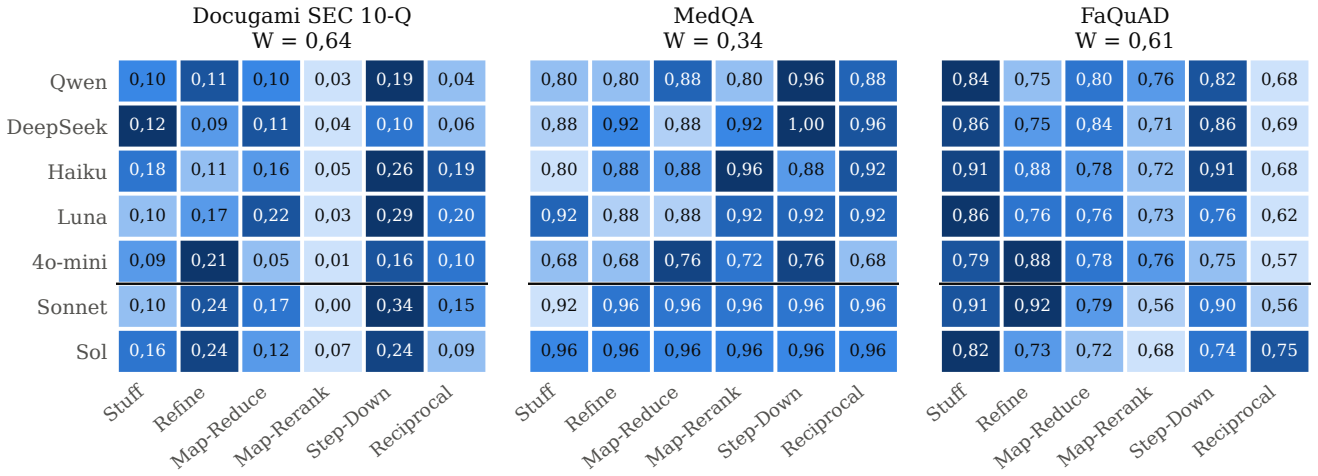


FIGURA 6. Métrica principal dos sete LLMs nas 25 perguntas comuns de cada conjunto. A cor indica a posição do método dentro de cada LLM (mais escuro, melhor; valores iguais, mesma cor); W é o coeficiente de concordância de Kendall entre os sete LLMs. Abaixo da linha, os intermediários.

TABELA 9. Modelo econômico com o seu melhor método (escolhido nas 100 perguntas da camada principal; em empate, o mais barato) contra o intermediário da mesma família com o Stuff, nas perguntas da camada de generalização (25). Preço: US$ por milhão de tokens de entrada e de saída (Tabela 2). Tokens: média por pergunta, somando a entrada e a saída de todas as chamadas do método, contados pelo tokenizador de cada modelo. Custo: US$ por 1.000 perguntas (tokens de entrada e de saída vezes o preço de cada um). Métrica: a principal de cada conjunto. p: McNemar exato (acurácia) ou Wilcoxon pareado entre as duas configurações. Razão: custo do intermediário dividido pelo do econômico, calculada antes do arredondamento.

Dataset	Família	Configuração	Preço (US$/1M)	Tokens	Custo (US$/1.000)	Métrica	p	Razão
Docugami	OpenAI	Luna + Step-Down	0,10 / 0,50	5.715	0,75	0,29		
		Sol + Stuff	2,00 / 10,00	1.037	2,47	0,16	0,122	3,3×
	Anthropic	Haiku + Step-Down	0,10 / 0,50	9.661	1,63	0,26		
		Sonnet + Stuff	2,00 / 10,00	1.630	5,23	0,10	0,018	3,2×
MedQA	OpenAI	Luna + Map-Rerank	0,10 / 0,50	2.094	0,28	0,92		
		Sol + Stuff	2,00 / 10,00	1.055	2,42	0,96	1,000	8,7×
	Anthropic	Haiku + Map-Rerank	0,10 / 0,50	3.759	0,65	0,96		
		Sonnet + Stuff	2,00 / 10,00	1.800	4,81	0,92	1,000	7,4×
FaQuAD	OpenAI	Luna + Stuff	0,10 / 0,50	662	0,08	0,86		
		Sol + Stuff	2,00 / 10,00	658	1,51	0,82	0,463	19,5×
	Anthropic	Haiku + Stuff	0,10 / 0,50	1.283	0,17	0,91		
		Sonnet + Stuff	2,00 / 10,00	1.255	3,14	0,91	0,686	18,3×

TABELA 10. Custo por resposta na camada principal (5 LLMs, 3 datasets, 1.500 respostas por método). Custo relativo: custo em US$ do método dividido pelo do Stuff, por LLM e dataset (mediana e faixa dos 15 pares). Tempo: da recuperação ao fim da geração.

Método	Chamadas	Tokens	Custo relativo ao Stuff	Tempo (s, mediana)
Sem RAG	1	317	0,4 (0,2–0,8)	1,9
Stuff	1	1.142	1	2,9
Refine	4	2.472	2,7 (1,5–4,5)	8,9
Map-Reduce	5	2.063	1,8 (0,9–2,7)	7,7
Map-Rerank	4	1.863	1,8 (1,0–2,5)	6,8
Step-Down	6	6.159	5,7 (3,7–7,5)	16,0
Reciprocal	5	5.463	5,3 (3,4–6,0)	12,8

pergunta, ficou, em média, entre 0 e 0,053. No MedQA, três dos quatro modelos escolheram a mesma alternativa nas três execuções de todas as perguntas. Os maiores desvios ocorreram no Sol no Docugami (0,053), no Luna no FaQuAD (0,051) e no Haiku no Docugami (0,035). As diferenças entre métodos que sustentam as conclusões do FaQuAD, como a do Reciprocal em relação ao Stuff (11 a 28 pontos), são muito maiores que essa variação. Já a vantagem do Query Step-Down sobre o Stuff no Docugami, de 2,8 a 6,5 pontos nos econômicos, tem a mesma ordem de grandeza da variação nesse conjunto, outro motivo para tratá-la como tendência.

H. A MÉTRICA E A COMPARAÇÃO COM O ESTUDO DE REFERÊNCIA

No Docugami, a similaridade de cosseno deu ao controle sem RAG uma nota média maior que a do Stuff em seis dos sete modelos — de 0,02 a 0,17 a mais em quatro deles, como no DeepSeek (0,81 contra 0,70) e no Qwen (0,81 contra 0,64), e menos de 0,01 a mais no Haiku e no

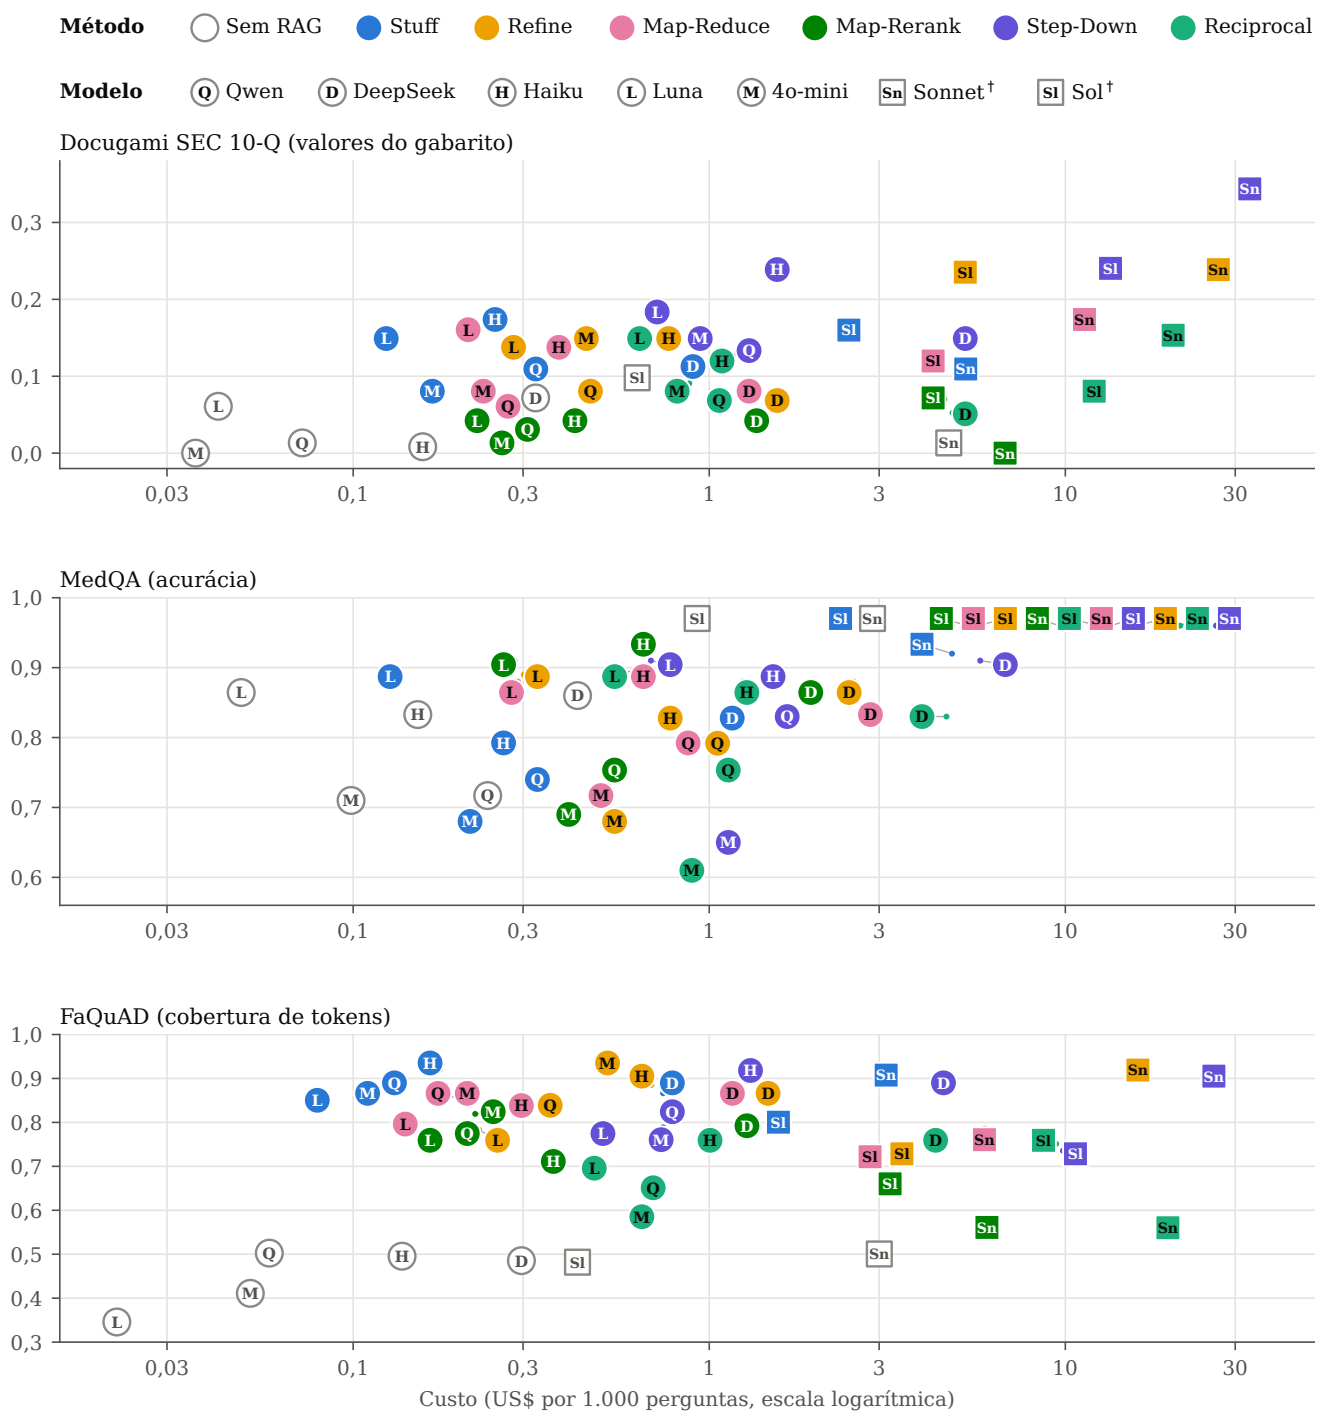


FIGURA 7. Desempenho e custo de cada método e LLM: métrica principal de cada conjunto contra o custo em US$ por 1.000 perguntas, em escala logarítmica (os mesmos valores das Tabelas 4 e 6). A cor indica o método, e a sigla, o LLM. Econômicos (círculos): camada principal (100 perguntas). †Intermediários (quadrados): as 25 perguntas da camada de generalização. Marcadores que se sobreporiam foram afastados o mínimo necessário, sem inverter a ordem dos valores nos dois eixos, e uma linha fina liga cada um à sua posição real.

Sonnet —, embora o Stuff trouxesse mais valores corretos em todos os sete. A métrica acompanha o acerto apenas de forma fraca (Spearman $\rho = 0{,}43$ entre o cosseno e a proporção de valores, nas 3.850 respostas): as respostas sem nenhum valor correto tiveram similaridade média de 0,70, e as com todos os valores, de 0,86. Respostas fluentes no vocabulário do domínio, como uma descrição geral da evolução das receitas de uma empresa sem nenhum número,

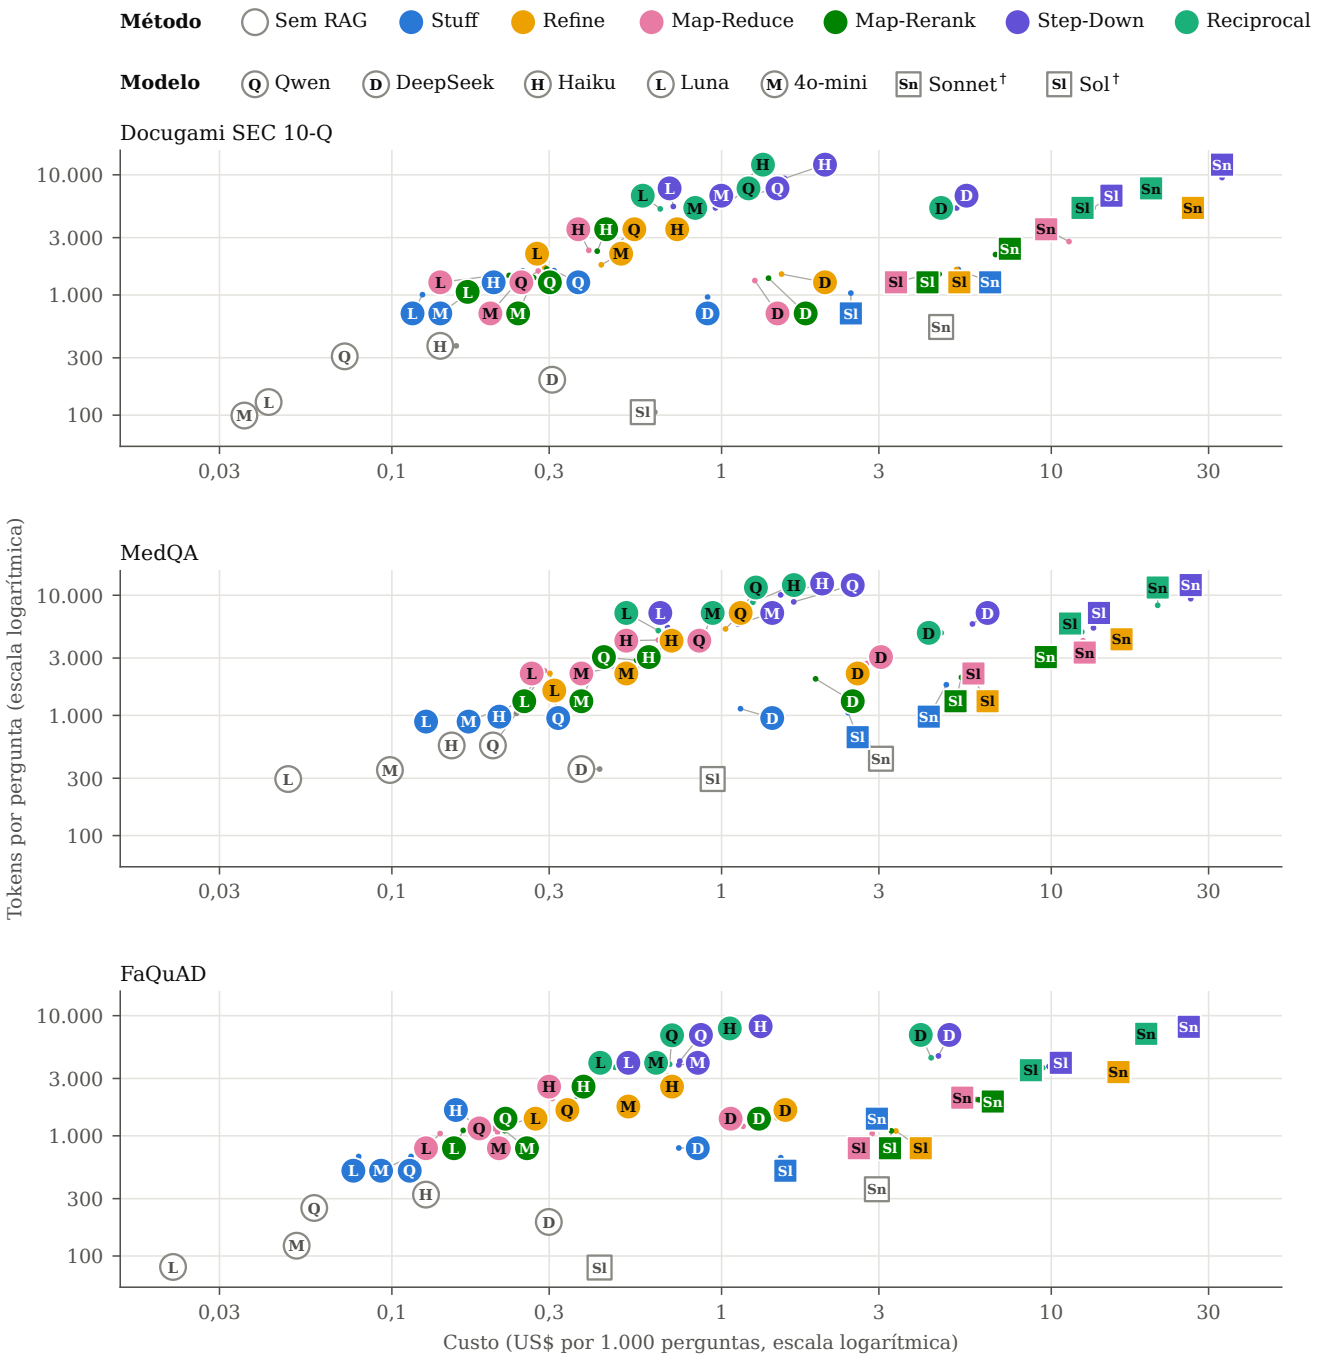


FIGURA 8. Tokens e custo de cada método e LLM: tokens por pergunta contra o custo em US$ por 1.000 perguntas, ambos em escala logarítmica (os mesmos valores das Tabelas 5 e 6). A cor indica o método, e a sigla, o LLM. Econômicos (círculos): camada principal (100 perguntas). †Intermediários (quadrados): as 25 perguntas da camada de generalização. Marcadores que se sobreporiam foram afastados o mínimo necessário, sem inverter a ordem dos valores nos dois eixos, e uma linha fina liga cada um à sua posição real.

ficam próximas da referência no espaço de embeddings. Uma análise feita apenas com a similaridade de cosseno concluiria que o RAG piora as respostas financeiras da maioria dos modelos, o oposto do que mostra a comparação com os valores do gabarito.

A Tabela 11 compara as medianas da similaridade de cosseno com as da Tabela 1 de Şakar e Emekci [4], com o bge-small-en-v1.5, um dos três embeddings daquele estudo. No Docugami, o Reciprocal, primeiro colocado no estudo de referência (0,971), foi aqui o último (0,683), e o Query Step-Down foi o primeiro (0,883), em linha com a métrica principal. No MedQA, os seis métodos ficaram entre 0,757

TABELA 11. Mediana da similaridade de cosseno com a resposta de referência: Tabela 1 de Şakar e Emekci [4] e este trabalho, com o bge-small-en-v1.5, um dos três embeddings daquele estudo, e todas as respostas dos 7 LLMs. Entre parênteses, a posição do método (valores iguais na terceira casa decimal dividem a posição).

	Docugami SEC 10-Q		MedQA	
Método	Artigo-base	Este trabalho	Artigo-base	Este trabalho
Stuff	0,895 (2º)	0,838 (3º)	0,641 (3º)	0,757 (6º)
Refine	0,836 (5º)	0,866 (2º)	0,609 (4º)	0,760 (5º)
Map-Reduce	0,873 (4º)	0,836 (4º)	0,569 (5º)	0,769 (3º)
Map-Rerank	0,801 (6º)	0,690 (5º)	0,148 (6º)	0,773 (2º)
Step-Down	0,890 (3º)	0,883 (1º)	0,678 (1º)	0,769 (3º)
Reciprocal	0,971 (1º)	0,683 (6º)	0,673 (2º)	0,776 (1º)

TABELA 12. Métricas RAGAS por método (média das respostas dos 7 LLMs; juiz gpt-4o-mini). A *Faithfulness* só se aplica aos métodos com um conjunto único de trechos.

	Faithfulness			*Answer Relevancy*		
Método	Docug.	MedQA	FaQuAD	Docug.	MedQA	FaQuAD
Sem RAG	–	–	–	0,28	0,53	0,56
Stuff	0,74	0,22	0,90	0,28	0,54	0,69
Refine	0,77	0,33	0,86	0,39	0,51	0,68
Map-Reduce	0,51	0,19	0,82	0,35	0,54	0,77
Map-Rerank	0,65	0,18	0,85	0,21	0,50	0,47
Step-Down	–	–	–	0,44	0,54	0,68
Reciprocal	–	–	–	0,29	0,50	0,50

e 0,776, enquanto o estudo de referência variou de 0,148 (Map-Rerank) a 0,678; com respostas que começam pela letra da alternativa e trazem uma justificativa, a similaridade com o texto da alternativa correta mede pouco, e a acurácia é a métrica adequada. A vantagem do Reciprocal não se reproduziu no Docugami com nenhuma das duas métricas; no MedQA, ele teve a maior mediana de cosseno, mas a menos de 0,02 dos demais e sem vantagem na acurácia. Como o estudo de referência agrega LLMs, embeddings, bancos e filtros de compressão e não detalha a sua implementação dos métodos, não é possível atribuir a divergência a uma causa única; a diferença entre a sua Tabela 1 e os resultados por LLM obtidos aqui indica, porém, que a ordem dos métodos relatada não é uma propriedade geral deles.

I. MÉTRICAS RAGAS

A Tabela 12 apresenta as métricas RAGAS por método. Na Faithfulness, o Stuff e o Refine tiveram as maiores médias no Docugami (0,74 e 0,77) e no FaQuAD (0,90 e 0,86), e o Map-Reduce a menor no Docugami (0,51): a etapa de combinação recebe as respostas parciais, e não os fragmentos, o que permite ao modelo acrescentar afirmações sem sustentação no contexto. No MedQA, a Faithfulness foi baixa em todos os métodos (0,18 a 0,33), como esperado: o prompt autoriza o modelo a usar o próprio conhecimento, e a métrica, nesse caso, mede o quanto a justificativa vai além dos trechos, e não alucinação.

A Answer Relevancy reproduziu, no FaQuAD, a ordem da métrica principal nos extremos: Map-Rerank (0,47) e Reciprocal (0,50) ficaram abaixo dos demais métodos e do próprio controle sem RAG (0,56). No Docugami, os valores foram baixos em todos os métodos (0,21 a 0,44), porque a métrica atribui nota zero a respostas evasivas [10], e as recusas foram frequentes; o Query Step-Down, que menos recusou, teve a maior média. No MedQA, a métrica praticamente não variou (0,50 a 0,54): respostas que começam pela letra de uma alternativa geram perguntas pouco específicas, e a métrica não distingue os métodos. Com o juiz validado em uma AUROC de 0,70, essas leituras são complementares e não alteram as conclusões tiradas das métricas comparadas com o gabarito.

J. BANCOS VETORIAIS

A Tabela 13 compara o ChromaDB e o FAISS. Nas duas bases menores, os bancos entregaram exatamente os mesmos quatro fragmentos em todas as consultas, e o Hit@4 foi idêntico; no Docugami, o índice dos experimentos divergiu da busca exata em uma das 100 consultas, sem mudar a métrica. No MedQA, com 121.553 vetores, a busca aproximada do HNSW devolveu um top-4 diferente da busca exata em 18% das consultas do índice recriado para o comparativo e em 16% das consultas em relação ao índice dos experimentos. Nessas 16 perguntas, o Stuff do `gpt-4o-mini` foi refeito com os fragmentos do FAISS: a acurácia nas 100 perguntas passou de 0,68 para 0,69, com uma única pergunta mudando de errada para certa (McNemar $p = 1{,}0$). A busca aproximada, portanto, não alterou os resultados deste estudo (QP4), embora a aproximação seja mensurável na maior base.

Em infraestrutura, o FAISS indexou centenas de vezes mais rápido (cerca de 240 vezes no Docugami e 860 no MedQA) e com menos memória, já que o ChromaDB também persiste os textos e os metadados em disco. Na consulta, o FAISS foi mais rápido na menor base (0,05 ms contra 3,78 ms no FaQuAD), equivalente no Docugami (2,1 ms nos dois) e mais lento na maior (36,5 ms contra 5,0 ms no MedQA): a busca exata cresce linearmente com o número de vetores, enquanto o HNSW cresce de forma sublinear [19]. Em todos os casos, os tempos de consulta são desprezíveis diante dos segundos gastos na geração.

K. QUAL MÉTODO ESCOLHER

Os resultados não apontam um método universalmente superior, mas apontam como escolher. Em bases com respostas localizadas em um único trecho, que a busca encontra, como no FaQuAD, o Stuff foi o melhor e o mais barato, e não há razão para pagar por métodos mais complexos. Em bases em que a recuperação é o gargalo, com respostas espalhadas por vários fragmentos, como no Docugami, o Query Step-Down foi o único método cujo custo adicional, de quase seis vezes o Stuff, trouxe um ganho consistente. Em domínios que o modelo já domina, como o MedQA, o método pouco importa, e o primeiro passo é medir se o RAG acrescenta algo em relação ao modelo sem recuperação. No Docugami e no FaQuAD, o Reciprocal e o Map-Rerank, que selecionam uma única resposta por nota de confiança, ficaram entre

TABELA 13. ChromaDB (HNSW, busca aproximada) e FAISS (`IndexFlatL2`, busca exata) sobre os mesmos vetores BGE-M3. Top-4 idêntico: consultas em que os dois bancos entregam os mesmos quatro fragmentos. Na última coluna, a métrica principal do Stuff do gpt-4o-mini nas 100 perguntas, refazendo com o top-4 do FAISS as perguntas em que ele difere do índice dos experimentos.

		Indexação (s)		Consulta (ms)		Memória (MB)			
Dataset	Vetores	Chroma	FAISS	Chroma	FAISS	Chroma	FAISS	Top-4 idêntico	Stuff: Chroma × FAISS
FaQuAD	318	0,63	0,001	3,78	0,05	29,3	1,6	100%	0,86 × 0,86
Docugami SEC 10-Q	4.463	4,01	0,017	2,11	2,08	191,9	17,8	100%	0,09 × 0,09
MedQA	121.553	260,83	0,304	5,00	36,47	801,5	474,8	82%	0,68 × 0,69

os piores; no MedQA, em que os métodos pouco diferiram, o Map-Rerank ficou entre os melhores. O Reciprocal, que custou cerca de cinco vezes o Stuff, ficou entre os dois piores métodos nos três domínios. Por fim, a escolha do método pesou tanto quanto a do modelo: os econômicos com o método adequado não ficaram significativamente abaixo dos intermediários com o Stuff em nenhum conjunto, a uma fração do custo.

L. LIMITAÇÕES

Os resultados devem ser lidos à luz das seguintes limitações.

- **Tamanho da amostra.** A camada principal tem 100 perguntas por conjunto, e a de generalização, 25. As conclusões sobre os métodos vêm da camada principal; nos intermediários, só diferenças grandes podem ser detectadas.
- **Configuração fixa.** Um único embedding (BGE-M3), um único tamanho de fragmento e $k = 4$, sem compressão contextual nem reordenação dos fragmentos. Com um k maior, por exemplo, a desvantagem do Stuff no Docugami poderia diminuir.
- **Gabaritos.** As respostas de referência do Docugami foram geradas pelo GPT-4 e revisadas por pessoas. As questões do MedQA são públicas desde 2020 e podem estar nos dados de treinamento dos modelos, o que inflaria a acurácia sem recuperação.
- **Métricas.** A proporção de valores do gabarito verifica a presença dos números pedidos, mas não penaliza valores errados acrescentados à resposta; a cobertura de tokens não penaliza respostas longas; e a acurácia depende da extração automática da alternativa escolhida, conferida manualmente nas 32 respostas que não a traziam no início. As métricas RAGAS e a classificação do contexto dependem de um juiz com AUROC de 0,70, que também é um dos modelos avaliados; nas recusas, ele se mostrou conservador, e as injustificadas podem estar subestimadas. O detector de recusas, por expressões regulares, não captura todas as redações, e parte das respostas sem a informação é, na verdade, recusa. As respostas não foram julgadas por avaliadores humanos.
- **Determinismo.** Quatro dos sete modelos não aceitam temperatura 0. A variação foi medida no Stuff, mas cada resultado dos demais métodos vem de uma única execução.
- **Tempo e custo.** Os modelos foram executados em paralelo na mesma máquina, e o embedding da pergunta é calculado localmente; os tempos medidos incluem essa disputa de CPU e a latência de cada provedor. Os tokens não são afetados. O custo é nominal e não considera descontos de cache de prompt.
- **Modelos comerciais.** Modelos acessados por API podem mudar sem aviso [25]. A versão informada pela API e o provedor foram registrados em cada execução, e dois dos sete modelos têm pesos abertos.

V. CONCLUSÃO

Este trabalho comparou seis métodos de RAG e um controle sem recuperação em três conjuntos de dados públicos com gabarito — relatórios financeiros (Docugami SEC 10-Q), questões de exame médico (MedQA-USMLE) e documentos do ensino superior em português (FaQuAD) —, com sete LLMs de quatro empresas, em 12.150 execuções. A qualidade foi medida diretamente contra o gabarito de cada conjunto e complementada pelas métricas RAGAS, com o juiz validado contra um conjunto anotado, e o efeito da busca aproximada do banco vetorial foi medido contra a busca exata.

Os principais resultados são os seguintes:

1) **O domínio decide quanto o RAG acrescenta.** Em documentos que o modelo não conhece, como as normas de uma universidade no FaQuAD, a recuperação multiplicou a qualidade das respostas por 1,7 a 2,5 em todos os modelos. Em conhecimento que os modelos já dominam, como as questões do USMLE, nenhum método alterou significativamente a acurácia de nenhum modelo, e os intermediários acertaram de 92% a 96% das questões com ou sem RAG.
2) **O domínio decide o melhor método, e a ordem se repete entre os LLMs.** No Docugami e no FaQuAD, os modelos ordenaram os métodos de forma parecida (W de Kendall de 0,71 e 0,74 entre os cinco econômicos, e de 0,64 e 0,61 entre os sete), mas o melhor método mudou de um domínio para outro: o Stuff no FaQuAD e o Query Step-Down no Docugami.
3) **Os métodos mais caros só compensam quando a recuperação é o gargalo.** O Query Step-Down, com quase seis vezes o custo do Stuff, foi o melhor no domínio financeiro, em que as respostas dependem de valores espalhados por vários fragmentos; no MedQA, ficou à frente na média dos postos, mas por poucos

pontos, e no FaQuAD ficou atrás do Stuff. O Reciprocal, melhor método do estudo de referência, custou quase o mesmo e ficou entre os piores em todos os domínios.

4) **O método adequado vale tanto quanto um modelo mais caro.** Os modelos econômicos com o melhor método não ficaram significativamente abaixo dos intermediários da mesma família com o Stuff em nenhum conjunto, e tiveram média igual ou maior em cinco das seis comparações, a um custo de 3 a 20 vezes menor.
5) **A métrica muda a conclusão.** No domínio financeiro, a similaridade de cosseno deu ao controle sem RAG notas maiores que as do Stuff em seis dos sete modelos (em dois deles, por menos de 0,01), embora o Stuff trouxesse mais valores corretos em todos. Uma análise feita só com essa métrica concluiria que o RAG piora as respostas.
6) **Recusar pouco não é sinal de qualidade.** No Docugami, quando a informação não chegou ao modelo, ele respondeu assim mesmo em 46% dos casos, e 93% dessas respostas não trouxeram nenhum valor correto. O Sol e o Luna, os modelos que menos recusaram com a informação no contexto, foram também os que mais responderam sem ela (65% e 74% das vezes). A taxa de recusa só diz algo sobre o modelo quando é analisada junto com o que chegou ao contexto.
7) **A busca aproximada não distorceu os resultados.** O ChromaDB e o FAISS entregaram os mesmos fragmentos nas bases de centenas e milhares de vetores; na de 121 mil vetores, o HNSW divergiu da busca exata em 16% a 18% das consultas, sem efeito significativo na acurácia.

Do ponto de vista prático, o trabalho sugere cinco diretrizes para quem constrói sistemas RAG: medir primeiro o modelo sem recuperação, para saber se o RAG acrescenta algo no domínio de interesse; começar pelo Stuff, o mais barato em quase todas as combinações, e só adotar métodos que reformulam a pergunta, como o Query Step-Down, quando a recuperação for o gargalo; evitar métodos que selecionam uma única resposta por nota de confiança, que ficaram entre os piores no Docugami e no FaQuAD; considerar um modelo econômico com o método adequado antes de trocar por um modelo mais caro; e avaliar com uma métrica que verifique o conteúdo pedido — o valor, a alternativa ou o trecho —, e não apenas a proximidade semântica com a resposta de referência.

Como trabalhos futuros, destacam-se: variar o número de fragmentos recuperados, o modelo de embedding e a compressão contextual; incluir reordenadores de fragmentos (rerankers) e métodos híbridos de busca no domínio financeiro; ampliar a camada de generalização, inclusive com os modelos de topo; acrescentar conjuntos em português de outros domínios; e validar as métricas automáticas contra a avaliação humana das respostas.

AGRADECIMENTOS

Agradecemos às nossas famílias, ao nosso orientador e ao corpo docente da Universidade Federal de Itajubá.

Referências

[1] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W.-t. Yih, T. Rocktäschel, S. Riedel, and D. Kiela, "Retrieval-augmented generation for knowledge-intensive NLP tasks," in Advances in Neural Information Processing Systems, vol. 33, 2020, pp. 9459–9474.

[2] K. Andriopoulos and J. Pouwelse, "Augmenting LLMs with knowledge: A survey on hallucination prevention," arXiv preprint arXiv:2309.16459, 2023.

[3] L. Ma, R. Zhang, Y. Han, S. Yu, Z. Wang, Z. Ning, J. Zhang, P. Xu, P. Li, Z. Qiao, W. Ju, C. Chen, D. Wang, K. Liu, P. Wang, P. Wang, Y. Fu, C. Liu, Y. Zhou, and C.-T. Lu, "A comprehensive survey on vector database: Storage and retrieval technique, challenge," arXiv preprint arXiv:2310.11703, 2024.

[4] T. Şakar and H. Emekci, "Maximizing RAG efficiency: A comparative analysis of RAG methods," Natural Language Processing, vol. 31, pp. 1–25, 2025.

[5] A. Mallen, A. Asai, V. Zhong, R. Das, D. Khashabi, and H. Hajishirzi, "When not to trust language models: Investigating effectiveness of parametric and non-parametric memories," in Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (ACL), 2023.

[6] G. Xiong, Q. Jin, Z. Lu, and A. Zhang, "Benchmarking retrieval-augmented generation for medicine," in Findings of the Association for Computational Linguistics: ACL 2024, 2024.

[7] L. S. F. Medeiros and H. T. A. d. Oliveira, "Comparação de modelos de embeddings e LLMs para geração aumentada por recuperação em português," in Anais do Seminário Integrado de Software e Hardware (SEMISH). Sociedade Brasileira de Computação, 2025, disponível em: https://sol.sbc.org.br/index.php/semish/article/view/36829.

[8] D. Jin, E. Pan, N. Oufattole, W.-H. Weng, H. Fang, and P. Szolovits, "What disease does this patient have? A large-scale open domain question answering dataset from medical exams," Applied Sciences, vol. 11, no. 14, p. 6421, 2021.

[9] H. F. Sayama, A. V. Araujo, and E. R. Fernandes, "FaQuAD: Reading comprehension dataset in the domain of Brazilian higher education," in Proceedings of the 8th Brazilian Conference on Intelligent Systems (BRACIS), 2019, pp. 443–448.

[10] S. Es, J. James, L. Espinosa-Anke, and S. Schockaert, "RAGAs: Automated evaluation of retrieval augmented generation," in Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations, 2024, pp. 150–158.

[11] R. Friel, M. Belyi, and A. Sanyal, "RAGBench: Explainable benchmark for retrieval-augmented generation systems," arXiv preprint arXiv:2407.11005, 2024.

[12] R. Schwaber-Cohen and A. Patel, "Chunking strategies for LLM applications," Pinecone Learning Center, 2025, disponível em: https://www.pinecone.io/learn/chunking-strategies/.

[13] S. Barnett, S. Kurniawan, S. Thudumu, Z. Brannelly, and M. Abdelrazek, "Seven failure points when engineering a retrieval augmented generation system," arXiv preprint arXiv:2401.05856, 2024.

[14] O. Topsakal and T. C. Akinci, "Creating large language model applications utilizing LangChain: A primer on developing LLM apps fast," in Proceedings of the 5th International Conference on Applied Engineering and Natural Sciences (ICAENS), Konya, Turkey, 2023.

[15] X. Ma, Y. Gong, P. He, H. Zhao, and N. Duan, "Query rewriting for retrieval-augmented large language models," arXiv preprint arXiv:2305.14283, 2023.

[16] Z. Rackauckas, "RAG-Fusion: A new take on retrieval-augmented generation," arXiv preprint arXiv:2402.03367, 2024.

[17] N. F. Liu, K. Lin, J. Hewitt, A. Paranjape, M. Bevilacqua, F. Petroni, and P. Liang, "Lost in the middle: How language models use long contexts," arXiv preprint arXiv:2307.03172, 2023.

[18] I. Nair, S. Somasundaram, A. Saxena, and K. Goswami, "Drilling down into the discourse structure with LLMs for long document question answering," arXiv preprint arXiv:2311.13565, 2023.

[19] Y. A. Malkov and D. A. Yashunin, "Efficient and robust approximate nearest neighbor search using hierarchical navigable small world graphs," IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 42, no. 4, pp. 824–836, 2020.

[20] J. Johnson, M. Douze, and H. Jégou, “Billion-scale similarity search with GPUs,” IEEE Transactions on Big Data, vol. 7, no. 3, pp. 535–547, 2021.
[21] P. Rajpurkar, J. Zhang, K. Lopyrev, and P. Liang, “SQuAD: 100,000+ questions for machine comprehension of text,” in Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing (EMNLP), 2016, pp. 2383–2392.
[22] L. Zheng, W.-L. Chiang, Y. Sheng, S. Zhuang, Z. Wu, Y. Zhuang, Z. Lin, Z. Li, D. Li, E. P. Xing, H. Zhang, J. E. Gonzalez, and I. Stoica, “Judging LLM-as-a-judge with MT-Bench and Chatbot Arena,” in Advances in Neural Information Processing Systems (Datasets and Benchmarks Track), vol. 36, 2023.
[23] A. Panickssery, S. R. Bowman, and S. Feng, “LLM evaluators recognize and favor their own generations,” in Advances in Neural Information Processing Systems, vol. 37, 2024.
[24] L. Chen, M. Zaharia, and J. Zou, “FrugalGPT: How to use large language models while reducing cost and improving performance,” arXiv preprint arXiv:2305.05176, 2023.
[25] ——, “How is ChatGPT’s behavior changing over time?” Harvard Data Science Review, vol. 6, no. 2, 2024.
[26] A. Palmer, N. A. Smith, and A. Spirling, “Using proprietary language models in academic research requires explicit justification,” Nature Computational Science, vol. 4, pp. 2–3, 2024.
[27] Docugami and LlamaIndex, “Docugami KG-RAG: SEC 10-Q (Llama datasets),” Disponível em: https://github.com/run-llama/llama-datasets/tree/main/llama_datasets/docugami_kg_rag/sec_10_q. Acesso em: 25 out. 2026.
[28] J. Chen, S. Xiao, P. Zhang, K. Luo, D. Lian, and Z. Liu, “BGE M3-Embedding: Multi-lingual, multi-functionality, multi-granularity text embeddings through self-knowledge distillation,” arXiv preprint arXiv:2402.03216, 2024.
[29] OpenRouter, “OpenRouter: interface unificada para modelos de linguagem,” Disponível em: https://openrouter.ai. Acesso em: 2 nov. 2026.
[30] J. Chen, H. Lin, X. Han, and L. Sun, “Benchmarking large language models in retrieval-augmented generation,” in Proceedings of the AAAI Conference on Artificial Intelligence, vol. 38, no. 16, 2024, pp. 17 754–17 762.
[31] J. A. Hanley and B. J. McNeil, “The meaning and use of the area under a receiver operating characteristic (ROC) curve,” Radiology, vol. 143, no. 1, pp. 29–36, 1982.
[32] M. Friedman, “The use of ranks to avoid the assumption of normality implicit in the analysis of variance,” Journal of the American Statistical Association, vol. 32, no. 200, pp. 675–701, 1937.
[33] F. Wilcoxon, “Individual comparisons by ranking methods,” Biometrics Bulletin, vol. 1, no. 6, pp. 80–83, 1945.
[34] S. Holm, “A simple sequentially rejective multiple test procedure,” Scandinavian Journal of Statistics, vol. 6, no. 2, pp. 65–70, 1979.
[35] J. Demšar, “Statistical comparisons of classifiers over multiple data sets,” Journal of Machine Learning Research, vol. 7, pp. 1–30, 2006.
[36] M. G. Kendall and B. Babington Smith, “The problem of m rankings,” The Annals of Mathematical Statistics, vol. 10, no. 3, pp. 275–287, 1939.
[37] Q. McNemar, “Note on the sampling error of the difference between correlated proportions or percentages,” Psychometrika, vol. 12, no. 2, pp. 153–157, 1947.
[38] C. Spearman, “The proof and measurement of association between two things,” The American Journal of Psychology, vol. 15, no. 1, pp. 72–101, 1904.