



UNIFEI

MAXIMIZANDO A EFICIÊNCIA DE RAG: UMA ANÁLISE COMPARATIVA DE MÉTODOS RAG

**Revisão bibliográfica e plano de trabalho enviado
para análise e deliberação da banca de TCC01**

Aluno(s):

Afonso Henriques Massunari – ECO

Ryan Alves Mazzeu - ECO

Orientação:

Carlos Henrique Valério de Moraes - Orientador

junho de 2026

Sumário

1	Introdução	2
2	Motivação	3
3	Revisão bibliográfica	4
4	Objetivos específicos	5
5	Materiais e métodos	6
6	Resultados esperados	7
7	Cronograma de atividades do TCC02	8

1 Introdução

O avanço contemporâneo dos Modelos de Linguagem de Grande Porte (LLMs) expandiu significativamente as fronteiras da Inteligência Artificial, permitindo a execução de tarefas complexas que variam desde a análise de documentos legais até a geração automatizada de códigos de programação. Contudo, apesar do notável desempenho em tarefas estritamente textuais, os LLMs tradicionais enfrentam limitações severas ao lidar com conhecimentos em constante evolução e dados de domínios específicos, frequentemente resultando em respostas alucinatórias ou desatualizadas. Para mitigar esse problema, a arquitetura de Geração Aumentada de Recuperação (RAG) consolidou-se como uma abordagem não-paramétrica indispensável, integrando a capacidade gerativa dos modelos à precisão de bases de conhecimento externas indexadas em bancos de dados vetoriais. No entanto, a implementação prática de novos sistemas RAG ainda introduz desafios complexos de engenharia e infraestrutura que exigem investigação, tais como restrições de tempo de execução, saturação de limites de tokens e o consumo elevado de recursos de hardware.

Diante desse cenário, este trabalho propõe-se a realizar uma análise investigativa das metodologias de otimização aplicadas aos processos de RAG. O escopo delineado para a pesquisa abrangerá uma avaliação comparativa detalhada entre abordagens clássicas e avançadas de recuperação — especificamente os métodos Stuff, Refine, Map Reduce, Map Re-rank, Query Step-Down e Reciprocal RAG. Pretende-se analisar os impactos diretos que a escolha dessas técnicas exerce sobre três pilares fundamentais de desempenho no ecossistema de inteligência artificial: a acurácia semântica das respostas geradas (mensurada por métricas de similaridade de cosseno), a eficiência no consumo de tokens e a utilização de infraestrutura de hardware, envolvendo o consumo de CPU, memória RAM e tempo de resposta. Esse recorte metodológico justifica-se pela necessidade premente de compreender os múltiplos tradeoffs técnicos existentes entre a precisão da resposta entregue ao usuário e os custos operacionais de computação em nuvem em ambientes de alta escala.

O objetivo principal desta proposta de pesquisa é projetar e sintetizar um panorama analítico sobre a eficiência de arquiteturas RAG, buscando identificar as melhores configurações de componentes para diferentes cenários de aplicação. Especificamente, o trabalho investigará como a escolha combinada de bancos de dados vetoriais (como ChromaDB, FAISS e Pinecone), modelos de embedding (como Bge-en-small, Text-embedding-v3-large e Cohere-en-v3) e filtros de compressão contextual (limiares de similaridade e redundância) afetam o equilíbrio entre o gerenciamento de recursos e a qualidade do texto final gerado pelo modelo. Para dar sustentação teórica e metodológica a este projeto, a pesquisa tomará como base empírica e ponto de partida os dados e parâmetros discutidos na literatura recente sobre otimização sistemática por varredura em grade (grid-search), o que inclui as metodologias de testes cruzados em múltiplos domínios textuais, tais como relatórios financeiros corporativos (SEC 10Q), documentação científica (Llama2 ArXiv) e exames da área médica (MedQA).

A revisão de literatura que fundamentará este projeto terá como foco publicações recentes indexadas em bases de prestígio acadêmico internacional, com ênfase em termos-chave estruturantes como Retrieval-Augmented Generation, Vector Databases, Contextual Compression e Embedding Models. Por fim, a proposta de desenvolvimento deste estudo está estruturada de forma a aprofundar essas discussões técnicas nas seções subsequentes. O plano de trabalho prevê inicialmente a apresentação do referencial teórico acerca do funcionamento matemático da similaridade de cosseno e dos algoritmos de busca por vizinhos mais próximos. Em seguida, detalha-se o cronograma e a metodologia planejada para a análise comparativa dos indicadores de desempenho de acurácia, consumo de hardware e eficácia dos filtros de compressão. Por fim, serão delineados os resultados esperados e as contribuições pretendidas para o desenvolvimento de aplicações práticas baseadas nas conclusões a serem estabelecidas pelo estudo.

2 Motivação

A justificativa para a realização deste estudo fundamenta-se nos severos desafios de engenharia e infraestrutura impostos pela operação de Modelos de Linguagem de Grande Porte (LLMs) em cenários de produção. Embora o surgimento da arquitetura de Geração Aumentada de Recuperação (RAG) tenha mitigado o problema das alucinações ao fornecer dados de fontes externas em tempo real, sua viabilidade comercial enfrenta uma barreira crítica: a ineficiência no consumo de recursos. À medida que o volume de dados organizacionais cresce, o processo tradicional de recuperar e injetar fragmentos extensos de texto diretamente nos prompts resulta em um aumento exponencial no consumo de tokens, saturação da janela de contexto e elevação dos custos com computação em nuvem. No ecossistema tecnológico atual, há uma lacuna evidente na compreensão de como as diferentes abordagens de manipulação desse contexto — como os métodos Stuff, Refine, Map Reduce, Map Re-rank, Query Step-Down e Reciprocal RAG — afetam diretamente o uso de hardware, especificamente o consumo de CPU, memória RAM e tempo de resposta (latência). Investigar esses parâmetros é fundamental para a Ciência da Computação e Engenharia de Software, pois o sucesso de aplicações de inteligência artificial depende intrinsecamente da habilidade de equilibrar a acurácia da resposta gerada com a sustentabilidade financeira e computacional da infraestrutura.

A relevância deste tema acentua-se diante das tendências de mercado e dos recentes avanços científicos na área de Processamento de Linguagem Natural (PLN). Estudos recentes de otimização sistemática por varredura em grade (grid-search), que chegam a realizar mais de 23.000 iterações de testes cruzados em domínios complexos (como relatórios financeiros e dados médicos), apontam que a escolha cega de componentes pode inviabilizar projetos de IA. A compressão de contexto e o uso estratégico de filtros de similaridade surgem não apenas como alternativas de refinamento, mas como requisitos obrigatórios para reduzir o tráfego desnecessário de dados. Consequentemente, a motivação para este trabalho decorre da necessidade prática de mapear esses cenários e propor um guia metodológico claro. Ao correlacionar a eficiência algorítmica com o impacto físico no hardware, este estudo conecta-se a um objetivo muito maior: democratizar e viabilizar a implementação de sistemas RAG robustos e escaláveis, reduzindo o desperdício computacional e otimizando a entrega de valor tecnológico tanto no ambiente acadêmico quanto na indústria de software.

3 Revisão bibliográfica

A seção de revisão bibliográfica tem como objetivo apresentar e discutir os principais estudos e contribuições já realizados sobre o tema, organizando o conhecimento existente de forma lógica e crítica. Para preenchê-la:

1. **Organize o conteúdo:** Estruture a revisão por temas, abordagens, cronologia ou outras categorias que facilitem a compreensão do leitor.
2. **Sintetize os principais trabalhos:** Destaque os estudos mais relevantes, mencionando seus autores, métodos, principais achados e limitações.
3. **Identifique lacunas:** Aponte aspectos ainda pouco explorados ou controversos, enfatizando oportunidades para contribuições futuras.
4. **Relacione com seu tema:** Explique como os estudos revisados estão conectados ao objetivo do seu trabalho e de que forma embasam sua discussão.
5. **Use referências de qualidade:** Priorize fontes confiáveis, como artigos científicos, livros e relatórios reconhecidos na área.

Mantenha o texto coeso e evite apenas listar trabalhos; ao invés disso, discuta as contribuições e conexões entre eles para oferecer uma visão abrangente e crítica do estado da arte.

4 Objetivos específicos

O objetivo geral desta pesquisa consiste em analisar o impacto de diferentes arquiteturas e métodos de Geração Aumentada de Recuperação (RAG) sobre a eficiência de uso de hardware, consumo de tokens e acurácia semântica, a fim de propor diretrizes técnicas para a otimização de pipelines de inteligência artificial aplicados a bases de dados complexas.

Para alcançar o propósito geral e responder à problemática de infraestrutura e custos computacionais que envolvem esses sistemas, estabelecem-se os seguintes objetivos específicos:

1. **Mapear e catalogar** as abordagens clássicas e avançadas de recuperação de contexto, com ênfase detalhada no funcionamento algorítmico dos métodos Stuff, Refine, Map Reduce, Map Re-rank, Query Step-Down e Reciprocal RAG.
2. **Avaliar e comparar** o desempenho de diferentes bancos de dados vetoriais (como ChromaDB, FAISS e Pinecone) em simulações cruzadas, mensurando de forma quantitativa métricas físicas de infraestrutura como o uso de CPU, consumo de memória RAM e latência de tempo de execução.
3. **Mensurar** a variação da acurácia semântica das respostas geradas a partir de métricas de similaridade de cosseno, correlacionando a precisão do texto final com a eficácia de diferentes modelos de embedding (incluindo Bge-en-small, Text-embedding-v3-large e Cohere-en-v3).
4. **Investigar** a influência e a viabilidade da aplicação de filtros de compressão contextual (focados em limites de similaridade e redundância) sobre a contenção e redução do volume total de tokens trafegados por requisição, analisando o tradeoff gerado entre a economia financeira de processamento e a eventual perda de qualidade informacional.
5. **Validar** as hipóteses e configurações propostas por meio de uma abordagem de testes sistemáticos baseada em varredura em grade (grid-search), executando os experimentos propostos sobre conjuntos de dados de múltiplos domínios públicos de alta complexidade (como relatórios SEC 10Q, Llama2 ArXiv e MedQA).
6. **Sintetizar e propor** um arcabouço de boas práticas ou guia de tomada de decisão para engenheiros de software e pesquisadores, indicando as melhores combinações de componentes RAG para restrições específicas de custo, tempo ou hardware.

5 Materiais e métodos

A seção de materiais e métodos descreve de forma detalhada os procedimentos adotados para a realização da pesquisa ou revisão, garantindo a transparência e a reprodutibilidade. Para preenchê-la:

1. **Descreva os materiais utilizados:** Liste os materiais, instrumentos ou recursos necessários para a execução da pesquisa, como equipamentos, softwares, reagentes, entre outros. Inclua informações detalhadas sobre as características e especificações, quando relevante.
2. **Explique a metodologia de forma clara:** Detalhe os métodos e procedimentos adotados para coletar, analisar e interpretar os dados ou informações, incluindo abordagens qualitativas ou quantitativas.
3. **Justifique as escolhas metodológicas:** Explique por que determinadas técnicas ou abordagens foram escolhidas, levando em consideração a natureza do estudo e os objetivos da pesquisa.
4. **Descreva a amostra ou população:** Caso relevante, forneça detalhes sobre a amostra ou população estudada, como tamanho, características demográficas ou critérios de inclusão/exclusão.
5. **Apresente os instrumentos de coleta e análise:** Caso a pesquisa envolva questionários, entrevistas ou outros instrumentos, descreva-os de forma detalhada, explicando como foram aplicados e analisados.
6. **Inclua informações sobre o procedimento e cronograma:** Descreva como a pesquisa foi conduzida ao longo do tempo, incluindo os principais estágios e cronogramas, se aplicável.

Esta seção deve ser o mais detalhada possível, de forma a permitir que outros pesquisadores possam replicar o estudo com base nas informações fornecidas. Lembre-se de que a clareza e a precisão são essenciais nesta parte do trabalho.

6 Resultados esperados

A seção de resultados deve apresentar de forma objetiva e clara os dados ou informações obtidas na pesquisa, sem interpretações ou conclusões. Para preenchê-la:

1. **Apresente os dados de forma clara:** Organize os resultados de maneira estruturada, utilizando tabelas, gráficos ou figuras para facilitar a compreensão. Certifique-se de que cada dado apresentado esteja acompanhado de uma legenda ou descrição explicativa.
2. **Use medidas adequadas de resumo:** Caso necessário, inclua estatísticas descritivas, como médias, desvios padrão, frequências ou outros indicadores relevantes para a análise dos dados.
3. **Relate os resultados principais:** Destaque os achados mais significativos de forma objetiva, sem incluir interpretações ou análises, que devem ser deixadas para a seção de Discussão.
4. **Organize os resultados de forma lógica:** Se os resultados envolverem diferentes grupos, condições ou variáveis, apresente-os de maneira sequencial e lógica, para facilitar a comparação e análise.
5. **Indique os métodos de análise utilizados:** Caso utilize técnicas estatísticas ou outros métodos de análise, descreva brevemente os procedimentos empregados, garantindo a transparência dos resultados.

Evite inserir interpretações ou discussões nesta seção; o objetivo é apresentar os dados de forma clara e objetiva, permitindo que o leitor forme suas próprias conclusões.

7 Cronograma de atividades do TCC02

F.0: Título da Fase 0
Breve descrição da fase 0
Atividades planejadas para a fase 0
A.0.1 Atividade 01 A.0.2 Atividades 02
Resultados esperados para a fase 0
Descrição dos resultados esperados para a fase 0. Esses resultados demarcam o fim da fase.
F.0: Título da Fase 1
Breve descrição da fase 0
Atividades planejadas para a fase 1
A.1.1 Atividade 01 A.1.2 Atividades 02
Resultados esperados para a fase 1
Descrição dos resultados esperados para a fase 0. Esses resultados demarcam o fim da fase.

2025					
01	02	03	04	05	06
		F.0: A.0.1			
				F.0: A.0.2	

Referências Bibliográficas