



UNIFEI

MAXIMIZANDO A EFICIÊNCIA DE RAG: UMA ANÁLISE COMPARATIVA DE MÉTODOS RAG

**Revisão bibliográfica e plano de trabalho enviado
para análise e deliberação da banca de TCC01**

Aluno(s):

Afonso Henriques Massunari – ECO

Ryan Alves Mazzeu - ECO

Orientação:

Carlos Henrique Valério de Moraes - Orientador

junho de 2026

Sumário

1	Introdução	2
2	Motivação	3
3	Revisão bibliográfica	4
4	Objetivos específicos	5
5	Materiais e métodos	6
6	Resultados esperados	7
7	Cronograma de atividades do TCC02	8

1 Introdução

O avanço contemporâneo dos Modelos de Linguagem de Grande Porte (LLMs) expandiu significativamente as fronteiras da Inteligência Artificial, permitindo a execução de tarefas complexas que variam desde a análise de documentos legais até a geração automatizada de códigos de programação. Contudo, apesar do notável desempenho em tarefas estritamente textuais, os LLMs tradicionais enfrentam limitações severas ao lidar com conhecimentos em constante evolução e dados de domínios específicos, frequentemente resultando em respostas alucinatórias ou desatualizadas. Para mitigar esse problema, a arquitetura de Geração Aumentada de Recuperação (RAG) consolidou-se como uma abordagem não-paramétrica indispensável, integrando a capacidade gerativa dos modelos à precisão de bases de conhecimento externas indexadas em bancos de dados vetoriais. No entanto, a implementação prática de novos sistemas RAG ainda introduz desafios complexos de engenharia e infraestrutura que exigem investigação, tais como restrições de tempo de execução, saturação de limites de tokens e o consumo elevado de recursos de hardware.

Diante desse cenário, este trabalho propõe-se a realizar uma análise investigativa das metodologias de otimização aplicadas aos processos de RAG. O escopo delineado para a pesquisa abrangerá uma avaliação comparativa detalhada entre abordagens clássicas e avançadas de recuperação — especificamente os métodos Stuff, Refine, Map Reduce, Map Re-rank, Query Step-Down e Reciprocal RAG. Pretende-se analisar os impactos diretos que a escolha dessas técnicas exerce sobre três pilares fundamentais de desempenho no ecossistema de inteligência artificial: a acurácia semântica das respostas geradas (mensurada por métricas de similaridade de cosseno), a eficiência no consumo de tokens e a utilização de infraestrutura de hardware, envolvendo o consumo de CPU, memória RAM e tempo de resposta. Esse recorte metodológico justifica-se pela necessidade premente de compreender os múltiplos tradeoffs técnicos existentes entre a precisão da resposta entregue ao usuário e os custos operacionais de computação em nuvem em ambientes de alta escala.

O objetivo principal desta proposta de pesquisa é projetar e sintetizar um panorama analítico sobre a eficiência de arquiteturas RAG, buscando identificar as melhores configurações de componentes para diferentes cenários de aplicação. Especificamente, o trabalho investigará como a escolha combinada de bancos de dados vetoriais (como ChromaDB, FAISS e Pinecone), modelos de embedding (como Bge-en-small, Text-embedding-v3-large e Cohere-en-v3) e filtros de compressão contextual (limiares de similaridade e redundância) afetam o equilíbrio entre o gerenciamento de recursos e a qualidade do texto final gerado pelo modelo. Para dar sustentação teórica e metodológica a este projeto, a pesquisa tomará como base empírica e ponto de partida os dados e parâmetros discutidos na literatura recente sobre otimização sistemática por varredura em grade (grid-search), o que inclui as metodologias de testes cruzados em múltiplos domínios textuais, tais como relatórios financeiros corporativos (SEC 10Q), documentação científica (Llama2 ArXiv) e exames da área médica (MedQA).

A revisão de literatura que fundamentará este projeto terá como foco publicações recentes indexadas em bases de prestígio acadêmico internacional, com ênfase em termos-chave estruturantes como Retrieval-Augmented Generation, Vector Databases, Contextual Compression e Embedding Models. Por fim, a proposta de desenvolvimento deste estudo está estruturada de forma a aprofundar essas discussões técnicas nas seções subsequentes. O plano de trabalho prevê inicialmente a apresentação do referencial teórico acerca do funcionamento matemático da similaridade de cosseno e dos algoritmos de busca por vizinhos mais próximos. Em seguida, detalha-se o cronograma e a metodologia planejada para a análise comparativa dos indicadores de desempenho de acurácia, consumo de hardware e eficácia dos filtros de compressão. Por fim, serão delineados os resultados esperados e as contribuições pretendidas para o desenvolvimento de aplicações práticas baseadas nas conclusões a serem estabelecidas pelo estudo.

2 Motivação

A seção de motivação tem o papel de justificar a realização da revisão, destacando por que o tema é relevante e merece atenção. Para preenchê-la:

1. **Explique o contexto e relevância:** Aborde os desafios, problemas ou lacunas no tema que demandam maior entendimento ou investigação.
2. **Justifique a escolha do tema:** Argumente sobre a importância do assunto para a área de estudo, sociedade ou aplicação prática, usando exemplos ou dados concretos, se possível.
3. **Conecte com objetivos maiores:** Relacione o tema a objetivos mais amplos, como avanços científicos, solução de problemas críticos ou melhoria em processos existentes.
4. **Incorpore dados ou tendências:** Apresente dados estatísticos, mudanças tecnológicas ou tendências recentes que reforcem a urgência de explorar o tema.
5. **Estabeleça relevância pessoal ou acadêmica (opcional):** Indique se a motivação surge de um interesse particular, lacunas em pesquisas anteriores ou demandas do campo.

Mantenha um tom envolvente, mas objetivo, enfatizando a importância do tema para captar o interesse do leitor.

3 Revisão bibliográfica

A seção de revisão bibliográfica tem como objetivo apresentar e discutir os principais estudos e contribuições já realizados sobre o tema, organizando o conhecimento existente de forma lógica e crítica. Para preenchê-la:

1. **Organize o conteúdo:** Estructure a revisão por temas, abordagens, cronologia ou outras categorias que facilitem a compreensão do leitor.
2. **Sintetize os principais trabalhos:** Destaque os estudos mais relevantes, mencionando seus autores, métodos, principais achados e limitações.
3. **Identifique lacunas:** Aponte aspectos ainda pouco explorados ou controversos, enfatizando oportunidades para contribuições futuras.
4. **Relacione com seu tema:** Explique como os estudos revisados estão conectados ao objetivo do seu trabalho e de que forma embasam sua discussão.
5. **Use referências de qualidade:** Priorize fontes confiáveis, como artigos científicos, livros e relatórios reconhecidos na área.

Mantenha o texto coeso e evite apenas listar trabalhos; ao invés disso, discuta as contribuições e conexões entre eles para oferecer uma visão abrangente e crítica do estado da arte.

4 Objetivos específicos

A seção de objetivos específicos deve detalhar as metas mais concretas e direcionadas que a pesquisa ou revisão busca alcançar. Para preenchê-la:

1. **Defina objetivos claros e mensuráveis:** Estabeleça metas específicas que podem ser avaliadas ao longo da execução do estudo ou revisão.
2. **Alinhe os objetivos com a questão central:** Certifique-se de que cada objetivo contribui diretamente para responder à pergunta principal da pesquisa.
3. **Divida em sub-objetivos, se necessário:** Caso o tema seja amplo, subdivida os objetivos em partes menores e mais focadas para uma execução mais organizada.
4. **Relacionar com a metodologia:** Indique de que maneira os objetivos serão alcançados, conectando-os às abordagens e técnicas específicas que serão utilizadas.
5. **Estabeleça prazos ou etapas (opcional):** Caso relevante, descreva as etapas ou cronogramas necessários para atingir os objetivos.

A redação deve ser objetiva, utilizando verbos no infinitivo, como "analisar", "identificar", "comparar", para expressar claramente as ações a serem realizadas. Lembre-se de que os objetivos devem ser alcançáveis dentro do escopo da pesquisa.

5 Materiais e métodos

A seção de materiais e métodos descreve de forma detalhada os procedimentos adotados para a realização da pesquisa ou revisão, garantindo a transparência e a reprodutibilidade. Para preenchê-la:

1. **Descreva os materiais utilizados:** Liste os materiais, instrumentos ou recursos necessários para a execução da pesquisa, como equipamentos, softwares, reagentes, entre outros. Inclua informações detalhadas sobre as características e especificações, quando relevante.
2. **Explique a metodologia de forma clara:** Detalhe os métodos e procedimentos adotados para coletar, analisar e interpretar os dados ou informações, incluindo abordagens qualitativas ou quantitativas.
3. **Justifique as escolhas metodológicas:** Explique por que determinadas técnicas ou abordagens foram escolhidas, levando em consideração a natureza do estudo e os objetivos da pesquisa.
4. **Descreva a amostra ou população:** Caso relevante, forneça detalhes sobre a amostra ou população estudada, como tamanho, características demográficas ou critérios de inclusão/exclusão.
5. **Apresente os instrumentos de coleta e análise:** Caso a pesquisa envolva questionários, entrevistas ou outros instrumentos, descreva-os de forma detalhada, explicando como foram aplicados e analisados.
6. **Inclua informações sobre o procedimento e cronograma:** Descreva como a pesquisa foi conduzida ao longo do tempo, incluindo os principais estágios e cronogramas, se aplicável.

Esta seção deve ser o mais detalhada possível, de forma a permitir que outros pesquisadores possam replicar o estudo com base nas informações fornecidas. Lembre-se de que a clareza e a precisão são essenciais nesta parte do trabalho.

6 Resultados esperados

A seção de resultados deve apresentar de forma objetiva e clara os dados ou informações obtidas na pesquisa, sem interpretações ou conclusões. Para preenchê-la:

1. **Apresente os dados de forma clara:** Organize os resultados de maneira estruturada, utilizando tabelas, gráficos ou figuras para facilitar a compreensão. Certifique-se de que cada dado apresentado esteja acompanhado de uma legenda ou descrição explicativa.
2. **Use medidas adequadas de resumo:** Caso necessário, inclua estatísticas descritivas, como médias, desvios padrão, frequências ou outros indicadores relevantes para a análise dos dados.
3. **Relate os resultados principais:** Destaque os achados mais significativos de forma objetiva, sem incluir interpretações ou análises, que devem ser deixadas para a seção de Discussão.
4. **Organize os resultados de forma lógica:** Se os resultados envolverem diferentes grupos, condições ou variáveis, apresente-os de maneira sequencial e lógica, para facilitar a comparação e análise.
5. **Indique os métodos de análise utilizados:** Caso utilize técnicas estatísticas ou outros métodos de análise, descreva brevemente os procedimentos empregados, garantindo a transparência dos resultados.

Evite inserir interpretações ou discussões nesta seção; o objetivo é apresentar os dados de forma clara e objetiva, permitindo que o leitor forme suas próprias conclusões.

7 Cronograma de atividades do TCC02

F.0: Título da Fase 0
Breve descrição da fase 0
Atividades planejadas para a fase 0
A.0.1 Atividade 01 A.0.2 Atividades 02
Resultados esperados para a fase 0
Descrição dos resultados esperados para a fase 0. Esses resultados demarcam o fim da fase.
F.0: Título da Fase 1
Breve descrição da fase 0
Atividades planejadas para a fase 1
A.1.1 Atividade 01 A.1.2 Atividades 02
Resultados esperados para a fase 1
Descrição dos resultados esperados para a fase 0. Esses resultados demarcam o fim da fase.

2025					
01	02	03	04	05	06
		F.0: A.0.1			
				F.0: A.0.2	

Referências Bibliográficas