



UNIFEI

Maximizando a eficiência de RAG: uma análise comparativa de métodos
RAG

**Revisão bibliográfica e plano de trabalho enviado
para análise e deliberação da banca de TCC01**

Aluno(s):

Afonso Henriques Massunari – ECO

Ryan Alves Mazzeu - ECO

Orientação:

Carlos Henrique Valério de Moraes - Orientador

junho de 2026

Sumário

1	Introdução	2
2	Motivação	3
3	Revisão bibliográfica	4
3.1	Limitações dos LLMs e a consolidação do RAG	4
3.2	Métodos de manipulação de contexto e o compromisso de eficiência	4
3.3	Estratégias avançadas de recuperação	4
3.4	Contexto longo, estruturação documental e fragmentação	5
3.5	Infraestrutura de armazenamento e recuperação vetorial	5
3.6	Aplicações de domínio específico	5
3.7	Lacunas identificadas	5
4	Objetivos específicos	6
5	Materiais e métodos	7
6	Resultados esperados	8
7	Cronograma de atividades do TCC02	9

1 Introdução

O avanço contemporâneo dos Modelos de Linguagem de Grande Porte (LLMs) expandiu significativamente as fronteiras da Inteligência Artificial, permitindo a execução de tarefas complexas que variam desde a análise de documentos legais até a geração automatizada de códigos de programação. Contudo, apesar do notável desempenho em tarefas estritamente textuais, os LLMs tradicionais enfrentam limitações severas ao lidar com conhecimentos em constante evolução e dados de domínios específicos, frequentemente resultando em respostas alucinatórias ou desatualizadas. Para mitigar esse problema, a arquitetura de Geração Aumentada de Recuperação (RAG) consolidou-se como uma abordagem não-paramétrica indispensável [1], integrando a capacidade gerativa dos modelos à precisão de bases de conhecimento externas indexadas em bancos de dados vetoriais [2]. No entanto, a implementação prática de novos sistemas RAG ainda introduz desafios complexos de engenharia e infraestrutura que exigem investigação, tais como restrições de tempo de execução, saturação de limites de tokens e o consumo elevado de recursos de hardware.

Diante desse cenário, este trabalho propõe-se a realizar uma análise investigativa das metodologias de otimização aplicadas aos processos de RAG. O escopo delineado para a pesquisa abrangerá uma avaliação comparativa detalhada entre abordagens clássicas e avançadas de recuperação — especificamente os métodos Stuff, Refine, Map Reduce, Map Re-rank, Query Step-Down e Reciprocal RAG [3]. Pretende-se analisar os impactos diretos que a escolha dessas técnicas exerce sobre três pilares fundamentais de desempenho no ecossistema de inteligência artificial: a acurácia semântica das respostas geradas (mensurada por métricas de similaridade de cosseno), a eficiência no consumo de tokens e a utilização de infraestrutura de hardware, envolvendo o consumo de CPU, memória RAM e tempo de resposta. Esse recorte metodológico justifica-se pela necessidade premente de compreender os múltiplos tradeoffs técnicos existentes entre a precisão da resposta entregue ao usuário e os custos operacionais de computação em nuvem em ambientes de alta escala.

O objetivo principal desta proposta de pesquisa é projetar e sintetizar um panorama analítico sobre a eficiência de arquiteturas RAG, buscando identificar as melhores configurações de componentes para diferentes cenários de aplicação. Especificamente, o trabalho investigará como a escolha combinada de bancos de dados vetoriais (como ChromaDB, FAISS e Pinecone), modelos de embedding (como Bge-en-small, Text-embedding-v3-large e Cohere-en-v3) e filtros de compressão contextual (limiares de similaridade e redundância) afetam o equilíbrio entre o gerenciamento de recursos e a qualidade do texto final gerado pelo modelo. Para dar sustentação teórica e metodológica a este projeto, a pesquisa tomará como base empírica e ponto de partida os dados e parâmetros discutidos na literatura recente sobre otimização sistemática por varredura em grade (grid-search), o que inclui as metodologias de testes cruzados em múltiplos domínios textuais, tais como relatórios financeiros corporativos (SEC 10Q), documentação científica (Llama2 ArXiv) e exames da área médica (MedQA) [4].

A revisão de literatura que fundamentará este projeto terá como foco publicações recentes indexadas em bases de prestígio acadêmico internacional, com ênfase em termos-chave estruturantes como Retrieval-Augmented Generation, Vector Databases, Contextual Compression e Embedding Models. Por fim, a proposta de desenvolvimento deste estudo está estruturada de forma a aprofundar essas discussões técnicas nas seções subsequentes. O plano de trabalho prevê inicialmente a apresentação do referencial teórico acerca do funcionamento matemático da similaridade de cosseno e dos algoritmos de busca por vizinhos mais próximos. Em seguida, detalha-se o cronograma e a metodologia planejada para a análise comparativa dos indicadores de desempenho de acurácia, consumo de hardware e eficácia dos filtros de compressão. Por fim, serão delineados os resultados esperados e as contribuições pretendidas para o desenvolvimento de aplicações práticas baseadas nas conclusões a serem estabelecidas pelo estudo.

2 Motivação

A justificativa para a realização deste estudo fundamenta-se nos severos desafios de engenharia e infraestrutura impostos pela operação de Modelos de Linguagem de Grande Porte (LLMs) em cenários de produção. Embora o surgimento da arquitetura de Geração Aumentada de Recuperação (RAG) tenha mitigado o problema das alucinações ao fornecer dados de fontes externas em tempo real, sua viabilidade comercial enfrenta uma barreira crítica: a ineficiência no consumo de recursos. À medida que o volume de dados organizacionais cresce, o processo tradicional de recuperar e injetar fragmentos extensos de texto diretamente nos prompts resulta em um aumento exponencial no consumo de tokens, saturação da janela de contexto e elevação dos custos com computação em nuvem. No ecossistema tecnológico atual, há uma lacuna evidente na compreensão de como as diferentes abordagens de manipulação desse contexto — como os métodos Stuff, Refine, Map Reduce, Map Re-rank, Query Step-Down e Reciprocal RAG [3] — afetam diretamente o uso de hardware, especificamente o consumo de CPU, memória RAM e tempo de resposta (latência). Investigar esses parâmetros é fundamental para a Ciência da Computação e Engenharia de Software, pois o sucesso de aplicações de inteligência artificial depende intrinsecamente da habilidade de equilibrar a acurácia da resposta gerada com a sustentabilidade financeira e computacional da infraestrutura.

A relevância deste tema acentua-se diante das tendências de mercado e dos recentes avanços científicos na área de Processamento de Linguagem Natural (PLN). Estudos recentes de otimização sistemática por varredura em grade (grid-search), que chegam a realizar mais de 23.000 iterações de testes cruzados em domínios complexos (como relatórios financeiros e dados médicos) [4], apontam que a escolha cega de componentes pode inviabilizar projetos de IA. A compressão de contexto e o uso estratégico de filtros de similaridade surgem não apenas como alternativas de refinamento, mas como requisitos obrigatórios para reduzir o tráfego desnecessário de dados. Consequentemente, a motivação para este trabalho decorre da necessidade prática de mapear esses cenários e propor um guia metodológico claro. Ao correlacionar a eficiência algorítmica com o impacto físico no hardware, este estudo conecta-se a um objetivo muito maior: democratizar e viabilizar a implementação de sistemas RAG robustos e escaláveis, reduzindo o desperdício computacional e otimizando a entrega de valor tecnológico tanto no ambiente acadêmico quanto na indústria de software.

3 Revisão bibliográfica

A literatura recente sobre Geração Aumentada de Recuperação (RAG) organiza-se em torno de um problema central: como integrar conhecimento externo a Modelos de Linguagem de Grande Porte (LLMs) de forma simultaneamente precisa e computacionalmente sustentável. Para situar a contribuição deste trabalho, esta revisão estrutura-se em cinco eixos temáticos: (i) a motivação da arquitetura RAG frente às limitações dos LLMs; (ii) os métodos de manipulação de contexto e seus compromissos de eficiência; (iii) as estratégias avançadas de recuperação; (iv) a infraestrutura de bancos de dados vetoriais; e (v) as aplicações de domínio específico. Ao fim, discutem-se as lacunas que justificam a investigação proposta.

3.1 Limitações dos LLMs e a consolidação do RAG

Os LLMs, apesar de seu desempenho notável, são propensos a alucinações e à desatualização do conhecimento paramétrico. O levantamento de Andriopoulos e Pouwelse [1] sistematiza as estratégias de aumento de conhecimento como principal caminho para prevenir alucinações, posicionando o RAG como uma alternativa não-paramétrica de baixo custo de atualização frente ao retreinamento contínuo dos modelos. Essa fragilidade também se manifesta na própria engenharia dos sistemas: Barnett et al. [5], a partir de três estudos de caso em domínios distintos (pesquisa, educação e biomedicina), catalogam sete pontos de falha recorrentes na construção de pipelines RAG, concluindo que a robustez desses sistemas é construída empiricamente durante a operação e não estabelecida em projeto. Em conjunto, esses trabalhos delimitam o problema que motiva a área, mas tratam predominantemente da acurácia e da confiabilidade, sem quantificar de forma sistemática o custo de hardware envolvido.

3.2 Métodos de manipulação de contexto e o compromisso de eficiência

O núcleo metodológico deste estudo apoia-se na caracterização dos métodos de injeção de contexto. Topsakal e Akinci [3] descrevem, em nível arquitetural, o funcionamento dos quatro fluxos fundamentais disponíveis em frameworks como o LangChain — Stuff, Map Reduce, Refine e Map Re-rank —, evidenciando trade-offs estruturais como o gargalo de paralelização do Refine e o elevado volume de chamadas do Map Reduce. Trata-se, contudo, de um trabalho descritivo, sem medições empíricas. Essa lacuna quantitativa é preenchida por Şakar e Emekci [4], que conduzem uma busca em grade de 23.625 iterações comparando seis métodos (Stuff, Refine, Map Reduce, Map Re-rank, Query Step-Down e Reciprocal RAG) e filtros de compressão contextual ao longo de múltiplos bancos vetoriais, modelos de embedding e LLMs. Os autores demonstram que não existe arquitetura universalmente ótima: enquanto o Reciprocal RAG atinge a maior similaridade, o método Stuff é 38,9% mais rápido e consome 70,5% menos tokens, e a compressão contextual reduz o uso de recursos ao custo de degradar a similaridade quando seus limiares não são calibrados por domínio. Esse trabalho constitui a principal âncora teórica e metodológica da presente pesquisa.

3.3 Estratégias avançadas de recuperação

Para além da simples injeção dos fragmentos recuperados, parte expressiva da literatura busca refinar a etapa de recuperação. Ma et al. [6] propõem o paradigma *Rewrite-Retrieve-Read*, no qual um reescritor treinado por aprendizado por reforço adapta a consulta do usuário antes da busca, mitigando a lacuna entre a pergunta e o conhecimento indexado. Em direção complementar, Rackauckas [7] combina a geração de múltiplas consultas com a fusão recíproca de postos (*reciprocal rank fusion*) no método RAG-Fusion, ampliando a abrangência das respostas, embora ao risco de desvio temático quando as consultas geradas se distan-

ciam da intenção original. Essas abordagens elevam a qualidade da recuperação, mas introduzem chamadas adicionais ao LLM, reforçando a tensão entre acurácia e custo que este trabalho pretende mensurar.

3.4 Contexto longo, estruturação documental e fragmentação

A forma como o conteúdo recuperado é apresentado ao modelo também impacta o desempenho. Liu et al. [8] demonstram empiricamente o fenômeno *lost in the middle*: o desempenho dos LLMs degrada-se quando a informação relevante se encontra no meio de contextos longos, o que questiona a estratégia de simplesmente acumular fragmentos. Como resposta, Nair et al. [9] exploram a estrutura de discurso de documentos longos para construir representações condensadas, preservando 99,6% do desempenho do melhor método zero-shot enquanto processam apenas 26% dos tokens. No nível mais elementar, Schwaber-Cohen e Patel [10] discutem estratégias de fragmentação (*chunking*) e seu efeito sobre a relevância da recuperação. Esses estudos reforçam que a eficiência em tokens — objeto deste trabalho — depende não apenas do método de injeção, mas também da estruturação prévia do contexto.

3.5 Infraestrutura de armazenamento e recuperação vetorial

O desempenho de um pipeline RAG é igualmente condicionado pela camada de armazenamento. O levantamento abrangente de Ma et al. [2] sistematiza técnicas de armazenamento e recuperação em bancos de dados vetoriais, bem como seus desafios de escalabilidade, fornecendo a base conceitual para a comparação entre soluções como ChromaDB, FAISS e Pinecone prevista nos objetivos deste estudo. A escolha desses componentes, como apontado por Şakar e Emekci [4], tem impacto direto sobre o consumo de CPU e a latência, conectando a infraestrutura de recuperação às métricas de hardware aqui investigadas.

3.6 Aplicações de domínio específico

Por fim, a literatura evidencia o potencial do RAG em domínios verticais de alta complexidade. Cui et al. [11] apresentam o Chatlaw, assistente jurídico multiagente que combina recuperação de conhecimento legal com uma arquitetura de mistura de especialistas para reduzir alucinações em um domínio sensível. No setor financeiro, Gupta [12] utiliza LLMs para analisar relatórios anuais extensos e derivar estratégias de investimento, ilustrando o desafio de processar documentos longos e ricos em jargão. Esses casos confirmam a relevância prática da otimização de RAG e dialogam com os domínios financeiro e técnico empregados como base empírica nesta pesquisa.

3.7 Lacunas identificadas

A análise conjunta revela que a literatura avançou significativamente na acurácia [6, 7], na confiabilidade [1, 5] e na compreensão das limitações de contexto [8, 9]. Entretanto, a correlação sistemática entre a escolha do método RAG e o impacto físico sobre o hardware — consumo de CPU, memória RAM e tempo de resposta — permanece pouco explorada, sendo tratada de forma agregada apenas por Şakar e Emekci [4] em escala computacional incompatível com ambientes restritos. É justamente nessa lacuna — mapear de forma reproduzível os trade-offs de eficiência de hardware entre os métodos de RAG — que este trabalho se insere.

4 Objetivos específicos

O objetivo geral desta pesquisa consiste em analisar o impacto de diferentes arquiteturas e métodos de Geração Aumentada de Recuperação (RAG) sobre a eficiência de uso de hardware, consumo de tokens e acurácia semântica, a fim de propor diretrizes técnicas para a otimização de pipelines de inteligência artificial aplicados a bases de dados complexas.

Para alcançar o propósito geral e responder à problemática de infraestrutura e custos computacionais que envolvem esses sistemas, estabelecem-se os seguintes objetivos específicos:

1. **Mapear e catalogar** as abordagens clássicas e avançadas de recuperação de contexto, com ênfase detalhada no funcionamento algorítmico dos métodos Stuff, Refine, Map Reduce, Map Re-rank, Query Step-Down e Reciprocal RAG [3].
2. **Avaliar e comparar** o desempenho de diferentes bancos de dados vetoriais (como ChromaDB, FAISS e Pinecone) em simulações cruzadas, mensurando de forma quantitativa métricas físicas de infraestrutura como o uso de CPU, consumo de memória RAM e latência de tempo de execução.
3. **Mensurar** a variação da acurácia semântica das respostas geradas a partir de métricas de similaridade de cosseno, correlacionando a precisão do texto final com a eficácia de diferentes modelos de embedding (incluindo Bge-en-small, Text-embedding-v3-large e Cohere-en-v3).
4. **Investigar** a influência e a viabilidade da aplicação de filtros de compressão contextual (focados em limites de similaridade e redundância) sobre a contenção e redução do volume total de tokens trafegados por requisição, analisando o tradeoff gerado entre a economia financeira de processamento e a eventual perda de qualidade informacional.
5. **Validar** as hipóteses e configurações propostas por meio de uma abordagem de testes sistemáticos baseada em varredura em grade (grid-search), executando os experimentos propostos sobre conjuntos de dados de múltiplos domínios públicos de alta complexidade (como relatórios SEC 10Q, Llama2 ArXiv e MedQA) [4].
6. **Sintetizar e propor** um arcabouço de boas práticas ou guia de tomada de decisão para engenheiros de software e pesquisadores, indicando as melhores combinações de componentes RAG para restrições específicas de custo, tempo ou hardware.

5 Materiais e métodos

A seção de materiais e métodos descreve de forma detalhada os procedimentos adotados para a realização da pesquisa ou revisão, garantindo a transparência e a reprodutibilidade. Para preenchê-la:

1. **Descreva os materiais utilizados:** Liste os materiais, instrumentos ou recursos necessários para a execução da pesquisa, como equipamentos, softwares, reagentes, entre outros. Inclua informações detalhadas sobre as características e especificações, quando relevante.
2. **Explique a metodologia de forma clara:** Detalhe os métodos e procedimentos adotados para coletar, analisar e interpretar os dados ou informações, incluindo abordagens qualitativas ou quantitativas.
3. **Justifique as escolhas metodológicas:** Explique por que determinadas técnicas ou abordagens foram escolhidas, levando em consideração a natureza do estudo e os objetivos da pesquisa.
4. **Descreva a amostra ou população:** Caso relevante, forneça detalhes sobre a amostra ou população estudada, como tamanho, características demográficas ou critérios de inclusão/exclusão.
5. **Apresente os instrumentos de coleta e análise:** Caso a pesquisa envolva questionários, entrevistas ou outros instrumentos, descreva-os de forma detalhada, explicando como foram aplicados e analisados.
6. **Inclua informações sobre o procedimento e cronograma:** Descreva como a pesquisa foi conduzida ao longo do tempo, incluindo os principais estágios e cronogramas, se aplicável.

Esta seção deve ser o mais detalhada possível, de forma a permitir que outros pesquisadores possam replicar o estudo com base nas informações fornecidas. Lembre-se de que a clareza e a precisão são essenciais nesta parte do trabalho.

6 Resultados esperados

A seção de resultados deve apresentar de forma objetiva e clara os dados ou informações obtidas na pesquisa, sem interpretações ou conclusões. Para preenchê-la:

1. **Apresente os dados de forma clara:** Organize os resultados de maneira estruturada, utilizando tabelas, gráficos ou figuras para facilitar a compreensão. Certifique-se de que cada dado apresentado esteja acompanhado de uma legenda ou descrição explicativa.
2. **Use medidas adequadas de resumo:** Caso necessário, inclua estatísticas descritivas, como médias, desvios padrão, frequências ou outros indicadores relevantes para a análise dos dados.
3. **Relate os resultados principais:** Destaque os achados mais significativos de forma objetiva, sem incluir interpretações ou análises, que devem ser deixadas para a seção de Discussão.
4. **Organize os resultados de forma lógica:** Se os resultados envolverem diferentes grupos, condições ou variáveis, apresente-os de maneira sequencial e lógica, para facilitar a comparação e análise.
5. **Indique os métodos de análise utilizados:** Caso utilize técnicas estatísticas ou outros métodos de análise, descreva brevemente os procedimentos empregados, garantindo a transparência dos resultados.

Evite inserir interpretações ou discussões nesta seção; o objetivo é apresentar os dados de forma clara e objetiva, permitindo que o leitor forme suas próprias conclusões.

7 Cronograma de atividades do TCC02

F.0: Título da Fase 0
Breve descrição da fase 0
Atividades planejadas para a fase 0
A.0.1 Atividade 01 A.0.2 Atividades 02
Resultados esperados para a fase 0
Descrição dos resultados esperados para a fase 0. Esses resultados demarcam o fim da fase.
F.0: Título da Fase 1
Breve descrição da fase 0
Atividades planejadas para a fase 1
A.1.1 Atividade 01 A.1.2 Atividades 02
Resultados esperados para a fase 1
Descrição dos resultados esperados para a fase 0. Esses resultados demarcam o fim da fase.

2025					
01	02	03	04	05	06
		F.0: A.0.1			
				F.0: A.0.2	

Referências Bibliográficas

[1] K. Andriopoulos and J. Pouwelse, "Augmenting LLMs with knowledge: A survey on hallucination prevention," arXiv preprint arXiv:2309.16459, 2023.

[2] L. Ma, R. Zhang, Y. Han, S. Yu, Z. Wang, Z. Ning, J. Zhang, P. Xu, P. Li, Z. Qiao, W. Ju, C. Chen, D. Wang, K. Liu, P. Wang, P. Wang, Y. Fu, C. Liu, Y. Zhou, and C.-T. Lu, "A comprehensive survey on vector database: Storage and retrieval technique, challenge," arXiv preprint arXiv:2310.11703, 2024.

[3] O. Topsakal and T. C. Akinci, "Creating large language model applications utilizing LangChain: A primer on developing LLM apps fast," in *Proceedings of the 5th International Conference on Applied Engineering and Natural Sciences (ICAENS)*, Konya, Turkey, 2023.

[4] T. Şakar and H. Emekci, "Maximizing RAG efficiency: A comparative analysis of RAG methods," *Natural Language Processing*, vol. 31, pp. 1–25, 2025.

[5] S. Barnett, S. Kurniawan, S. Thudumu, Z. Brannelly, and M. Abdelrazek, "Seven failure points when engineering a retrieval augmented generation system," arXiv preprint arXiv:2401.05856, 2024.

- [6] X. Ma, Y. Gong, P. He, H. Zhao, and N. Duan, "Query rewriting for retrieval-augmented large language models," arXiv preprint arXiv:2305.14283, 2023.
- [7] Z. Rackauckas, "RAG-Fusion: A new take on retrieval-augmented generation," arXiv preprint arXiv:2402.03367, 2024.
- [8] N. F. Liu, K. Lin, J. Hewitt, A. Paranjape, M. Bevilacqua, F. Petroni, and P. Liang, "Lost in the middle: How language models use long contexts," arXiv preprint arXiv:2307.03172, 2023.
- [9] I. Nair, S. Somasundaram, A. Saxena, and K. Goswami, "Drilling down into the discourse structure with LLMs for long document question answering," arXiv preprint arXiv:2311.13565, 2023.
- [10] R. Schwaber-Cohen and A. Patel, "Chunking strategies for LLM applications," Pinecone Learning Center, 2025, disponível em: <https://www.pinecone.io/learn/chunking-strategies/>.
- [11] J. Cui, M. Ning, Z. Li, H. Li, Y. Yan, B. Chen, B. Ling, Y. Tian, and L. Yuan, "Chatlaw: A multi-agent legal assistant based on a role-aligned mixture-of-experts architecture," arXiv preprint arXiv:2306.16092, 2023.
- [12] U. Gupta, "GPT-InvestAR: Enhancing stock investment strategies through annual report analysis with large language models," arXiv preprint arXiv:2309.03079, 2023.