Maximizando a eficiência de RAG:

uma análise comparativa de métodos RAG

Trabalho de conclusão de curso

Afonso Henriques Massunari | Ryan Alves Mazzeu
Orientador: Carlos Henrique Valerio de Moraes

UNIFEI - Novembro 2026

INTRODUÇÃO

O que são LLMs?

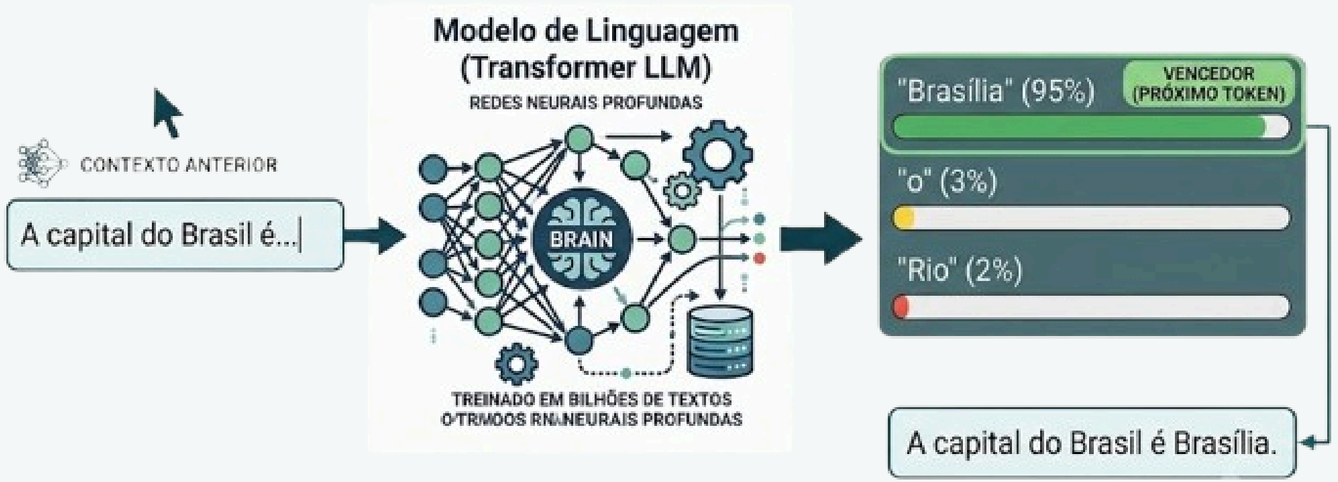
Os **Large Language Models (LLMs)** são modelos de Inteligência Artificial treinados em volumes massivos de texto para compreender e gerar linguagem humana de forma natural.



INTRODUÇÃO

Como funciona o LLM?

No fundo, um **LLM** funciona como um corretor ortográfico ultra-sofisticado: a partir de um prompt, ele calcula a **probabilidade estatística** para **prever** e **gerar a próxima palavra.**



- **Tokenização e Vetorização: O modelo não lê texto. As palavras são quebradas em partes menores (tokens) e convertidas em matrizes matemáticas.**
- **Predição Estatística: Um LLM utiliza estatística para prever qual é o próximo token mais provável com base no contexto**

INTRODUÇÃO

Os problemas do LLM

1

Alucinação

Inventa com a mesma fluência com que acerta

2

Conhecimento parado

O que veio depois do treinamento não existe para ele

3

Documentos privados

Normas de uma universidade, relatórios de uma empresa

4

Retreinar é caro e lento

E teria que ser repetido a cada documento novo

INTRODUÇÃO

Exemplo de um problema real de LLM

Sete modelos receberam uma pergunta sobre um regulamento que nunca viram. Veja o que cada um fez.

INSTRUÇÃO AO MODELO

Responda à pergunta. **Se não souber, diga que não sabe.** Responda em português.

PERGUNTA

Qual o objetivo do período letivo especial?

RESPOSTA NO DOCUMENTO

Destina-se ao oferecimento de disciplinas obrigatórias e optativas, a critério do Colegiado de Curso.

3 de 7

Respondeu sem saber

gpt-4o-mini · GPT-6 Luna · DeepSeek V4 Pro

Afirmaram com segurança: serve para “recuperar disciplinas”.

2 de 7

Disse que não sabe e chutou

Qwen3.5-9B · Claude Sonnet 5

Admitiram a dúvida e chutaram: “recuperar notas ou disciplinas”.

2 de 7

Só disse que não sabe

Claude Haiku 5.5 · GPT-6 Sol

Seguiram a instrução e perguntaram a qual instituição se refere.

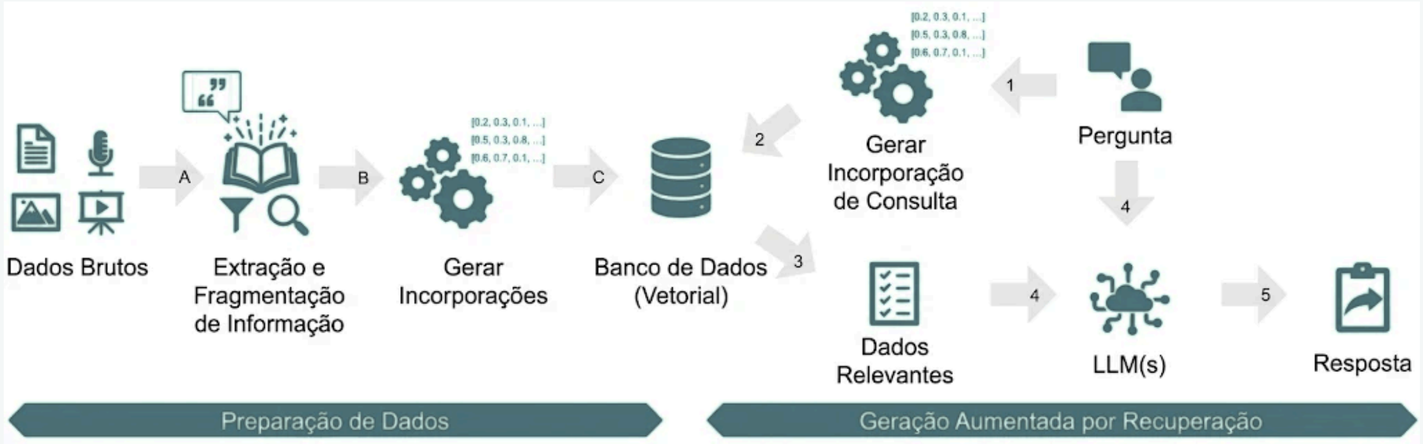
Sem o documento, o LLM preenche a lacuna com respostas plausíveis, e nenhum chute acertou.

INTRODUÇÃO

O que é RAG?

Retrieval-Augmented Generation

É uma arquitetura de IA que conecta o LLM a fontes de dados externas para fundamentar suas respostas em fatos reais, superando as limitações do modelo isolado.



- **Busca (Retrieval): Quando você faz uma pergunta, o sistema primeiro busca em bancos de dados internos, documentos ou internet por informações atualizadas.**
- **Geração (Generation): O LLM recebe a sua pergunta junto com os dados recuperados e usa essas evidências para formular uma resposta precisa.**
- **Vantagem Estratégica: Minimiza as alucinações, consulta dados e permite o uso de IA em bases privadas corporativas sem a necessidade de retreinamento.**

INTRODUÇÃO

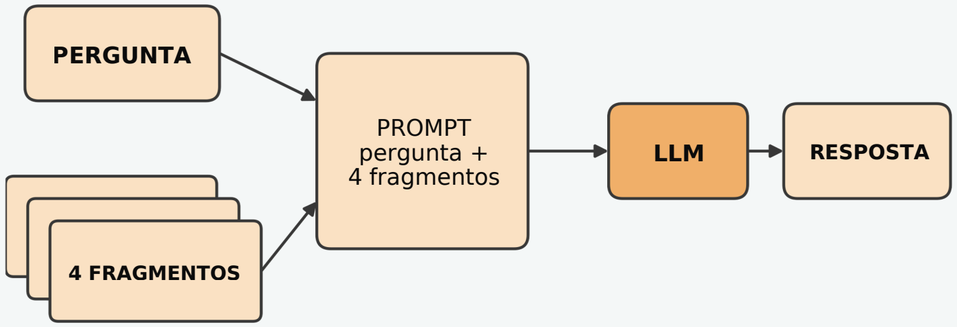
Pipeline de um RAG



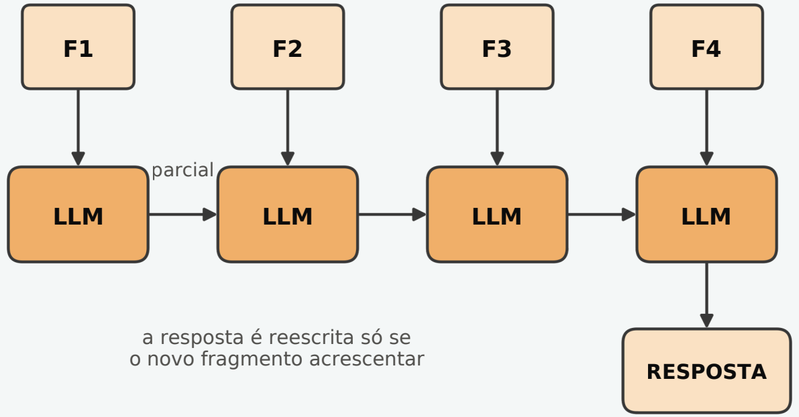
A busca semântica compara o vetor da pergunta com os vetores guardados no banco.

Metodos de RAG

Stuff (1 chamada)

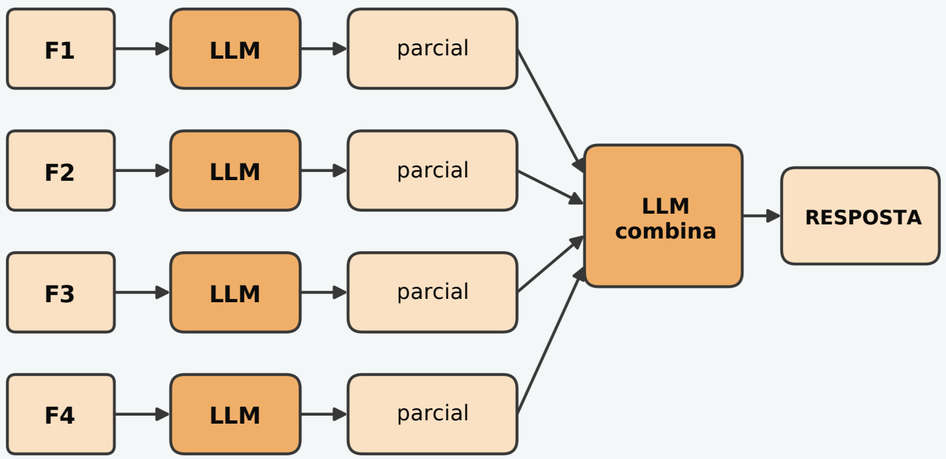


Refine (4 chamadas, em sequência)

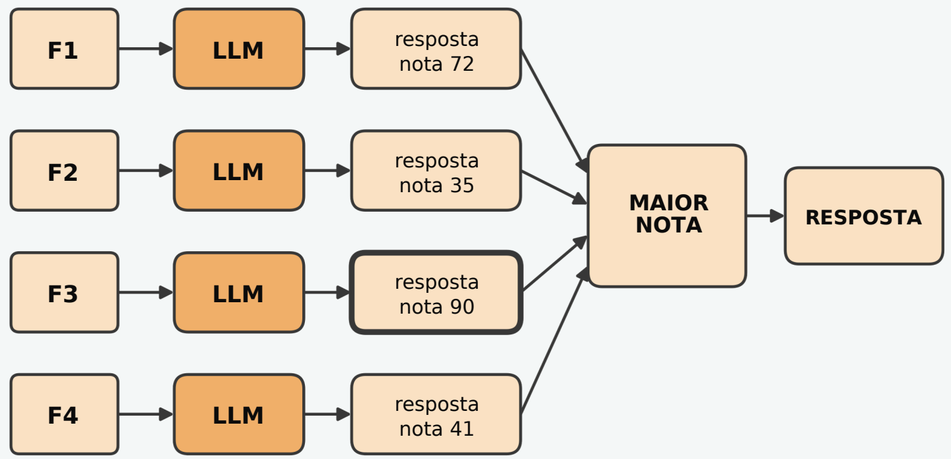


Metodos de RAG

Map-Reduce (5 chamadas)

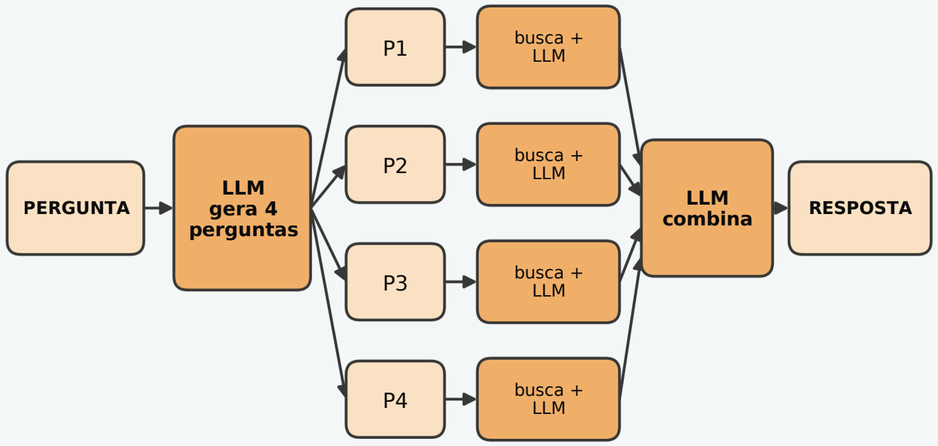


Map-Rerank (4 chamadas)

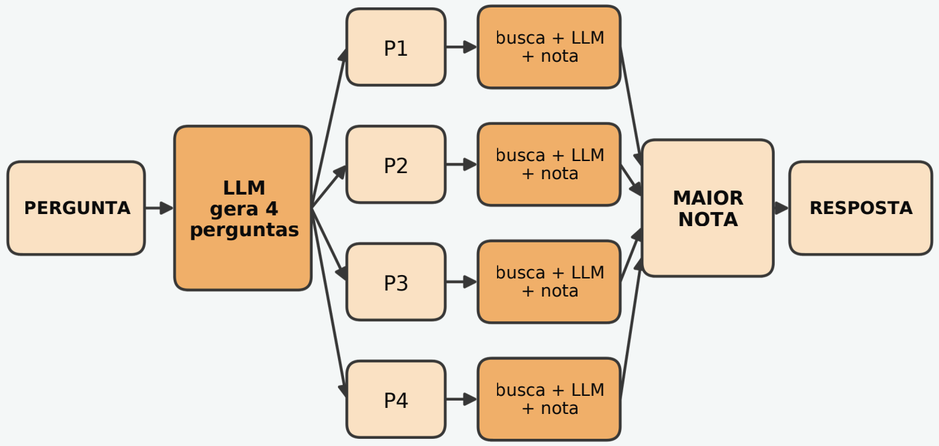


Metodos de RAG

Query Step-Down (6 chamadas)



Reciprocal (5 chamadas)



Metodos de RAG

Família	Método	Chamadas	Como usa os fragmentos
Tudo de uma vez	**Stuff**	1	Junta os 4 fragmentos e a pergunta em um único prompt
Um fragmento por vez	**Refine**	4	Responde com o 1º e refina a resposta a cada fragmento seguinte
	Map-Reduce	5	Uma resposta parcial por fragmento; combina as parciais no final
	Map-Rerank	4	Uma resposta por fragmento, com nota de confiança; fica com a maior
Reformula a pergunta	**Query Step-Down**	6	Gera 4 perguntas mais específicas, busca para cada uma e combina as respostas
	Reciprocal RAG	5	Gera as mesmas 4 perguntas e fica só com a resposta mais confiante

Chamadas ao LLM com k = 4: cada método muda o custo e o tempo, e a forma de usar o contexto.

INTRODUÇÃO

Problemática e Motivação

Um pipeline de RAG envolve escolhas de engenharia cujo efeito combinado raramente é medido de forma sistemática.

O PROBLEMA

Escolhas de engenharia no pipeline

- Método de injeção
- LLM
- Banco vetorial
- Modelo de embedding

↓

Efeito sobre qualidade · tokens

1. **Quando o RAG acrescenta algo?**
   O ganho depende do domínio e do que o LLM já sabe.
2. **Qual método de injeção usar?**
   Mais chamadas ao LLM custam mais tokens e tempo.
3. **O método certo vale um modelo mais caro?**
   Comparar modelos econômicos e intermediários.

É preciso equilibrar a qualidade da resposta com o custo em tokens, dólares .

Objetivos da pesquisa

Estudo de referência

23.625

configurações testadas por Şakar e Emekci (2025). Lacunas:

- Só similaridade de cosseno
- Sem controle sem RAG
- Resultados agregados entre LLMs
- Só documentos em inglês

QP1 Como os 6 métodos se comparam em qualidade e custo em cada domínio?

QP2 A ordem dos métodos se mantém entre LLMs diferentes?

QP3 Quanto o RAG acrescenta em relação ao LLM sem RAG?

QP4 A busca aproximada do banco vetorial altera os resultados?

METODOLOGIA

Desenho do estudo

Estudo quantitativo e experimental: as mesmas perguntas respondidas por cada método e cada LLM.

7

condições por pergunta

Os 6 métodos de RAG e um controle sem recuperação

3

conjuntos de dados públicos

Docugami (financeiro), MedQA (médico) e FaQuAD (português)

7

LLMs de 4 empresas

5 modelos econômicos e 2 intermediários, 2 deles de pesos abertos

100

perguntas por conjunto

Camada principal; 25 delas na camada de generalização

FIXO EM TODOS OS EXPERIMENTOS

BGE-M3, fragmentos de 1.000 caracteres e k = 4

O QUE VARIA

Só o método de injeção e o LLM, para isolar o efeito de cada um deles

METODOLOGIA

Execução dos testes

Cada método rodou com cada LLM, nos três domínios, sobre as mesmas perguntas.

10.500

Camada principal

5 LLMs × 3 conjuntos × 7 condições × 100 perguntas

+

1.050

Generalização

2 LLMs × 3 conjuntos × 7 condições × 25 perguntas

+

600

Repetições do Stuff

4 LLMs × 3 conjuntos × 25 perguntas × 2 repetições

=

12.150

Execuções no total

Soma das três partes

Variação do modelo

Temperatura 0 onde o modelo aceita. Haiku, Luna, Sonnet e Sol, que não aceitam, rodaram o Stuff 3 vezes para medir a variação.

Ambiente

Out.–nov. de 2026, Python 3.12, notebook i5-12450H com 20 GB de RAM, sem GPU. OpenAI pela API; os demais via OpenRouter.

Registro

Cada execução guardou pergunta, fragmentos, resposta, tokens, tempos, versão do modelo e provedor.

METODOLOGIA

Conjuntos de dados

Públicos **Gabarito feito por terceiros** **Corpus igual ao material de origem**

Conjunto	Domínio	Corpus	Fragmentos	Perguntas (amostra)	Gabarito
Docugami SEC 10-Q	Financeiro, inglês	20 relatórios trimestrais de Apple, Amazon, Intel, Microsoft e NVIDIA	4.463	195 (100)	Resposta escrita com os valores pedidos
MedQA-USMLE	Médico, inglês	18 livros-texto de medicina	121.553	1.273 (100)	Alternativa correta oficial
FaQuAD	Ensino superior, português	249 parágrafos de uma universidade federal e da Wikipédia	318	900 (100)	Trecho do parágrafo

METODOLOGIA

Modelos de LLM utilizados

Modelo	Empresa	Pesos	US$/1M (entrada / saída)	Camada
gpt-4o-mini	OpenAI	Fechados	0,15 / 0,60	Principal: 100 perguntas por conjunto
GPT-6 Luna	OpenAI	Fechados	0,10 / 0,50	Principal
Claude Haiku 5.5	Anthropic	Fechados	0,10 / 0,50	Principal
Qwen3.5-9B	Alibaba	Abertos	0,17 / 0,25	Principal
DeepSeek V4 Pro	DeepSeek	Abertos	0,90 / 1,80	Principal
Claude Sonnet 5	Anthropic	Fechados	2 / 10	Generalização: 25 perguntas por conjunto
GPT-6 Sol	OpenAI	Fechados	2 / 10	Generalização

Raciocínio estendido desligado em todos: o foco é o método, não o quanto o modelo pensa

METODOLOGIA

Embedding e Banco Vetorial

1.000

caracteres por fragmento, com sobreposição de 100

BGE-M3

embedding multilíngue, executado localmente

HNSW

índice do ChromaDB: busca aproximada

k = 4

fragmentos por pergunta, em todos os métodos

Verificação à parte: ChromaDB (HNSW) × FAISS (busca exata)

318 vetores	4.463 vetores	121.553 vetores

METODOLOGIA

Métricas Principais

MedQA	Acurácia: a letra escolhida contra a alternativa oficial
FaQuAD	Cobertura de tokens: fração da resposta de referência presente na gerada
Docugami	Valores do gabarito: fração dos valores em US$ e % na resposta (tolerância de 2%)
Custo e busca	Tokens, US$ · Hit@4, Recall@4 e MRR@10

METODOLOGIA

Métricas complementares RAGAS: um LLM como juiz

LADO DA RESPOSTA

Faithfulness

A resposta se sustenta nos trechos recuperados?

LADO DA RESPOSTA

Answer Relevancy

A resposta trata do que foi perguntado?

LADO DA BUSCA

Context Precision

Os trechos recuperados são relevantes?

LADO DA BUSCA

Context Recall

Os trechos cobrem a resposta de referência?

AUROC

0,70

Juiz validado no RAGBench, em 206 respostas. Moderadamente confiável: as conclusões principais vêm do gabarito. Modelo do juiz: gpt-4o-mini.

METODOLOGIA

Execução e análise estatística

12.150

execuções no total

US$ 20,09

custo nominal de geração

Pareada

todos os métodos respondem às mesmas perguntas

W de Kendall

concordância da ordem dos métodos entre LLMs

Friedman e Wilcoxon com correção de Holm: dizem se um método é de fato melhor que outro

Métodos implementados direto sobre as APIs, com cada chamada registrada