Maximizando a eficiência de RAG:

uma análise comparativa de métodos RAG

Trabalho de conclusão de curso

Afonso Henriques Massunari | Ryan Alves Mazzeu
Orientador: Carlos Henrique Valerio de Moraes

UNIFEI - Novembro 2026

INTRODUÇÃO

O que são LLMs?

DEFINIÇÃO

Large Language Models (LLMs)

Modelos de Inteligência Artificial treinados em volumes massivos de texto para compreender e gerar linguagem humana de forma natural.

Treinados em texto

Entendem linguagem

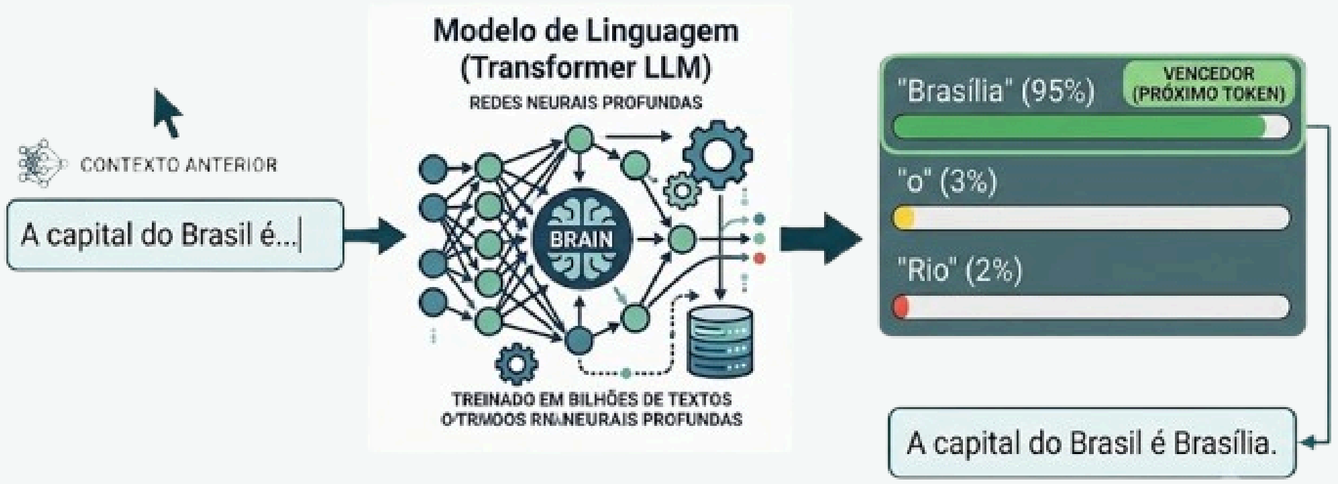
Geram texto natural



INTRODUÇÃO

Como funciona o LLM?

No fundo, um **LLM** funciona como um corretor ortográfico ultra-sofisticado: a partir de um prompt, ele calcula a **probabilidade estatística** para **prever** e **gerar a próxima palavra.**



- **Tokenização e Vetorização: O modelo não lê texto. As palavras são quebradas em partes menores (tokens) e convertidas em matrizes matemáticas.**
- **Predição Estatística: Um LLM utiliza estatística para prever qual é o próximo token mais provável com base no contexto**

INTRODUÇÃO

Os problemas do LLM

1

Alucinação

Inventa com a mesma fluência com que acerta

2

Conhecimento parado

O que veio depois do treinamento não existe para ele

3

Documentos privados

Normas de uma universidade, relatórios de uma empresa

4

Retreinar é caro e lento

E teria que ser repetido a cada documento novo

INTRODUÇÃO

Exemplo de um problema real de LLM

Sete modelos receberam uma pergunta sobre um regulamento que nunca viram. Veja o que cada um fez.

INSTRUÇÃO AO MODELO

Responda à pergunta. **Se não souber, diga que não sabe.** Responda em português.

PERGUNTA

Qual o objetivo do período letivo especial?

RESPOSTA NO DOCUMENTO

Destina-se ao oferecimento de disciplinas obrigatórias e optativas, a critério do Colegiado de Curso.

3 de 7

Respondeu sem saber

gpt-4o-mini · GPT-6 Luna · DeepSeek V4 Pro

Afirmaram com segurança: serve para “recuperar disciplinas”.

2 de 7

Disse que não sabe e chutou

Qwen3.5-9B · Claude Sonnet 5

Admitiram a dúvida e chutaram: “recuperar notas ou disciplinas”.

2 de 7

Só disse que não sabe

Claude Haiku 5.5 · GPT-6 Sol

Seguiram a instrução e perguntaram a qual instituição se refere.

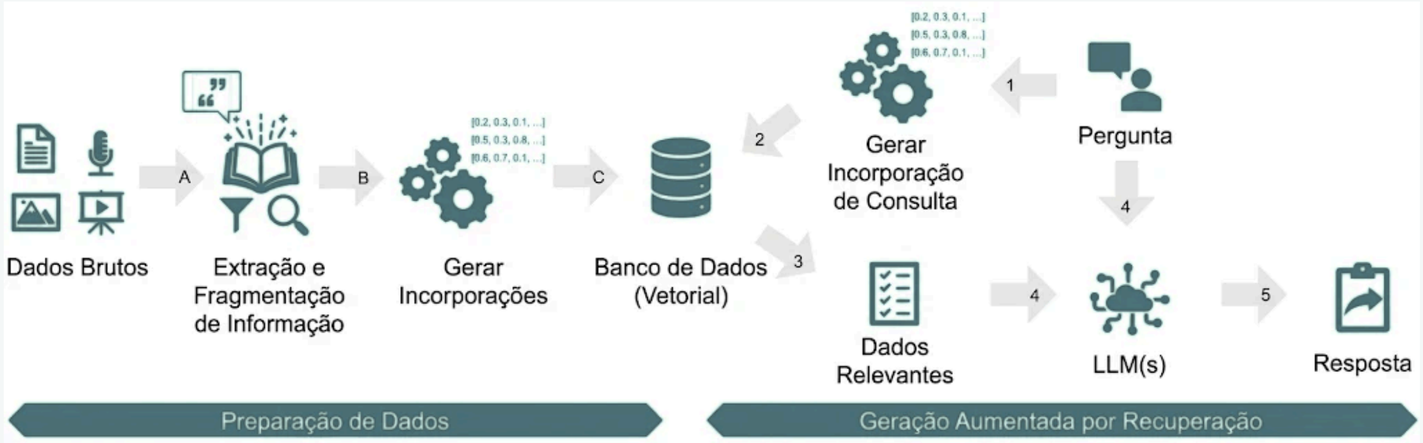
Sem o documento, o LLM preenche a lacuna com respostas plausíveis, e nenhum chute acertou.

INTRODUÇÃO

O que é RAG?

Retrieval-Augmented Generation

É uma arquitetura de IA que conecta o LLM a fontes de dados externas para fundamentar suas respostas em fatos reais, superando as limitações do modelo isolado.



- **Busca (Retrieval): Quando você faz uma pergunta, o sistema primeiro busca em bancos de dados internos, documentos ou internet por informações atualizadas.**
- **Geração (Generation): O LLM recebe a sua pergunta junto com os dados recuperados e usa essas evidências para formular uma resposta precisa.**
- **Vantagem Estratégica: Minimiza as alucinações, consulta dados e permite o uso de IA em bases privadas corporativas sem a necessidade de retreinamento.**

INTRODUÇÃO

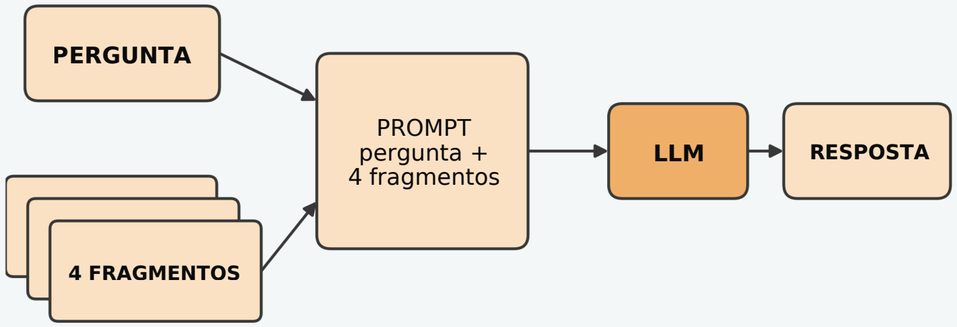
Pipeline de um RAG



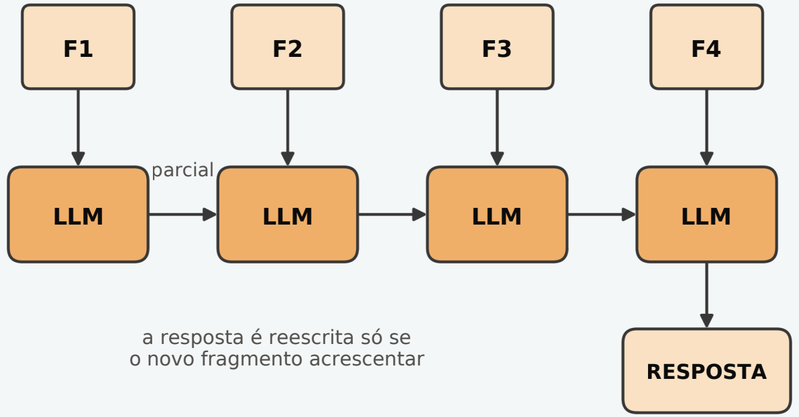
A busca semântica compara o vetor da pergunta com os vetores guardados no banco.

Metodos de RAG

Stuff (1 chamada)

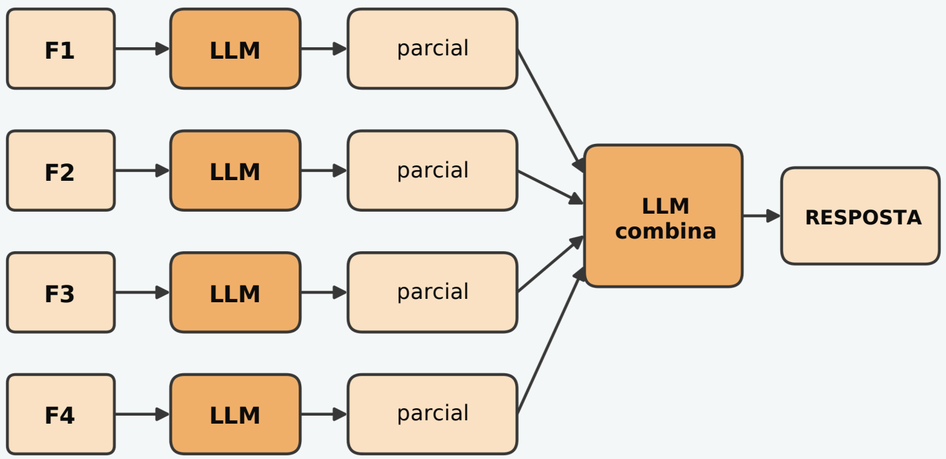


Refine (4 chamadas, em sequência)

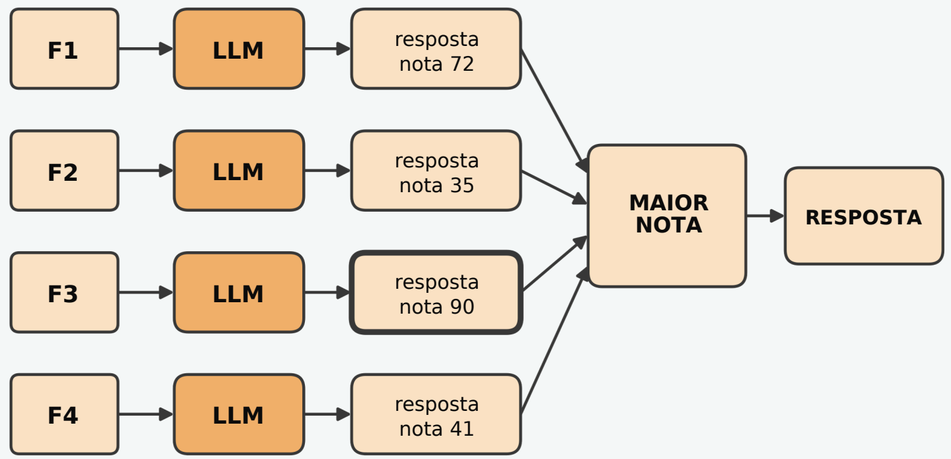


Metodos de RAG

Map-Reduce (5 chamadas)

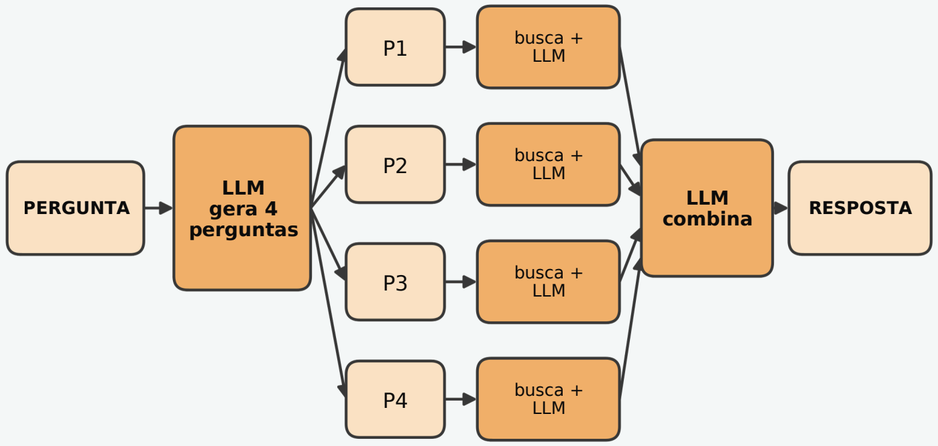


Map-Rerank (4 chamadas)

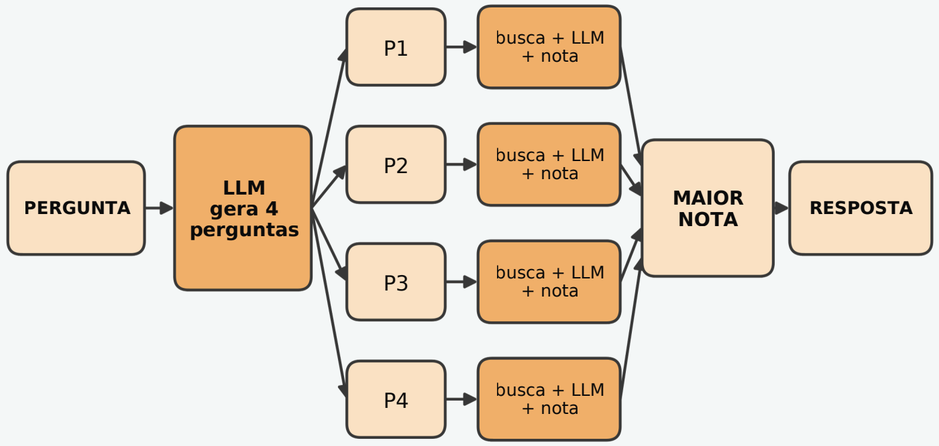


Metodos de RAG

Query Step-Down (6 chamadas)



Reciprocal (5 chamadas)



Metodos de RAG

Família	Método	Chamadas	Como usa os fragmentos
Tudo de uma vez	**Stuff**	1	Junta os 4 fragmentos e a pergunta em um único prompt
Um fragmento por vez	**Refine**	4	Responde com o 1º e refina a resposta a cada fragmento seguinte
	Map-Reduce	5	Uma resposta parcial por fragmento; combina as parciais no final
	Map-Rerank	4	Uma resposta por fragmento, com nota de confiança; fica com a maior
Reformula a pergunta	**Query Step-Down**	6	Gera 4 perguntas mais específicas, busca para cada uma e combina as respostas
	Reciprocal RAG	5	Gera as mesmas 4 perguntas e fica só com a resposta mais confiante

Chamadas ao LLM com k = 4: cada método muda o custo e o tempo, e a forma de usar o contexto.

INTRODUÇÃO

Problemática e Motivação

Um pipeline de RAG envolve escolhas de engenharia cujo efeito combinado raramente é medido de forma sistemática.

O PROBLEMA

Escolhas de engenharia no pipeline

- Método de injeção
- LLM
- Banco vetorial
- Modelo de embedding

↓

Efeito sobre qualidade · tokens

1. **Quando o RAG acrescenta algo?**
   O ganho depende do domínio e do que o LLM já sabe.
2. **Qual método de injeção usar?**
   Mais chamadas ao LLM custam mais tokens e tempo.
3. **O método certo vale um modelo mais caro?**
   Comparar modelos econômicos e intermediários.

É preciso equilibrar a qualidade da resposta com o custo em tokens, dólares .

Objetivos da pesquisa

Estudo de referência

23.625

configurações testadas por Şakar e Emekci (2025). Lacunas:

- Só similaridade de cosseno
- Sem controle sem RAG
- Resultados agregados entre LLMs
- Só documentos em inglês

QP1 Como os 6 métodos se comparam em qualidade e custo em cada domínio?

QP2 A ordem dos métodos se mantém entre LLMs diferentes?

QP3 Quanto o RAG acrescenta em relação ao LLM sem RAG?

QP4 A busca aproximada do banco vetorial altera os resultados?

METODOLOGIA

Desenho do estudo

Estudo quantitativo e experimental: as mesmas perguntas respondidas por cada método e cada LLM.

7

condições por pergunta

Os 6 métodos de RAG e um controle sem recuperação

3

conjuntos de dados públicos

Docugami (financeiro), MedQA (médico) e FaQuAD (português)

7

LLMs de 4 empresas

5 modelos econômicos e 2 intermediários, 2 deles de pesos abertos

100

perguntas por conjunto

Camada principal; 25 delas na camada de generalização

FIXO EM TODOS OS EXPERIMENTOS

BGE-M3, fragmentos de 1.000 caracteres e k = 4

O QUE VARIA

Só o método de injeção e o LLM, para isolar o efeito de cada um deles

METODOLOGIA

Execução dos testes

Cada método rodou com cada LLM, nos três domínios, sobre as mesmas perguntas.

10.500

Camada principal

5 LLMs × 3 conjuntos × 7 condições × 100 perguntas

+

1.050

Generalização

2 LLMs × 3 conjuntos × 7 condições × 25 perguntas

+

600

Repetições do Stuff

4 LLMs × 3 conjuntos × 25 perguntas × 2 repetições

=

12.150

Execuções no total

Soma das três partes

Variação do modelo

Temperatura 0 onde o modelo aceita. Haiku, Luna, Sonnet e Sol, que não aceitam, rodaram o Stuff 3 vezes para medir a variação.

Ambiente

Out.–nov. de 2026, Python 3.12, notebook i5-12450H com 20 GB de RAM, sem GPU. OpenAI pela API; os demais via OpenRouter.

Registro

Cada execução guardou pergunta, fragmentos, resposta, tokens, tempos, versão do modelo e provedor.

METODOLOGIA

Conjuntos de dados

Públicos | **Gabarito feito por terceiros** | **Corpus igual ao material de origem**

Conjunto	Domínio	Corpus	Fragmentos	Perguntas (amostra)	Gabarito
Docugami SEC 10-Q	Financeiro, inglês	20 relatórios trimestrais de Apple, Amazon, Intel, Microsoft e NVIDIA	4.463	195 (100)	Resposta escrita com os valores pedidos
MedQA-USMLE	Médico, inglês	18 livros-texto de medicina	121.553	1.273 (100)	Alternativa correta oficial
FaQuAD	Ensino superior, português	249 parágrafos de uma universidade federal e da Wikipédia	318	900 (100)	Trecho do parágrafo

METODOLOGIA

Modelos de LLM utilizados

Modelo	Empresa	Pesos	US$/1M (entrada / saída)	Camada
gpt-4o-mini	OpenAI	Fechados	0,15 / 0,60	Principal: 100 perguntas por conjunto
GPT-6 Luna	OpenAI	Fechados	0,10 / 0,50	Principal
Claude Haiku 5.5	Anthropic	Fechados	0,10 / 0,50	Principal
Qwen3.5-9B	Alibaba	Abertos	0,17 / 0,25	Principal
DeepSeek V4 Pro	DeepSeek	Abertos	0,90 / 1,80	Principal
Claude Sonnet 5	Anthropic	Fechados	2 / 10	Generalização: 25 perguntas por conjunto
GPT-6 Sol	OpenAI	Fechados	2 / 10	Generalização

Raciocínio estendido desligado em todos: o foco é o método, não o quanto o modelo pensa

METODOLOGIA

Embedding e Banco Vetorial

1.000

caracteres por fragmento, com sobreposição de 100

BGE-M3

embedding multilíngue, executado localmente

HNSW

índice do ChromaDB: busca aproximada

k = 4

fragmentos por pergunta, em todos os métodos

Verificação à parte: ChromaDB (HNSW) × FAISS (busca exata)

318 vetores	4.463 vetores	121.553 vetores

METODOLOGIA

Métricas Principais

MedQA	Acurácia: a letra escolhida contra a alternativa oficial
FaQuAD	Cobertura de tokens: fração da resposta de referência presente na gerada
Docugami	Valores do gabarito: fração dos valores em US$ e % na resposta (tolerância de 2%)
Custo e busca	Tokens, US$ · Hit@4, Recall@4 e MRR@10

METODOLOGIA

Métricas complementares RAGAS: um LLM como juiz

LADO DA RESPOSTA

Faithfulness

A resposta se sustenta nos trechos recuperados?

LADO DA RESPOSTA

Answer Relevancy

A resposta trata do que foi perguntado?

LADO DA BUSCA

Context Precision

Os trechos recuperados são relevantes?

LADO DA BUSCA

Context Recall

Os trechos cobrem a resposta de referência?

AUROC

0,70

Juiz validado no RAGBench, em 206 respostas. Moderadamente confiável: as conclusões principais vêm do gabarito. Modelo do juiz: gpt-4o-mini.

METODOLOGIA

Execução e análise estatística

12.150

execuções no total

US$ 20,09

custo nominal de geração

Pareada

todos os métodos respondem às mesmas perguntas

W de Kendall

concordância da ordem dos métodos entre LLMs

Friedman e Wilcoxon com correção de Holm: dizem se um método é de fato melhor que outro

Métodos implementados direto sobre as APIs, com cada chamada registrada

RESULTADOS

O dominio decide o resultado

O mesmo experimento produziu três comportamentos diferentes do RAG

FaQuAD · normas de uma universidade

1,7× a 2,5×

a cobertura da resposta com o RAG, em todos os modelos

O Stuff, o método mais simples e barato, foi o melhor.

MedQA · questões de medicina

0

métodos que mudaram a acurácia de forma significativa

Os modelos já acertam de 71% a 96% sem RAG: o conteúdo já está neles.

Docugami · relatórios financeiros

< 25%

dos valores pedidos, mesmo no melhor caso dos econômicos

A recuperação é o gargalo, e o Query Step-Down liderou.

A ordem dos métodos depende mais do domínio do que do LLM

RESULTADOS

Achar o documento certo não basta

Qualidade dos quatro fragmentos que chegam ao LLM, a mesma para todos os modelos

FaQuAD

249 parágrafos · 900 perguntas

das perguntas com o parágrafo certo entre os 4 fragmentos

91%

da resposta de referência coberta pelos fragmentos (Context Recall)

0,94

Docugami

20 relatórios · 195 perguntas

das perguntas com o relatório certo entre os 4 fragmentos

82%

da resposta coberta: menos da metade (Context Recall)

0,41

MedQA

18 livros-texto · 121 mil fragmentos

o gabarito não indica o trecho dos livros

—

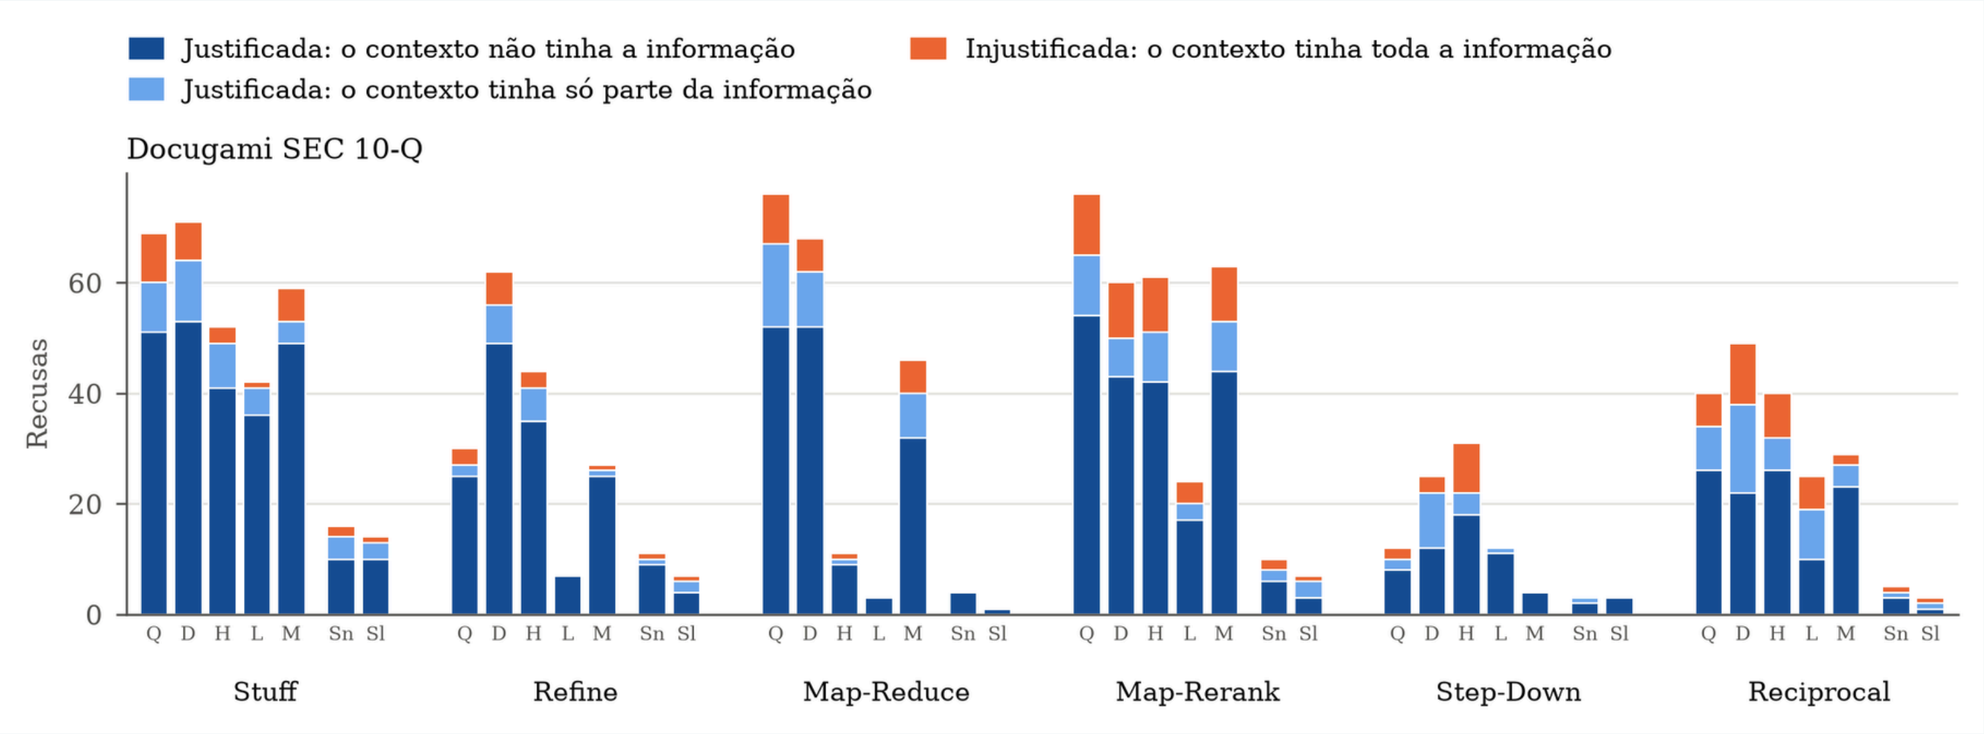
da resposta coberta pelos livros-texto (Context Recall)

0,52

No Docugami, a resposta junta valores de tabelas, trimestres e empresas diferentes: quatro fragmentos raramente trazem tudo

RESULTADOS

A maior parte das recusas é falha de recuperação



das 1.302 recusas: sem a informação no contexto

72%

com só parte da informação no contexto

16%

injustificadas: o contexto tinha tudo

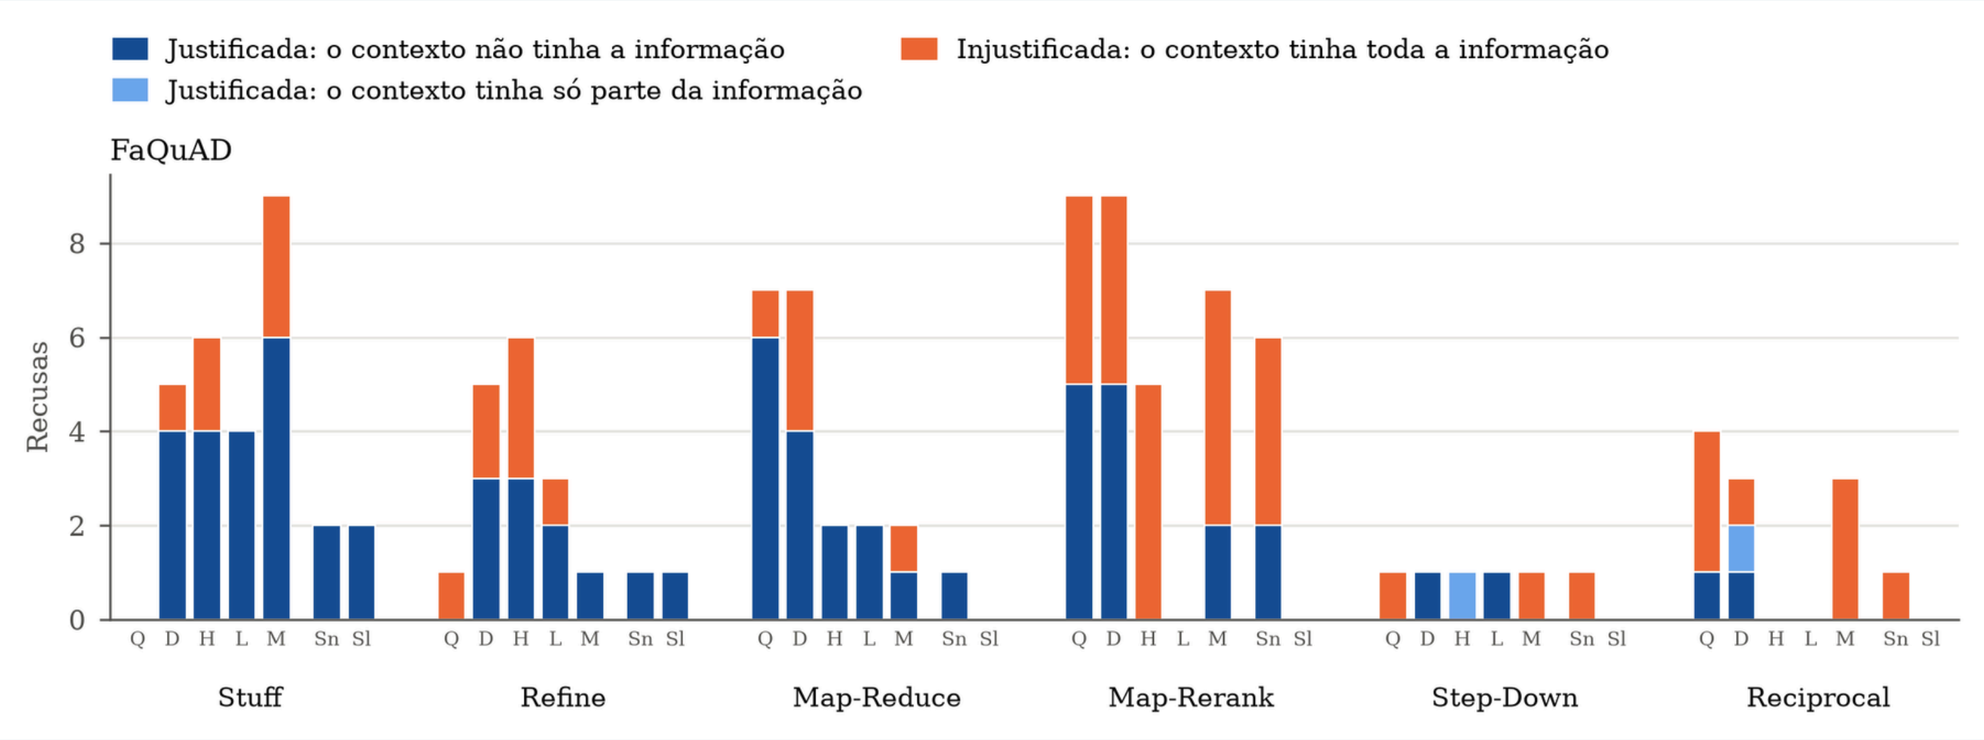
13%

recusas do Query Step-Down × do Stuff

90 × 323

RESULTADOS

Recusas no FaQuAD



recusas nos 7 modelos e 6 métodos

120

injustificadas: o contexto tinha toda a informação

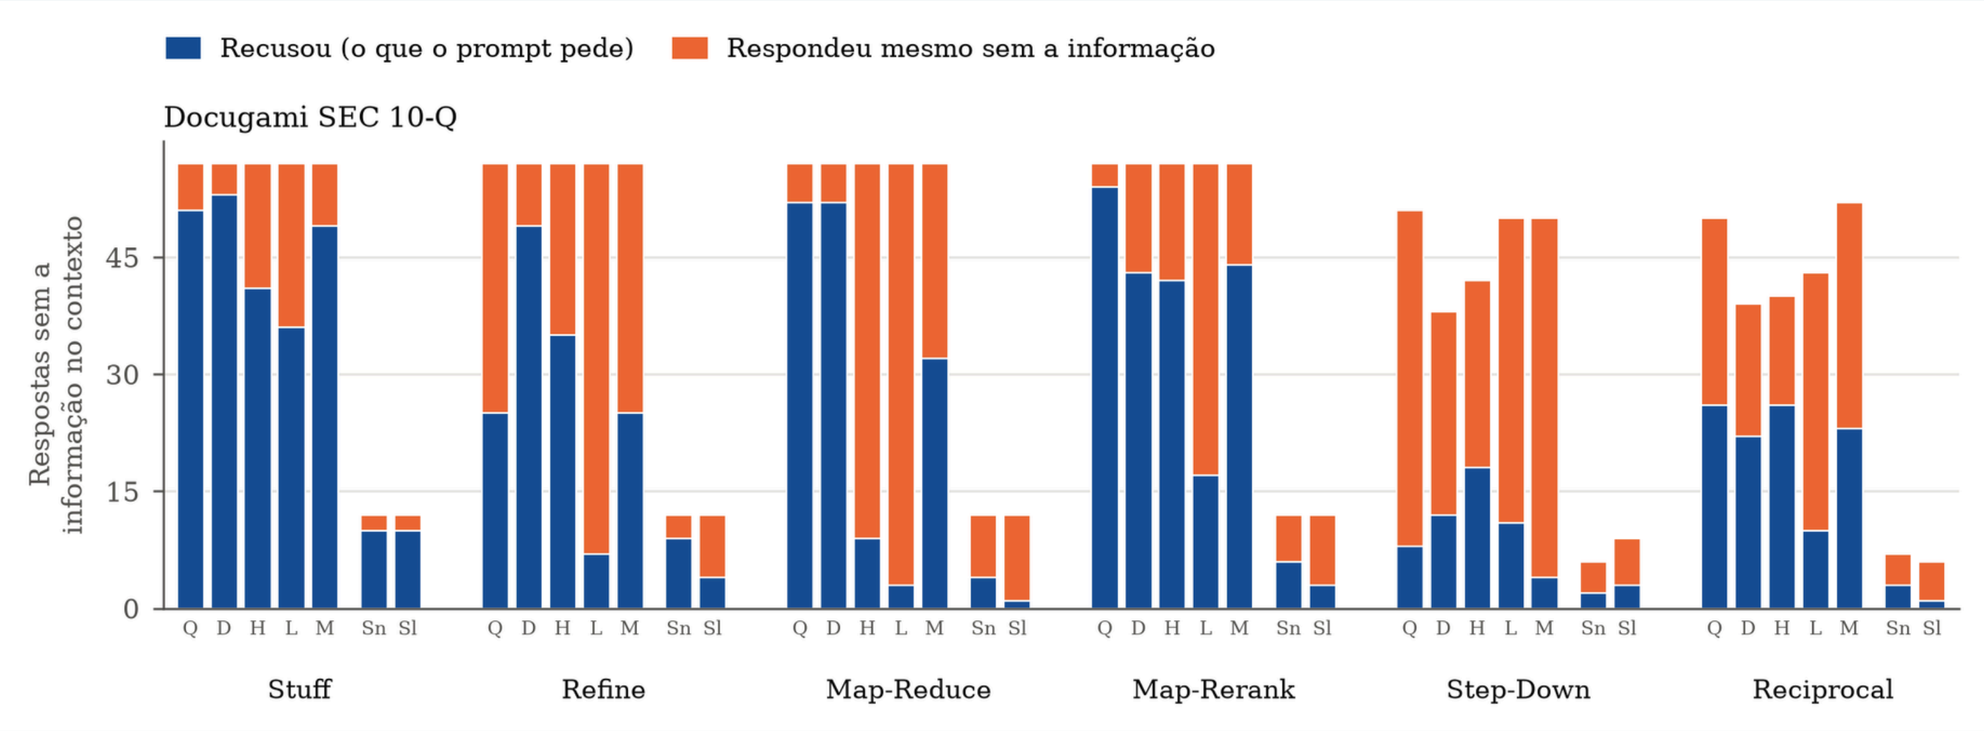
43%

injustificadas vieram do Map-Rerank, mais que as suas recusas justificadas (14)

22 de 51

RESULTADOS

Recusar pouco não é sinal de qualidade



das respostas de RAG sem nada da informação no contexto

52%

delas foram respondidas assim mesmo

46%

dessas respostas sem nenhum valor correto

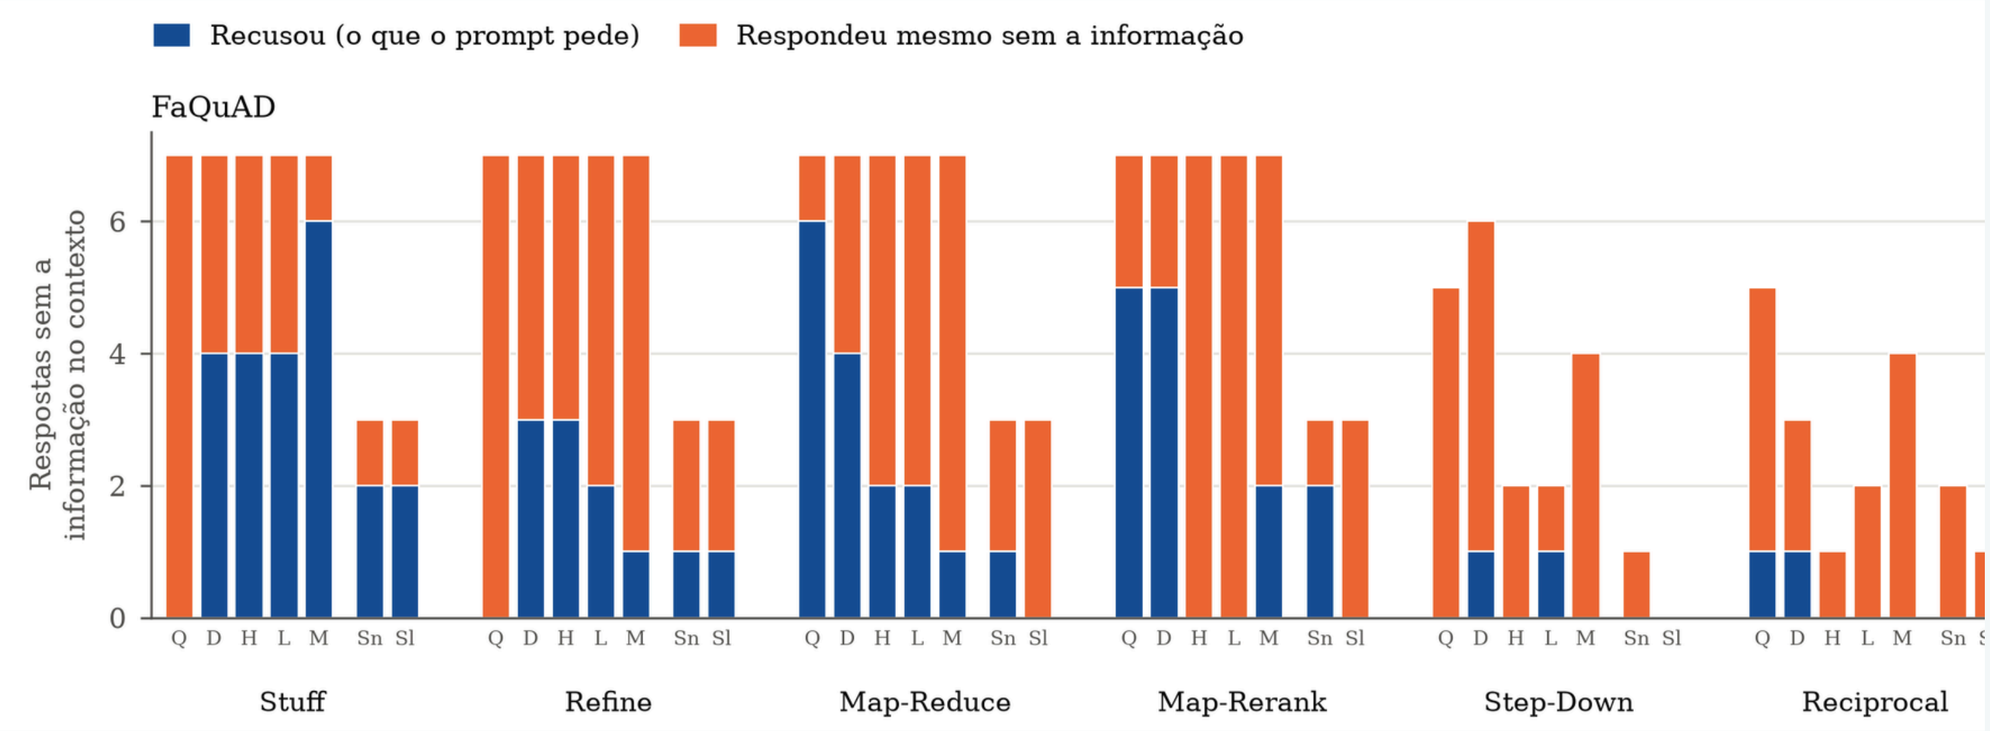
93%

Luna e Sol: os que menos recusam são os que mais respondem sem a informação

74% · 65%

RESULTADOS

No FaQuAD a imformação quase sempre chega



das respostas de RAG sem nada da informação no contexto (52% no Docugami)

6%

delas foram respondidas assim mesmo

67%

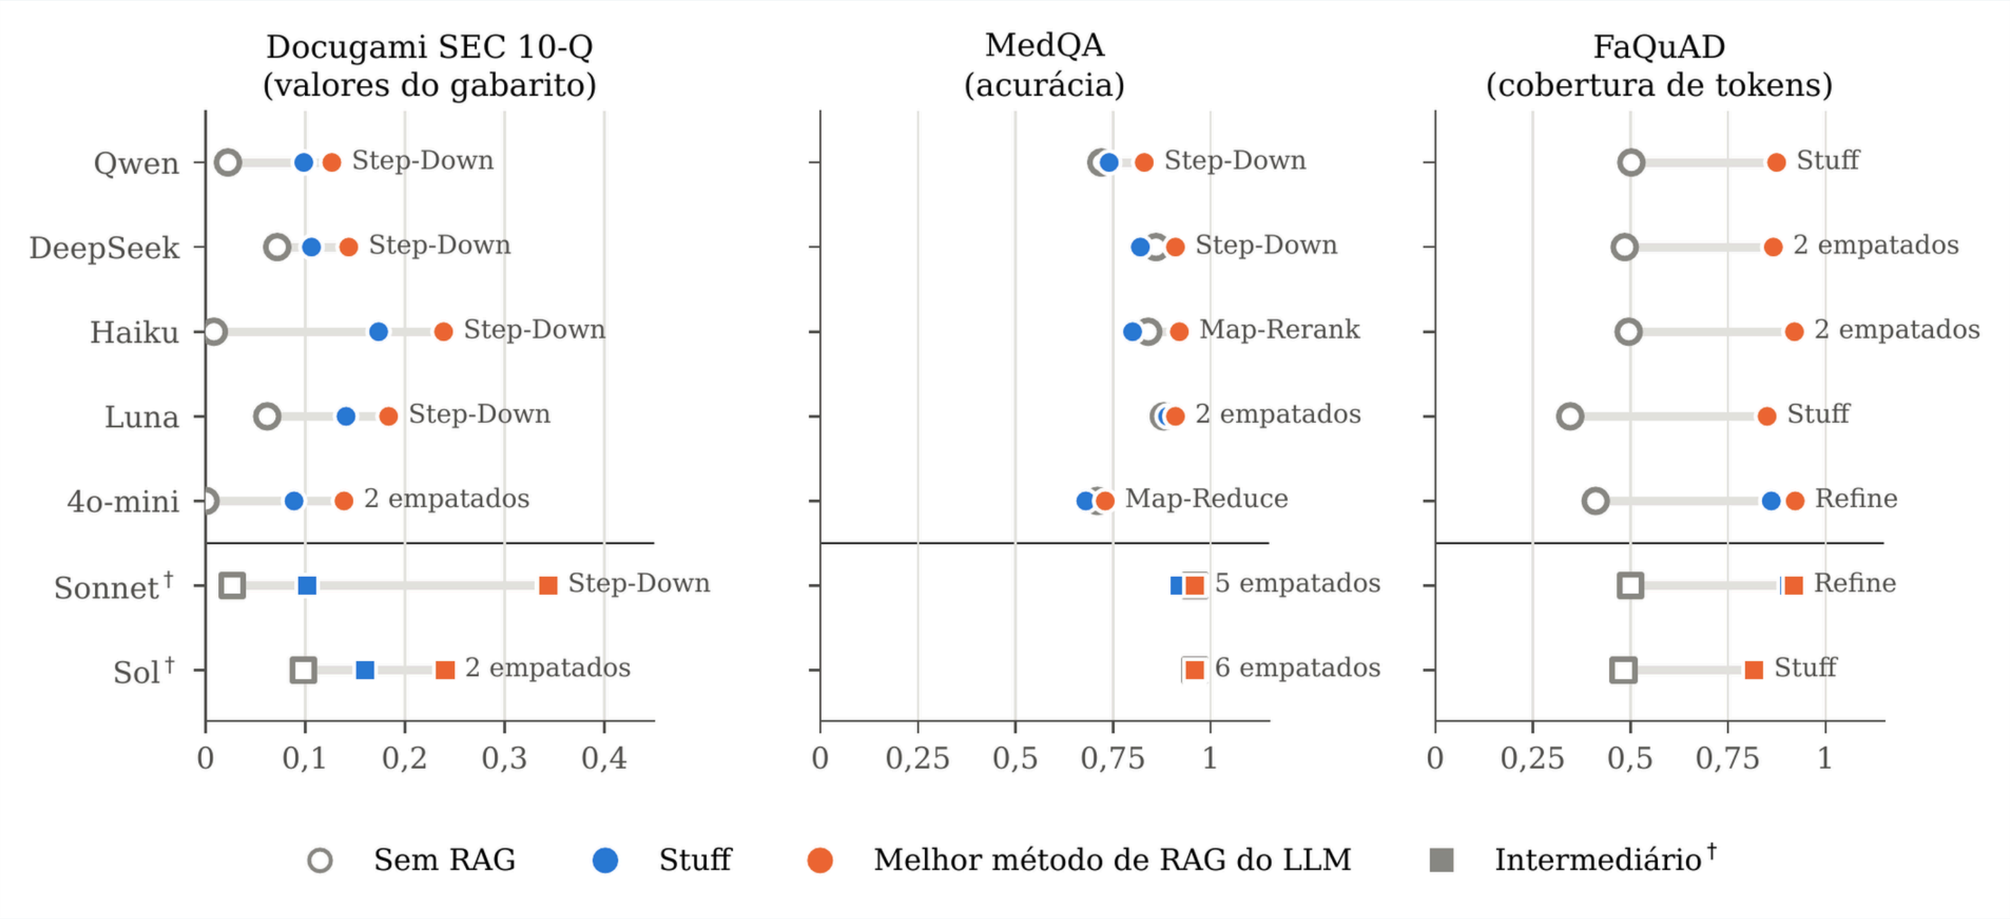
cobertura média dessas respostas, contra 0,85 com toda a informação no contexto

0,39

das respondidas tinham a resposta literalmente no contexto: o juiz nem sempre a reconheceu

40%

Efeito do RAG em cada domínio



Círculos: econômicos (100 perguntas). Quadrados: intermediários (25 perguntas). Docugami: valores do gabarito; MedQA: acurácia; FaQuAD: cobertura de tokens.

RESULTADOS

Impacto do RAG

FaQuAD

cobertura da resposta

sem RAG	com o Stuff
35–50%	→ 85–92%

- Todos os 6 métodos melhoraram os 5 modelos
- Normas que o modelo não tem como saber de memória

MedQA

acurácia

sem RAG	com o Stuff
71–88%	→ ± 4 p.p.

- Nenhum método mudou a acurácia de forma significativa
- Sonnet e Sol: 96% com ou sem RAG

Docugami

valores do gabarito na resposta

sem RAG	melhor método
0–7%	→ 13–24%

- Ganho significativo em 4 dos 5 modelos
- Mesmo assim, o Stuff recusou 42% a 71%

Quanto mais o modelo já sabe, menor o espaço para o RAG

RESULTADOS

O melhor método muda com o domínio

Método	Docugami	FaQuAD	MedQA
Stuff	2,8	**1,4**	**5,2**
Refine	3,2	3,0	3,7
Map-Reduce	3,8	2,8	3,0
Map-Rerank	**6,0**	5,0	2,4
Step-Down	**1,2**	3,0	**2,3**
Reciprocal	4,0	**5,8**	4,4

Posto médio nos 5 modelos econômicos (1 = melhor). Verde-azulado: o melhor; âmbar: o pior.

Docugami · Query Step-Down

Maior proporção de valores; o Map-Rerank ficou significativamente abaixo dele nos 5 modelos

FaQuAD · Stuff

Maior cobertura com o método mais barato; o Reciprocal perdeu de 11 a 28 pontos para o Stuff

MedQA · sem vencedor claro

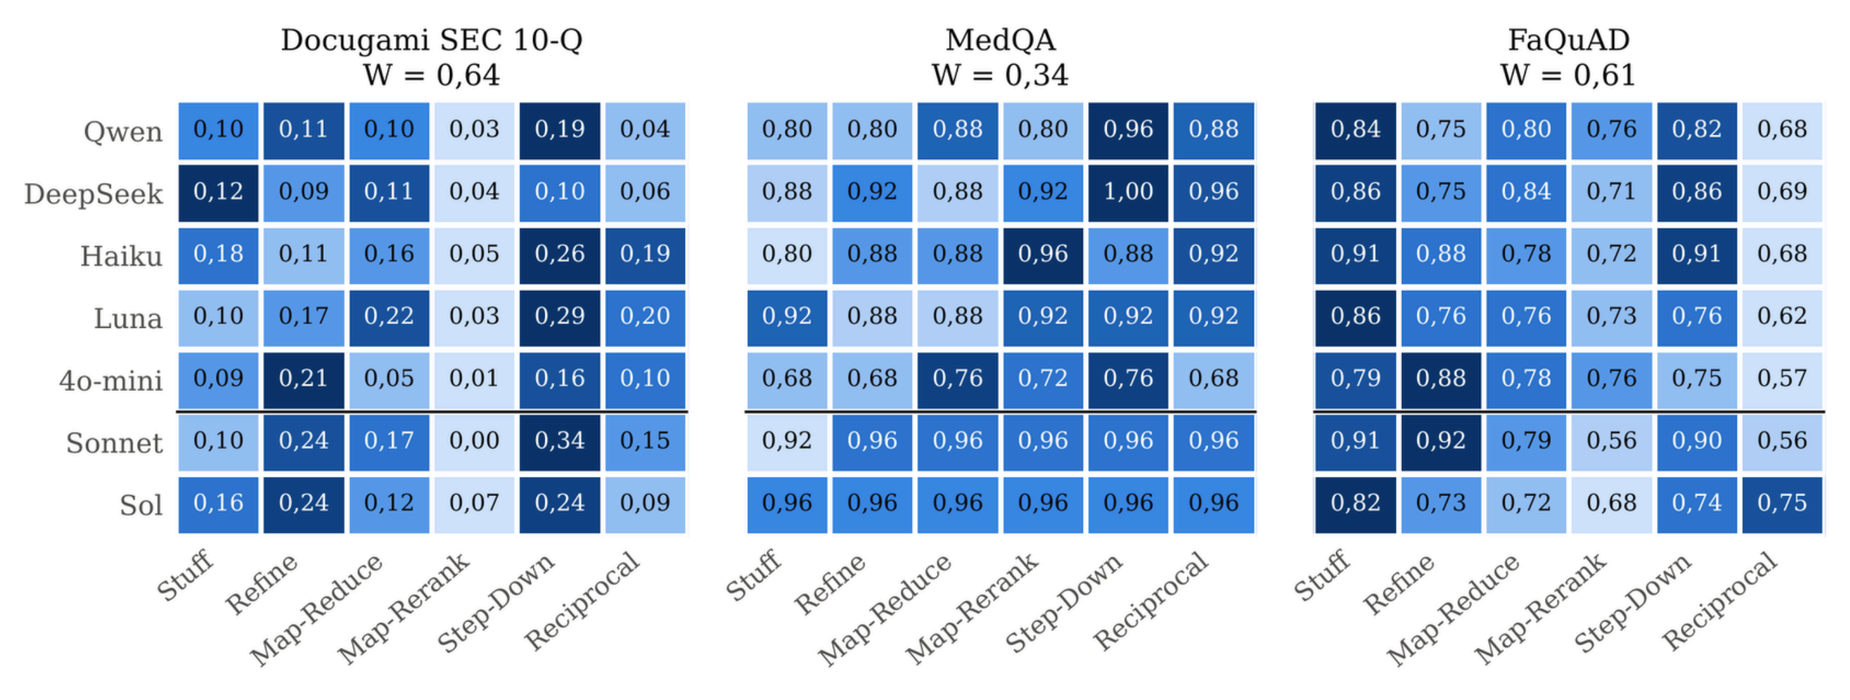
Sem ordem consistente entre os modelos (W = 0,39; p = 0,08): diferenças de poucos pontos

Map-Rerank e Reciprocal, que escolhem uma única resposta por nota de confiança, ficaram entre os piores no Docugami e no FaQuAD

RESULTADOS

Ordem dos métodos se repete entre os LLMs

Posição de cada método dentro de cada LLM nas 25 perguntas comuns (mais escuro = melhor)



Docugami: concordância alta entre os 5 econômicos (p = 0,003)

W = 0,71

MedQA: sem ordem consistente entre os 5 econômicos (p = 0,08)

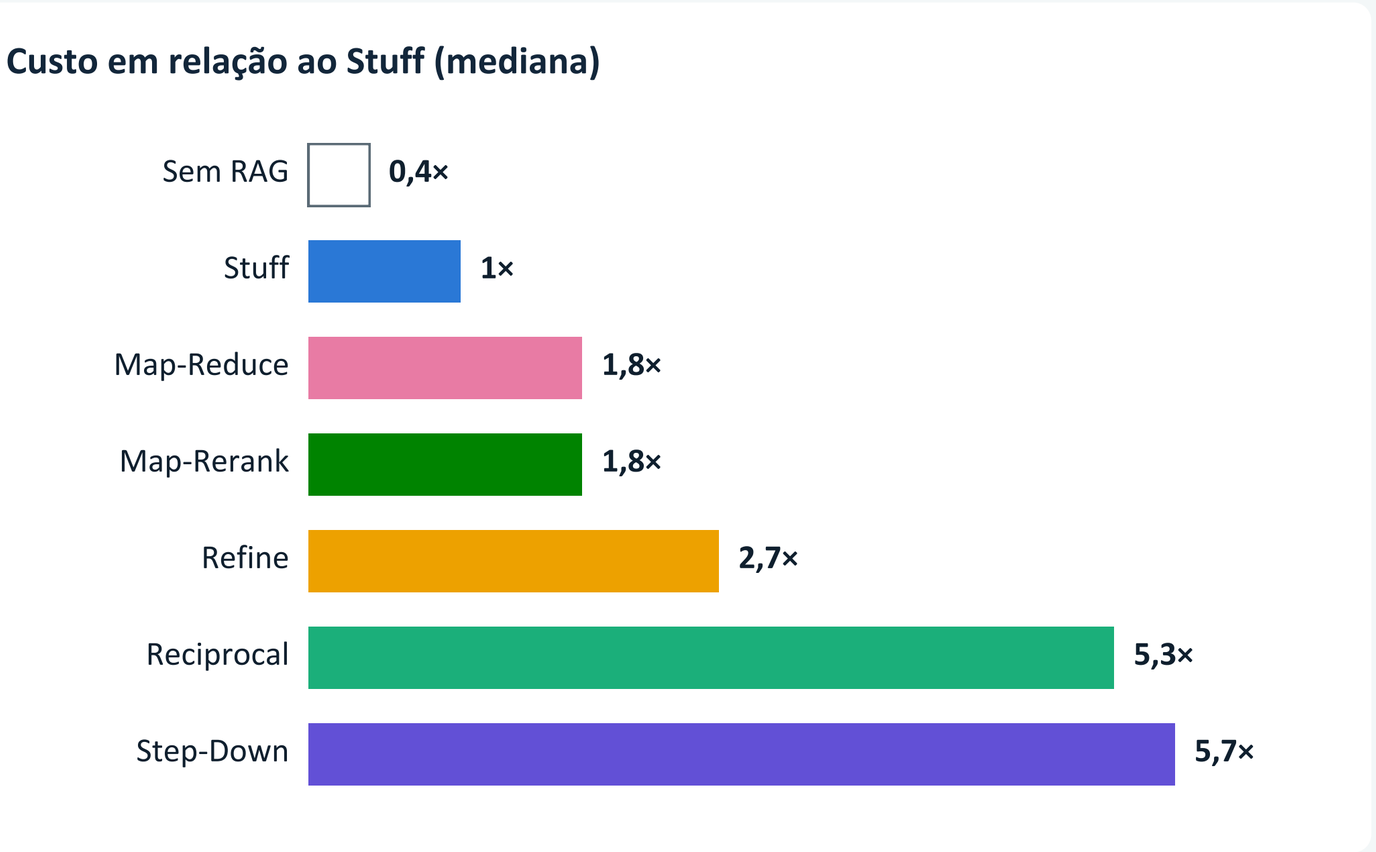
W = 0,39

FaQuAD: concordância alta entre os 5 econômicos (p = 0,002)

W = 0,74

RESULTADOS

Custo de cada método



tempo mediano do Stuff, da recuperação ao fim da geração

2,9 s

tempo mediano do Query Step-Down, o mais lento

16,0 s

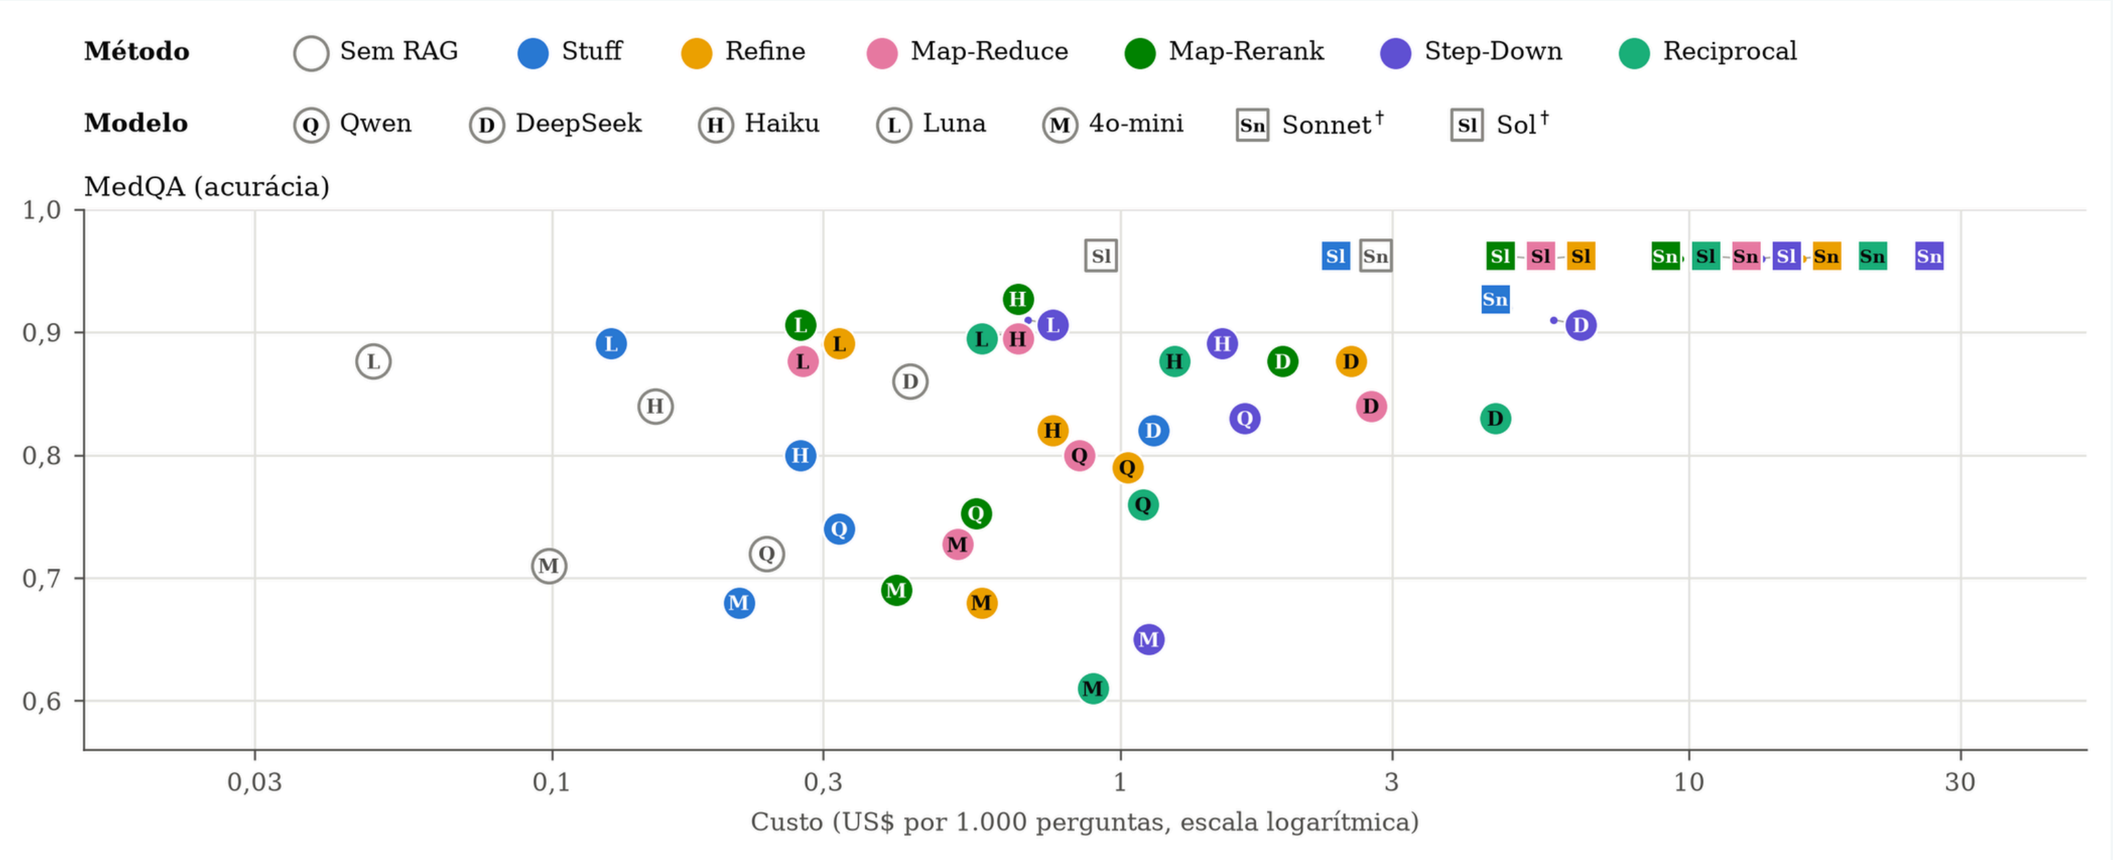
ao LLM por pergunta no Query Step-Down; o Stuff faz 1

6 chamadas

Custo relativo: custo do método ÷ custo do Stuff, por LLM e conjunto (mediana dos 15 pares da camada principal). Tempo: mediana de 1.500 respostas por método.

RESULTADOS

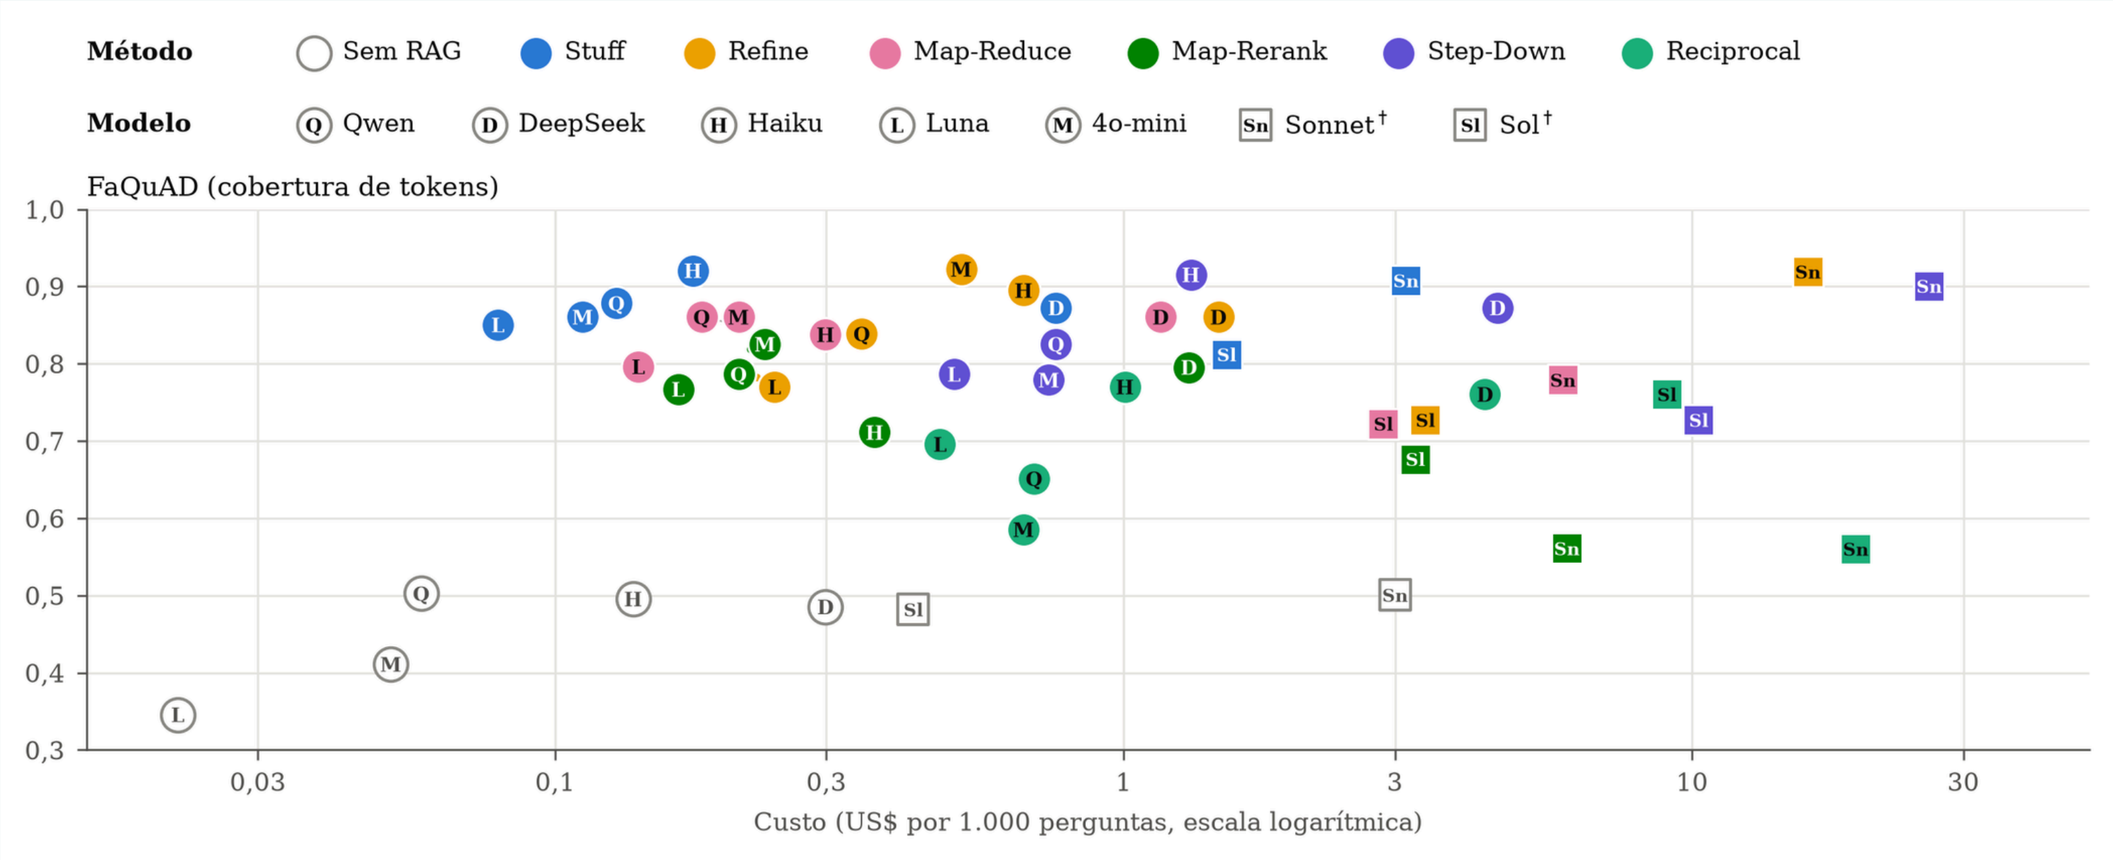
Desempenho no MedQA



Do método mais barato ao mais caro, o custo variou de 7 a 15 vezes, e a acurácia, no máximo 12 pontos

RESULTADOS

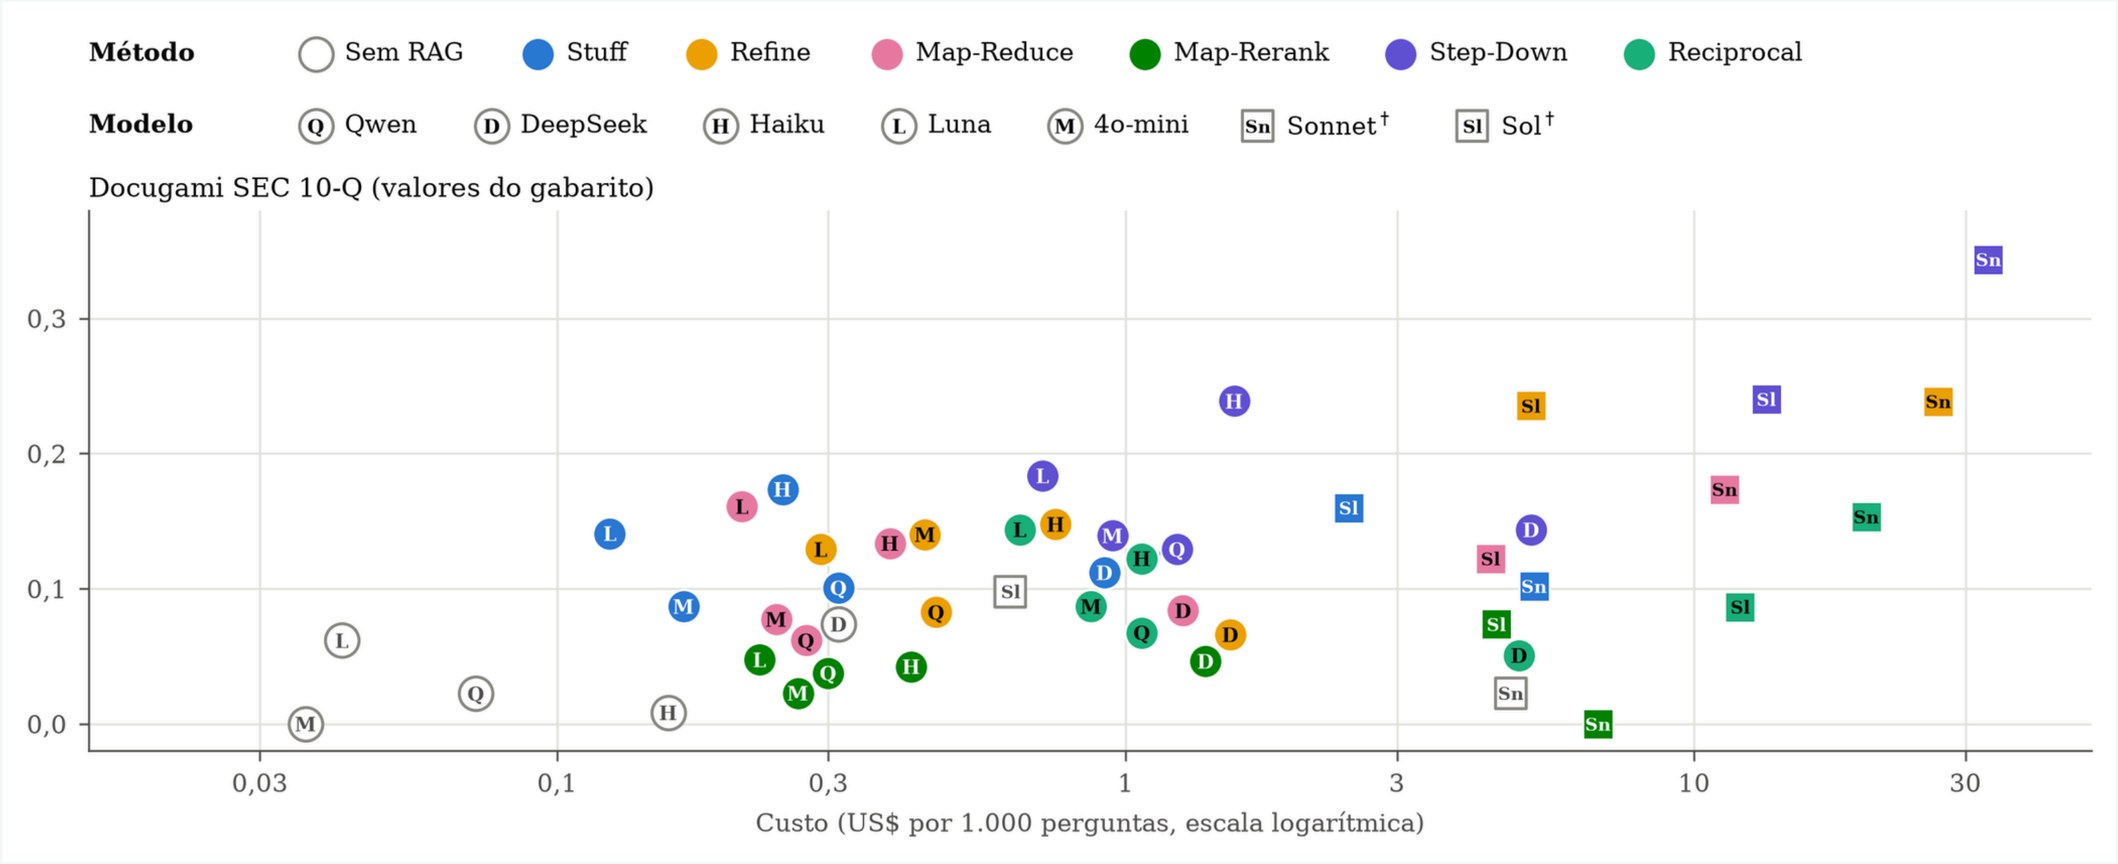
Desempenho no FaQuAD



O Stuff, o método de RAG mais barato, teve a maior cobertura ou empatou com ela em 5 dos 7 modelos

RESULTADOS

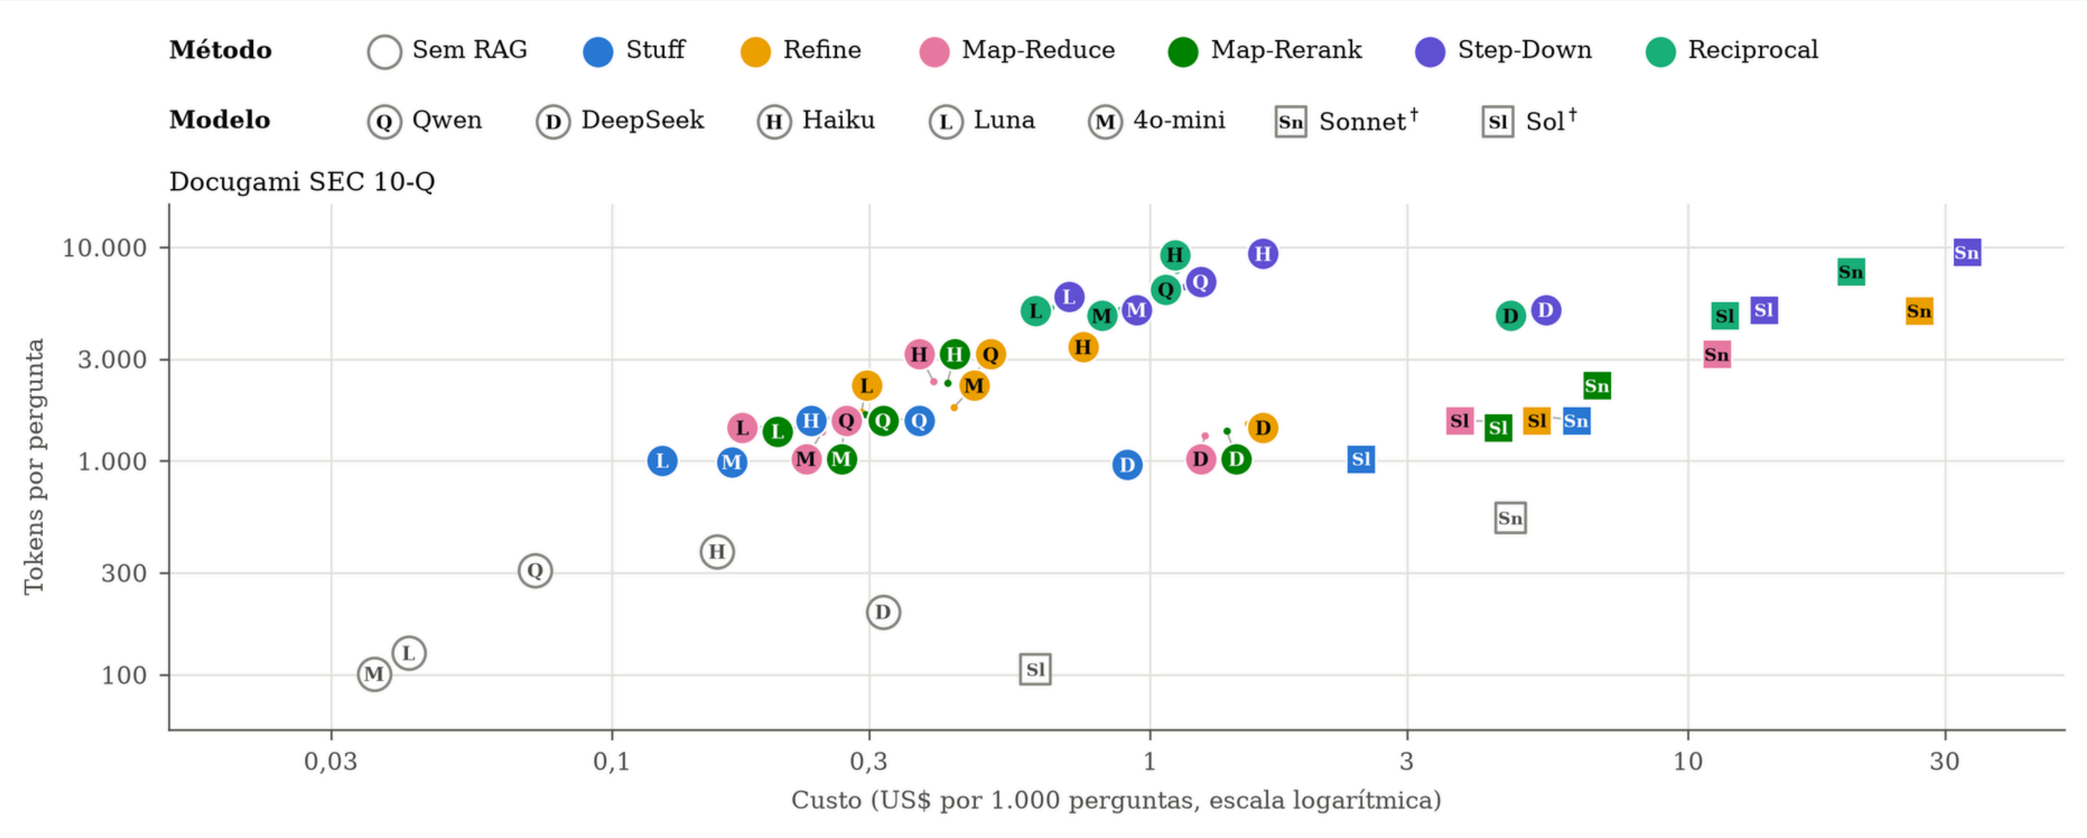
Desempenho no Docugami



O Query Step-Down, o mais caro, teve a maior métrica em 5 dos 7 modelos e empatou com o Refine nos outros 2

RESULTADOS

O preço do token pesa mais



Mesmo consumo, token 20 vezes mais caro: até o Stuff do Sonnet e do Sol custou mais que o Query Step-Down do Haiku e do Luna

RESULTADOS

O método certo vale mais que o modelo caro

Econômico com o seu melhor método contra o intermediário com o Stuff, nas 25 perguntas que os dois modelos responderam

Docugami valores do gabarito na resposta	**Haiku + Query Step-Down** US$ 1,63 por 1.000 perguntas	26%	vs	**Sonnet + Stuff** US$ 5,23 por 1.000 perguntas	10%	p = 0,018 significativo · 3,2× mais barato
	Luna + Query Step-Down US$ 0,75 por 1.000 perguntas	29%	vs	**Sol + Stuff** US$ 2,47 por 1.000 perguntas	16%	p = 0,12 não significativo · 3,3× mais barato
MedQA acurácia	**Haiku + Map-Rerank** US$ 0,65 por 1.000 perguntas	96%	vs	**Sonnet + Stuff** US$ 4,81 por 1.000 perguntas	92%	p = 1,00 não significativo · 7,4× mais barato
	Luna + Map-Rerank US$ 0,28 por 1.000 perguntas	92%	vs	**Sol + Stuff** US$ 2,42 por 1.000 perguntas	96%	p = 1,00 não significativo · 8,7× mais barato
FaQuAD cobertura de tokens	**Haiku + Stuff** US$ 0,17 por 1.000 perguntas	0,91	vs	**Sonnet + Stuff** US$ 3,14 por 1.000 perguntas	0,91	p = 0,69 não significativo · 18,3× mais barato
	Luna + Stuff US$ 0,08 por 1.000 perguntas	0,86	vs	**Sol + Stuff** US$ 1,51 por 1.000 perguntas	0,82	p = 0,46 não significativo · 19,5× mais barato

Em nenhum conjunto o intermediário foi significativamente superior, e o econômico custou de 3 a 20 vezes menos.

RESULTADOS

A métrica muda a conclusão

Docugami: as duas métricas contam histórias opostas

Similaridade de cosseno

6 de 7

modelos deram nota maior ao sem RAG que ao Stuff (em 2 deles, por menos de 0,01)

Valores do gabarito

7 de 7

modelos trouxeram mais valores corretos com o Stuff que sem RAG

correlação entre o cosseno e os valores corretos, em 3.850 respostas

ρ = 0,43

cosseno das respostas sem nenhum valor correto × com todos os valores

0,70 × 0,86

O estudo de referência mediu só o cosseno e recomendou o Reciprocal para documentos financeiros; aqui, ele ficou entre os piores no Docugami

RESULTADOS

Métricas RAGAS

	Faithfulness			Answer Relevancy		
	Docugami	MedQA	FaQuAD	Docugami	MedQA	FaQuAD
Sem RAG	—	—	—	0,28	0,53	0,56
Stuff	0,74	0,22	0,90	0,28	0,54	0,69
Refine	0,77	0,33	0,86	0,39	0,51	0,68
Map-Reduce	0,51	0,19	0,82	0,35	0,54	0,77
Map-Rerank	0,65	0,18	0,85	0,21	0,50	0,47
Step-Down	—	—	—	0,44	0,54	0,68
Reciprocal	—	—	—	0,29	0,50	0,50

Médias das respostas dos 7 LLMs.

AUROC do juiz gpt-4o-mini no RAGBench: as métricas RAGAS são uma leitura complementar

0,70

A Faithfulness só se aplica aos métodos com um conjunto único de trechos.

RESULTADOS

Os resultados resistem a variações

Busca aproximada × exata

ChromaDB (HNSW) contra FAISS (busca exata), com os mesmos vetores

mesmos 4 fragmentos no FaQuAD e no Docugami

100%

no MedQA, com 121 mil vetores

82%

acurácia do Stuff refeito com o FAISS no MedQA (McNemar p = 1,0)

0,68 → 0,69

Variação entre execuções

Stuff repetido 3 vezes nos 4 modelos sem temperatura 0

desvio-padrão médio da métrica entre as 3 execuções

≤ 0,053

modelos escolheram a mesma alternativa nas 3 execuções em todo o MedQA

3 de 4

perda do Reciprocal para o Stuff no FaQuAD: muito maior que a variação

11 a 28 pontos

CONCLUSÃO

Resposta às perguntas da pesquisa

QP1

Como os 6 métodos se comparam em qualidade e custo em cada domínio?

Depende do domínio: Query Step-Down à frente no financeiro, Stuff no FaQuAD e nenhuma diferença relevante no MedQA.

QP2

A ordem dos métodos se mantém entre LLMs diferentes?

Sim no Docugami e no FaQuAD (W de Kendall de 0,71 e 0,74); no MedQA, não houve ordem consistente.

QP3

Quanto o RAG acrescenta em relação ao LLM sem RAG?

Muito quando o modelo não conhece o conteúdo (FaQuAD: 1,7 a 2,5 vezes); nada quando já conhece (MedQA).

QP4

A busca aproximada do banco vetorial altera os resultados?

Não: os bancos entregaram os mesmos fragmentos em 82% a 100% das consultas, sem mudar a acurácia.

CONCLUSÃO

O que mais os dados mostraram

1

O método certo vale um modelo mais caro

Os econômicos com o método adequado não ficaram significativamente abaixo dos intermediários, a um custo de 3 a 20 vezes menor.

2

A métrica muda a conclusão

Só com a similaridade de cosseno, o RAG pareceria piorar as respostas financeiras, embora traga mais valores corretos.

3

Recusar pouco não é sinal de qualidade

Os modelos que menos recusam com a informação no contexto são os que mais respondem sem ela.

A recuperação é o gargalo: quando a informação não chega ao modelo, trocar o LLM não resolve

CONCLUSÃO

Recomendações para construção de um RAG

1

Medir o modelo sem RAG primeiro

para saber se a recuperação acrescenta algo no domínio

2

Começar pelo Stuff

o mais barato em quase todas as combinações e o melhor quando a busca acha o trecho

3

Reformular a pergunta só se a recuperação for o gargalo

o Query Step-Down custa quase 6 vezes o Stuff

4

Evitar escolher uma resposta por nota de confiança

Map-Rerank e Reciprocal ficaram entre os piores no Docugami e no FaQuAD

5

Testar um modelo econômico com o método certo

antes de pagar 20 vezes mais por token

6

Medir o conteúdo, não só a semelhança

a métrica deve verificar o valor, a alternativa ou o trecho pedido

CONCLUSÃO

Limitações e Trabalhos futuros

Limitações

- 100 perguntas por conjunto (25 nos modelos intermediários)
- Uma configuração fixa: BGE-M3, fragmentos de 1.000 caracteres e k = 4
- Juiz automático com AUROC de 0,70, sem avaliação humana
- 4 dos 7 modelos sem temperatura 0; os outros métodos rodaram uma vez
- Modelos comerciais podem mudar sem aviso

Trabalhos futuros

- Variar k, o modelo de embedding e a compressão do contexto
- Testar rerankers e busca híbrida no domínio financeiro
- Incluir modelos de topo na camada de generalização
- Acrescentar conjuntos em português de outros domínios
- Validar as métricas automáticas com avaliação humana

Obrigado!

Perguntas?

Afonso Henriques Massunari | Ryan Alves Mazzeu

Orientador: Carlos Henrique Valério de Moraes

UNIFEI - Novembro 2026